

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT TP. HỒ CHÍ MINH
KHOA CÔNG NGHỆ THÔNG TIN



HCMUTE

BÁO CÁO MÔN HỌC
LẬP TRÌNH R CHO PHÂN TÍCH
HỆ THỐNG PHÂN TÍCH VÀ DỰ ĐOÁN
GIÁ BẤT ĐỘNG SẢN TP.HCM

GVHD: ThS. Phan Thị Thê

SVTH:	Họ tên	MSSV
	Trương Quốc Duy	24133009
	Võ Lê Hoàng Đức	24133013
	Trần Anh Khoa	24133031
	Bùi Nguyễn Nguyên Khang	24133902
	Phạm Thế Quân	24134057

TP. Hồ Chí Minh, tháng 6 năm 2026

[illegible]

Thành phố Hồ Chí Minh, Ngày.....Tháng.....Năm.....

Giảng viên hướng dẫn

LỜI CẢM ƠN

Lời đầu tiên, nhóm thực hiện đề tài xin gửi lời cảm ơn chân thành đến Khoa Công nghệ Thông tin - Trường Đại học Công nghệ Kỹ thuật TP. Hồ Chí Minh. Nhờ sự tạo điều kiện thuận lợi từ phía Khoa, chúng em đã có cơ hội học tập, nghiên cứu và tích lũy những kiến thức nền tảng quý báu của môn học Lập trình R cho phân tích. Đây chính là yếu tố then chốt giúp chúng em xây dựng và hoàn thành dự án này.

Đặc biệt, chúng em xin bày tỏ lòng biết ơn sâu sắc đến cô ThS. Phan Thị Thê, người đã tận tâm truyền đạt kiến thức, hướng dẫn và đồng hành cùng nhóm trong suốt quá trình nghiên cứu. Những chỉ dẫn định hướng và góp ý chuyên môn của cô là kim chỉ nam giúp chúng em vượt qua các khó khăn kỹ thuật để hoàn thiện đề tài.

Với những kiến thức vững chắc và tư duy phân tích có được từ môn học, chúng em đã có thể áp dụng vào bài toán thực tế thông qua đề tài “Hệ thống phân tích và dự đoán giá bất động sản TP.HCM”. Thành quả ngày hôm nay không chỉ là một cột mốc học thuật ý nghĩa trong hành trình giảng đường, mà còn là hành trang, kinh nghiệm thực tiễn vô cùng quan trọng cho con đường sự nghiệp tương lai của mỗi thành viên trong nhóm.

Tuy nhiên, do giới hạn về mặt thời gian cũng như năng lực chuyên môn của các thành viên, đề tài chắc chắn khó tránh khỏi những thiếu sót nhất định. Nhóm chúng em rất kính mong nhận được những nhận xét, góp ý chân thành từ cô để chúng em có thể khắc phục, hoàn thiện tư duy hệ thống và nâng cao chất lượng cho các dự án tiếp theo.

Chúng em xin chân thành cảm ơn!

Nhóm sinh viên thực hiện

Trương Quốc Duy

Võ Lê Hoàng Đức

Trần Anh Khoa

Bùi Nguyễn Nguyên Khang

Phạm Thế Quân

BẢNG PHÂN CÔNG VÀ MỨC ĐỘ HOÀN THÀNH

STT	MSSV	Họ tên	Phân công	Mức độ hoàn thành
1	24133902	Bùi Nguyễn Nguyên Khang	1. Crawl và làm sạch dữ liệu 2. Trực quan hóa, tổng hợp và nhận xét toàn bộ dữ liệu 3. Mô Hình Hóa, xây dựng trợ lý ảo 4. Thiết kế giao diện Web và toàn bộ tính năng	100%
2	24134057	Phạm Thế Quân	1. Crawl và làm sạch dữ liệu 2. Trực quan hóa và nhận xét bộ dữ liệu 3. Xác suất và suy luận thống kê 4. Hỗ trợ Mô Hình Hóa	100%
3	24133031	Trần Anh Khoa	1. Crawl và làm sạch dữ liệu 2. Trực quan hóa và nhận xét bộ dữ liệu 3. Hỗ trợ thiết kế tính năng trực quan hóa trên web	100%
4	24133013	Võ Lê Hoàng Đức	1. Crawl và làm sạch dữ liệu 2. Trực quan hóa và nhận xét bộ dữ liệu	100%
5	24133009	Trương Quốc Duy	1. Làm sạch dữ liệu đã được crawl sẵn 2. Trực quan hóa và nhận xét bộ dữ liệu	100%

Ghi chú: Tất cả các thành viên nhóm đều tham gia viết báo cáo và chỉnh sửa slide thuyết trình

MỤC LỤC

CHƯƠNG 1. TÓM TẮT	1
1.1 Tổng quan quá trình thực hiện	1
1.2 Kết quả đạt được.....	2
CHƯƠNG 2. GIỚI THIỆU	2
2.1 Bối cảnh và lý do chọn đề tài.....	2
2.2 Vấn đề nghiên cứu.....	3
CHƯƠNG 3. DỮ LIỆU VÀ TIỀN XỬ LÝ	9
3.1. Thu thập dữ liệu	9
3.2. Cấu hình dữ liệu và tổ chức đường dẫn.....	11
3.3. Làm sạch dữ liệu	12
3.4. Xử lý tọa độ và làm sạch không gian địa lý	13
3.5. Chuẩn hóa tên quận/huyện và địa danh	13
3.6. Phân bố dữ liệu theo nguồn và theo loại giao dịch.....	14
3.7. Phân bố theo khu vực và loại bất động sản	16
3.8. Chất lượng tập dữ liệu chính	18
3.9. Trích xuất đặc trưng	19
3.10. Trích xuất tín hiệu ngữ nghĩa từ tiêu đề.....	19
3.11. Biến giá trên mét vuông và các biến log-transform	20
3.12. Đặc trưng không gian và thời gian	21
3.13. Target Encoding cho biến phân loại	21
3.14. Ý nghĩa tổng thể của quy trình ETL	22
CHƯƠNG 4. TRỰC QUAN HÓA DỮ LIỆU	22
4.1. Phân tích Khám phá tĩnh	22
4.2. Trực quan hóa không gian :	33
4.3. Phân tích giá	36
CHƯƠNG 5. TÍNH TOÁN XÁC SUẤT VÀ SUY LUẬN THỐNG KÊ.....	42
5.1. Thống kê mô tả và xử lý ngoại lệ	42
5.2. Tính toán xác suất	44
5.3. Tính toán suy luận thống kê.....	46
CHƯƠNG 6. MÔ HÌNH HÓA DỮ LIỆU	51

6.1. Thiết lập bài toán và chuẩn bị dữ liệu huấn luyện.....	51
6.2 Thuật toán học có giám sát (Supervised Learning): Dự đoán giá	59
6.3 Thuật toán học không giám sát (Unsupervised Learning): Phân cụm thị trường vĩ mô (K-Means Clustering).....	67
6.4 TRỢ LÝ ẢO XỬ LÝ NGÔN NGỮ TỰ NHIÊN (NLP LOCAL)	71
CHƯƠNG 7. THỰC NGHIỆM, KẾT QUẢ VÀ THẢO LUẬN	76
7.1 Thiết lập thực nghiệm	76
7.2 Các chỉ số đo lường hiệu năng	78
7.3 Kết quả dự đoán trên tập kiểm thử.....	81
7.4 Giải thích mô hình thông qua độ quan trọng của đặc trưng	83
7.5 Phân tích phần dư sai số và các hạn chế tồn tại	88
7.6 Kết quả phân cụm thị trường bằng thuật toán K-Means	92
7.7 Thảo luận tổng hợp	94
CHƯƠNG 8. KẾT LUẬN	96
8.1 Đóng góp của đề tài.....	96
8.2 Hướng phát triển.....	96
TÀI LIỆU THAM KHẢO	97

DANH SÁCH HÌNH ẢNH

Hình 2.1: Cấu trúc thư mục dự án	8
Hình 4.1: Phân phối logarit giá.....	23
Hình 4.2: Phân bố giá theo quận/huyện.....	24
Hình 4.3: Tương quan giữa Diện tích và Giá theo loại BDS.....	25
Hình 4.4: Top 10 quận/huyện có nhiều tin đăng nhất.....	26
Hình 4.5: Top 10 quận/huyện có giá/m ² cao nhất	27
Hình 4.6: lượng tin đăng theo thời gian.....	28
Hình 4.7: Phân bố địa lý	29
Hình 4.8: phân bố giá theo loại BDS	30
Hình 4.9: Mức độ quan trọng của các biến trong phân khúc bán	31
Hình 4.10: mức độ quan trọng của các biến trong phân khúc thuê	31
Hình 4.11: So sánh kết quả dự đoán và thực tế trong phân khúc bán.....	32
Hình 4.12: So sánh kết quả dự đoán và thực tế trong phân khúc thuê	33
Hình 4.13: Trực quan hóa không gian 1	34
Hình 4.14: Trực quan hóa không gian 2	35
Hình 4.15: Hồ sơ chi tiết của marker.....	36
Hình 4.16: Biểu đồ Diện tích vs Giá theo phân khúc bán	37
Hình 4.17: Biểu đồ Diện tích vs Giá theo phân khúc thuê	37
Hình 4.18: Các biểu đồ theo phân khúc bán.....	39
Hình 4.19: Các biểu đồ theo phân khúc thuê.....	40
Hình 4.20: Các biểu đồ theo phân khúc bán.....	41
Hình 4.21: Các biểu đồ theo phân khúc thuê.....	41
Hình 5.1: Phát hiện ngoại lệ giá BĐS bằng biểu đồ hộp	43
Hình 5.2: Bản đồ nhiệt xác suất có điều kiện	46
Hình 5.3: So sánh phân phối tích lũy giá/m ² giữa Quận 1 và Quận Bình Tân	47
Hình 5.4: Mô phỏng định lý giới hạn trung tâm.....	48
Hình 5.5: Bootstrap lấy mẫu.....	49
Hình 5.6: Kết quả kiểm định giả thuyết.....	51
Hình 6.1: Sơ đồ luồng huấn luyện tổng quát	53
Hình 6.2: Sơ đồ Target Encoding.....	56
Hình 6.3: Sơ đồ luồng hoạt động của mô hình Random Forest trong dự án.	63
Hình 6.4: Sơ đồ quy trình phân cụm thị trường bằng K-Means	70
Hình 6.5: Biểu đồ bong bóng kết quả phân cụm K-Means	70
Hình 6.6: Sơ đồ cấu trúc điều hướng ứng dụng và luồng xử lý của trợ lý ảo.....	73
Hình 7.1: Sơ đồ quy trình tổng hợp các mô hình kiến trúc ưu việt nhất được hệ thống lựa chọn tự động	83
Hình 7.2: Sơ đồ hệ thống biểu đồ phân tích phần dư hiển thị trực tiếp trên giao diện ứng dụng	89
Hình 7.3: Biểu đồ phân cụm cấu trúc thị trường vĩ mô bằng thuật toán K-Means.....	93

DANH SÁCH BẢNG

Bảng 1.1: Bảng tổng quan các thông số cấu trúc của tập dữ liệu chính	2
Bảng 1.2: Kết quả đánh giá hiệu năng của mô hình tốt nhất trên tập kiểm thử.....	2
Bảng 2.1: Vai trò và chức năng của các tệp mã nguồn chính trong cấu trúc dự án	7
Bảng 3.1: Bảng tổng hợp các nguồn thu thập dữ liệu.....	11
Bảng 3.2: Bảng tóm tắt các tiêu chí lọc và làm sạch dữ liệu	12
Bảng 3.3: Bảng thống kê số lượng và tỷ trọng tin đăng theo từng nguồn dữ liệu.....	15
Bảng 3.4: Bảng phân loại và thống kê số lượng tin đăng theo loại hình giao dịch của từng nguồn dữ liệu.	15
Bảng 3.5: Bảng tổng hợp toàn diện về biến động số lượng dữ liệu và tình trạng tọa độ địa lý của từng nguồn.....	16
Bảng 3.6: Phân bố dữ liệu theo quận/huyện	17
Bảng 3.7: Thống kê số lượng tin đăng theo loại hình bất động sản	17
Bảng 3.8: Thống kê tổng quan dữ liệu sau làm sạch	18
Bảng 3.9: Tổng hợp các nhóm đặc trưng.....	19
Bảng 5.1: Bảng xác suất thực nghiệm	45
Bảng 6.1: Chi tiết phân chia quy mô tập dữ liệu huấn luyện và kiểm thử theo từng phân khúc giao dịch.....	55
Bảng 6.2: Danh mục các biến mã hóa mục tiêu được thiết lập trong quá trình huấn luyện mô hình.	57
Bảng 6.3: Phân loại và tổng hợp chi tiết tập các đặc trưng đầu vào được sử dụng để huấn luyện mô hình máy học.....	59
Bảng 6.4: Danh mục tổng hợp cấu trúc lớp mô hình thuật toán học có giám sát tham gia thực nghiệm.	60
Bảng 6.5: Lưới tham số cấu hình tối ưu và danh sách các ứng viên siêu tham số thực nghiệm của mô hình XGBoost.	65
Bảng 6.6: Danh sách phân loại các nhóm ý định nghiệp vụ của hệ thống trợ lý ảo	74
Bảng 6.7: Bảng minh họa cơ chế hoạt động của bộ nhớ lưu trữ ngữ cảnh hội thoại...	75
Bảng 7.1: Cấu hình quy mô dữ liệu thực nghiệm trên hệ thống.....	77
Bảng 7.2: Danh mục các tệp kết quả đầu ra sau quá trình thực nghiệm hệ thống.....	77
Bảng 7.3: Danh sách các kiến trúc thuật toán máy học tham gia thực nghiệm	78
Bảng 7.4: Kết quả đối chiếu hiệu năng các mô hình trên phân khúc giao dịch Bán ...	82
Bảng 7.5: Kết quả đối chiếu hiệu năng các mô hình trên phân khúc giao dịch Cho thuê	82
Bảng 7.6: Bảng tổng hợp các mô hình kiến trúc ưu việt nhất được hệ thống lựa chọn tự động	83
Bảng 7.7: Ý nghĩa các chỉ số đo lường mức độ quan trọng đặc trưng trong Random Forest	84
Bảng 7.8: Xếp hạng mức độ quan trọng của đặc trưng định giá trên phân khúc Bán .	86
Bảng 7.9: Xếp hạng mức độ quan trọng của đặc trưng định giá trên phân khúc Cho thuê	88
Bảng 7.10: Phân tích các biến số ẩn ngoại sinh gây ra sai số cho hệ thống dự báo	90

Bảng 7.11: Chẩn đoán các dạng sai số phần dư phổ biến trên hệ thống ứng dụng.....	91
Bảng 7.12: Tổng hợp kết quả phân rã không gian ô thị trường vĩ mô bằng thuật toán K-Means	93
Bảng 7.13: Đề xuất các định hướng nâng cấp kiến trúc hệ thống dự đoán trong tương lai	95

CHƯƠNG 1. TÓM TẮT

1.1 Tổng quan quá trình thực hiện

Đồ án này tập trung xây dựng một hệ thống phân tích và dự đoán giá bất động sản tại khu vực Thành phố Hồ Chí Minh bằng ngôn ngữ lập trình R. Hệ thống bao gồm ba luồng xử lý chính là thu thập và làm sạch dữ liệu, phân tích trực quan kết hợp thống kê suy luận, và huấn luyện các thuật toán máy học. Nguồn dữ liệu được cào tự động và tổng hợp từ 6 trang web lớn bao gồm Mogi, Chợ Tốt, Alonhadat, Luachonnhadat, Homedy và Muaban. Sau khi chạy các tập lệnh làm sạch để loại bỏ tin rác, khử trùng lặp theo ID và chuẩn hóa định dạng, tập dữ liệu chính đạt quy mô 30.250 tin đăng với 56 cột thuộc tính. Trong đó, dữ liệu được chia làm 14.891 tin rao bán và 15.359 tin cho thuê. Quá trình tiền xử lý cũng thực hiện tính toán khoảng cách địa lý dựa trên công thức Haversine, dùng biểu thức chính quy để bóc tách thông tin mặt tiền, hẻm xe hơi từ tiêu đề, và áp dụng phép biến đổi logarit để giảm độ lệch của biến giá.

Chỉ tiêu kỹ thuật hệ thống	Thông số thực tế ghi nhận
Tổng số bản ghi (tin đăng) sau làm sạch	30.250
Tổng số cột thuộc tính (đặc trưng)	56
Quy mô phân khúc dữ liệu Bán	14.891 tin đăng
Quy mô phân khúc dữ liệu Cho thuê	15.359 tin đăng
Nguồn thu thập dữ liệu đầu vào	Mogi, Chợ Tốt, Alonhadat, Luachonnhadat, Homedy, Muaban
Giá bán trung vị hệ thống ghi nhận	6.30 tỷ VND
Diện tích bán trung vị	76 mét vuông
Giá thuê trung vị hệ thống ghi nhận	25 triệu VND/tháng

Diện tích thuê trung vị	98 mét vuông
-------------------------	--------------

Bảng 1.1: Bảng tổng quan các thông số cấu trúc của tập dữ liệu chính

1.2 Kết quả đạt được

Bài toán dự đoán giá được chia làm hai phần độc lập cho phân khúc bán và cho thuê. Hệ thống tiến hành huấn luyện và so sánh 5 thuật toán bao gồm hồi quy tuyến tính, Random Forest, XGBoost, mô hình lai tạo trung bình và mô hình lai tạo tối ưu trọng số. Dữ liệu được chia theo tỷ lệ 80 phần trăm để huấn luyện và 20 phần trăm để kiểm thử, kết hợp phương pháp lấy mẫu phân tầng theo nguồn dữ liệu nhằm đảm bảo tính đại diện. Kết quả thực nghiệm cho thấy mô hình lai tạo tối ưu giữa Random Forest và XGBoost đạt hiệu năng dự báo tốt nhất trên cả hai phân khúc. Tuy nhiên, sai số phần trăm vẫn còn khá cao do tính chất phức tạp của thị trường. Sản phẩm cuối cùng của đồ án là một ứng dụng bảng điều khiển Shiny tích hợp biểu đồ tương tác và một trợ lý ảo xử lý ngôn ngữ tự nhiên chạy hoàn toàn ở máy cục bộ, có khả năng tự động nhận diện ý định và ghi nhớ ngữ cảnh hội thoại.

Phân khúc	Best model	Train validate	Test validate	RMSE	MAE	MAPE	R2
Bán	Tuned RF/XGBoost Ensemble	11.911	2.978	24.16 tỷ VND	6.89 tỷ VND	37.84%	0.680
Cho thuê	Tuned RF/XGBoost Ensemble	12.285	3.074	84.81 triệu VND	26.94 triệu VND	41.21%	0.564

Bảng 1.2: Kết quả đánh giá hiệu năng của mô hình tốt nhất trên tập kiểm thử

CHƯƠNG 2. GIỚI THIỆU

2.1 Bối cảnh và lý do chọn đề tài

Thị trường bất động sản Thành phố Hồ Chí Minh mang đặc thù có quy mô giao dịch rất lớn, tốc độ biến động cao và thông tin bị phân tán trên nhiều nền tảng đăng tin khác nhau. Thực trạng này gây ra khó khăn lớn cho người mua, người thuê hoặc nhà

đầu tư khi muốn nắm bắt mặt bằng giá chung. Người dùng phải tự đối mặt và xử lý hàng loạt vấn đề kỹ thuật của dữ liệu như: tin đăng bị trùng lặp do môi giới sao chép, mức giá đăng ảo, thiếu tọa độ địa lý, định dạng tên quận/huyện không đồng nhất và cách phân loại bất động sản khác nhau giữa các nguồn. Nếu chỉ đọc các tin riêng lẻ, người xem rất dễ bị tác động bởi các tin có giá quá cao hoặc quá thấp, từ đó bỏ qua xu hướng chung của thị trường.

Trong bối cảnh môn học Lập trình R cho phân tích, việc xây dựng một hệ thống xử lý tự động bằng ngôn ngữ R là giải pháp tối ưu và thiết thực. Đề tài này cho phép sinh viên vận dụng toàn diện các nhóm kỹ thuật đã được học bao gồm: đọc, ghi và tiền xử lý dữ liệu; thu thập dữ liệu từ web và API; làm sạch và chuẩn hóa nhãn; trực quan hóa dữ liệu bằng ggplot2, plotly và leaflet; áp dụng thống kê mô tả và thống kê suy luận; mô hình hóa dữ liệu bằng các thuật toán máy học; và đóng gói thành một ứng dụng phân tích tương tác bằng thư viện Shiny.

2.2 Vấn đề nghiên cứu

Đề án tập trung giải quyết và tìm kiếm câu trả lời cho sáu vấn đề nghiên cứu cốt lõi xoay quanh vòng đời của dữ liệu bất động sản tại Thành phố Hồ Chí Minh. Vấn đề đầu tiên là việc tìm kiếm giải pháp kỹ thuật lập trình để có thể tự động cào dữ liệu, thu thập và hợp nhất luồng thông tin không lồ từ nhiều nền tảng trực tuyến phân tán về chung một lược đồ cấu trúc dữ liệu duy nhất. Sau khi hoàn thiện tập dữ liệu sạch, nghiên cứu tiếp tục phân tích thống kê để bóc tách xem những khu vực hành chính nào đang nắm giữ dung lượng tin đăng dồi dào nhất, sở hữu mặt bằng đơn giá trên mỗi mét vuông cao nhất, cũng như cơ cấu phân bố của các loại hình bất động sản diễn ra như thế nào trên thị trường. Vấn đề thứ ba đi sâu vào việc khám phá mối quan hệ tác động qua lại giữa giá trị tài sản với các biến số định lượng và phân loại, diễn hình như quy mô diện tích, loại hình nhà đất, vị trí khu vực, khoảng cách tuyến tính đến trung tâm thành phố và các đặc trưng thông tin ẩn được trích xuất từ văn bản tiêu đề.

Dựa trên việc khám phá các mối quan hệ này, đề án đặt ra bài toán thứ tư là đánh giá khả năng ứng dụng các mô hình hồi quy và thuật toán máy học trong ngôn ngữ R để ước tính mức giá bán và giá thuê, nhằm xác định xem các mô hình này có thể đạt

được một tỷ lệ sai số chấp nhận được trong thực tế hay không. Đối với những sự bất định và điểm nhiễu tồn tại trong tập dữ liệu thu thập từ web, vấn đề thứ năm tập trung đánh giá xem chúng có thể được giải thích một cách khoa học thông qua các kỹ thuật thống kê suy luận như phương pháp lấy mẫu lại bootstrap, kiểm định t-test, kiểm định Wilcoxon và định lý giới hạn trung tâm (CLT) hay không. Cuối cùng, nghiên cứu đặt ra bài toán thực tiễn về việc thiết kế và lập trình một bảng điều khiển trực quan, nhằm đảm bảo người dùng phổ thông dù không có kiến thức đọc hiểu mã nguồn vẫn có thể thao tác dễ dàng với bản đồ không gian, biểu đồ phân tích, công cụ dự báo giá và hệ thống trợ lý ảo chuyên ngành.

2.3 Mục tiêu đề án

Đề án đặt ra sáu mục tiêu kỹ thuật chính cần giải quyết để hoàn thiện toàn bộ vòng đời của một hệ thống phân tích dữ liệu. Mục tiêu đầu tiên là xây dựng một đường ống dữ liệu có khả năng tự động thu thập và nạp thông tin từ sáu nền tảng trực tuyến bao gồm Chợ Tốt, Alonhadat, Luachonnhadat, Muaban, Mogi và Homedy. Dữ liệu thô thu về được hệ thống lưu trữ tập trung tại thư mục data/raw, sau đó tiến hành gộp lại thành tệp dữ liệu trung gian tại data/interim/du_lieu_gop_nguon.csv và xuất ra tệp dữ liệu chính thức data/main/du_lieu_chinh.csv để phục vụ cho toàn bộ các bước phân tích về sau.

Mục tiêu thứ hai tập trung vào việc chuẩn hóa và làm sạch tập dữ liệu đa nguồn này. Quá trình này đòi hỏi mã nguồn phải xử lý đưa toàn bộ dữ liệu về chung một lược đồ, ép kiểu dữ liệu cho từng cột, đồng thời cấu hình các bộ lọc để loại bỏ các dòng có mức giá hoặc diện tích bất hợp lý. Cùng với đó, hệ thống sẽ thực thi chuẩn hóa tên gọi khu vực quận huyện, tính toán đơn giá trên mỗi mét vuông và khử các tin đăng trùng lặp bằng cách dựa vào mã định danh ID cũng như đường dẫn URL của bài đăng.

Sau khi có được tập dữ liệu sạch, mục tiêu thứ ba là kỹ thuật hóa đặc trưng nhằm tạo ra các biến phân tích mới. Hệ thống sẽ quét văn bản tiêu đề và địa chỉ để trích xuất tín hiệu, tính toán khoảng cách không gian Haversine đến khu vực trung tâm, áp dụng phép biến đổi logarit cho các biến số, tạo ra các biến thời gian đăng tin, phân khúc giá và thiết lập cơ chế mã hóa mục tiêu ngay trong quá trình huấn luyện mô hình. Tiếp nối

công đoạn này, mục tiêu thứ tư là giải quyết bài toán trực quan hóa và thống kê bằng cách sinh ra các biểu đồ tĩnh lưu vào thư mục plots/ cũng như kết xuất các biểu đồ tương tác trực tiếp.

Hai mục tiêu cuối cùng hướng đến việc dự báo và đóng gói sản phẩm. Đối với mục tiêu thứ năm, đề án tiến hành huấn luyện và đánh giá năng lực dự báo giá của các cấu trúc thuật toán bao gồm hồi quy tuyến tính, Random Forest, XGBoost và mô hình lai tạo Ensemble. Hiệu năng của các thuật toán này sẽ được so sánh chéo dựa trên bốn chỉ số đo lường sai số là RMSE, MAE, MAPE và R bình phương. Cuối cùng, mục tiêu thứ sáu là triển khai mã nguồn thành một ứng dụng phân tích web bằng thư viện Shiny. Ứng dụng này tích hợp các bộ lọc dữ liệu, hệ thống bản đồ Leaflet, công cụ dự đoán giá, bảng chẩn đoán mô hình, chức năng phân cụm, bảng hiển thị dữ liệu chi tiết và đặc biệt là một trợ lý ảo hỏi đáp chuyên ngành hoạt động hoàn toàn ở môi trường cục bộ.

2.4 Phạm vi nghiên cứu

Về mặt không gian, dữ liệu được giới hạn tại thị trường Thành phố Hồ Chí Minh theo hệ thống nhãn hành chính cũ trên các trang đăng tin. Thông qua tập lệnh scripts/lib/chuan_hoa_quan_huyen.R, mã nguồn tự động quy chuẩn các nhãn phân mảnh như “Quận 2”, “Quận 9”, “Thủ Đức” về một nhãn thống nhất là “Thành phố Thủ Đức”. Sau bước làm sạch, tập dữ liệu không còn tồn tại nhãn “Không rõ”, tuy nhiên hệ thống vẫn cố tình giữ lại 2 dòng “TP Vũng Tàu cũ”, 1 dòng “TP Bến Cát cũ” và 1 dòng “Bình Dương cũ” để làm cơ chế cảnh báo về việc nguồn đăng tin có thể cung cấp dữ liệu vượt ra ngoài phạm vi thành phố.

Về mặt nghiệp vụ, hệ thống phân tách rạch ròi quá trình xử lý cho hai phân khúc giao dịch là Bán và Cho thuê. Việc tách riêng này là bắt buộc do đơn vị tính toán và động lực định giá của thị trường mua bán hoàn toàn khác so với thị trường cho thuê. Giới hạn quan trọng nhất của đề án là toàn bộ mức giá được phân tích đều là giá chào bán hoặc giá rao thuê lấy từ các bài đăng, không phải là giá trị giao dịch thực tế đã qua công chứng. Do đó, toàn bộ kết quả của mô hình mang ý nghĩa phản ánh mặt bằng giá rao trên các nền tảng trực tuyến.

2.5 Cấu trúc dự án và vai trò các tệp chính

Hệ thống mã nguồn của đề án được cấu trúc theo dạng các mô-đun độc lập nhằm dễ dàng bảo trì và tái sử dụng. Dưới đây là bảng tổng hợp vai trò của các tệp tin và thư mục cốt lõi trong hệ thống:

Tên tệp tin / Thư mục	Vai trò trong hệ thống
app.R	Điểm vào (entry point) của ứng dụng Shiny, chịu trách nhiệm nạp các thư viện, cấu hình cổng/máy chủ và gọi các mô-đun giao diện, máy chủ.
scripts/config/duong_dan_du_an.R	Tập cấu hình tập trung khai báo toàn bộ đường dẫn vật lý đến thư mục dữ liệu, mô hình, biểu đồ và các tập lệnh chạy luồng dữ liệu.
scripts/lib/chuan_hoa_quan_huyen.R	Tập lệnh chuẩn hóa tên quận/huyện, loại bỏ dấu tiếng Việt và ánh xạ các tên phường mới về hệ thống nhãn cũ.
scripts/processing/gop_nguon_du_lieu.R	Tập lệnh đọc các tệp CSV thô, chuẩn hóa về lược đồ 27 cột chung, lọc ngoại lệ, khử trùng lặp và lưu thành dữ liệu trung gian.
scripts/processing/tao_dac_trung.R	Tập lệnh tạo đặc trưng phân tích từ dữ liệu đã gộp, tính toán logarit, khoảng cách Haversine, cờ đánh dấu văn bản và thời gian.
scripts/analysis/phan_tich_eda.R	Mã nguồn sinh tự động 8 biểu đồ định dạng PNG và xuất tệp CSV tóm tắt thống kê thăm dò.
scripts/models/huan_luyen_mo_hinh.R	Tập lệnh huấn luyện thuật toán Linear, Random Forest, XGBoost, Ensemble, phân cụm K-Means và lưu trữ mô hình cùng các chỉ số đo lường.

ung_dung/giao_dien_ung_dung.R	Khai báo bố cục ứng dụng Shiny, bao gồm thanh bên, thanh điều hướng, các thẻ hiển thị và vị trí các đầu vào/đầu ra.
ung_dung/may_chu_ung_dung.R	Tập máy chủ phản ứng (server reactive) xử lý logic xuất biểu đồ, bản đồ, bảng biểu và quản lý các sự kiện click, tải báo cáo.
ung_dung/ham_ho_tro_ung_dung.R	Tập hợp các hàm xử lý định dạng, tính toán dự báo, thống kê suy luận, bộ máy NLP trợ lý ảo và xuất báo cáo.
www/giao_dien.css	Tập định dạng CSS thiết kế giao diện cho thẻ thông số, thanh lọc dữ liệu, khung chat trợ lý ảo và bố cục đáp ứng (responsive).
www/tuong_tac.js	Tập JavaScript điều khiển thanh điều hướng, tự động cuộn khung chat và tích hợp API nhận diện, phát âm thanh tiếng Việt.

Bảng 2.1: Vai trò và chức năng của các tệp mã nguồn chính trong cấu trúc dự án


```

phantichnhadathcm/
|-- app.R
|-- README.md
|-- data/
|   |-- raw/           # Du lieu rieng tung nguon
|   |-- interim/       # Du lieu gop nguon
|   |-- main/          # Du lieu chinh cho app/model
|   |-- logs/          # Nhat ky cap nhat
|-- scripts/
|   |-- config/        # Cau hinh path dung chung
|   |-- lib/           # Chuan hoa quan/huyen
|   |-- scrapers/      # Thu thap tu web/API
|   |-- importers/     # Nhap CSV local ve schema chung
|   |-- processing/    # Gop nguon, tao dac trung
|   |-- analysis/      # EDA/plots
|   |-- models/        # Huan luyen model
|   |-- pipeline/      # Chay pipeline/cap nhat tu dong
|   |-- checks/        # Kiem tra nhanh app/model/tro ly
|-- ung_dung/
|   |-- ham_ho_tro_ung_dung.R
|   |-- giao_dien_ung_dung.R
|   |-- may_chu_ung_dung.R
|-- models/
|-- plots/
|-- docs/
|   |-- co_so_ly_thuyet.md
|   |-- references/
|   |-- diagrams/
|-- www/
|   |-- giao_dien.css
|   |-- tuong_tac.js
|   |-- hcmute-logo.png

```

Hình 2.1: Cấu trúc thư mục dự án

CHƯƠNG 3. DỮ LIỆU VÀ TIỀN XỬ LÝ

Đề tài sử dụng cách tiếp cận ETL tương đối hoàn chỉnh để xây dựng tập dữ liệu bất động sản TP.HCM phục vụ phân tích, trực quan hóa và dự đoán giá trên nền tảng R/Shiny. Toàn bộ quy trình dữ liệu được tổ chức theo kiến trúc nhiều lớp gồm dữ liệu thô data/raw, dữ liệu hợp nhất trung gian data/interim/du_lieu_gop_nguon.csv và dữ liệu chính sau tạo đặc trưng data/main/du_lieu_chinh.csv, nhờ đó vừa bảo đảm khả năng truy vết nguồn gốc dữ liệu, vừa thuận tiện cho tái huấn luyện mô hình và cập nhật hệ thống về sau. Theo artifact hiện tại của dự án, hệ thống đã hợp nhất thành công dữ liệu từ 6 nhóm nguồn chính gồm Mogi, Chợ Tốt, Alonhadat, Luachonnhadat, Homedy và Muaban, tạo ra tập dữ liệu chuẩn hóa ban đầu có 30.254 dòng raw, sau bước lọc nghiệp vụ và khử trùng lặp còn 30.250 dòng trong tập dữ liệu interim và tiếp tục được làm giàu thành 30.250 quan sát với 56 cột trong file du_lieu_chinh.csv. Đây là quy mô dữ liệu đủ lớn để thực hiện đồng thời thống kê mô tả, kiểm định suy luận, phân cụm khu vực và huấn luyện các mô hình học máy cho hai phân khúc bán và cho thuê.

3.1. Thu thập dữ liệu

Hệ thống được thiết kế theo hướng thu thập đa nguồn, trong đó mỗi website được xử lý bằng chiến lược phù hợp với đặc điểm kỹ thuật riêng nhằm tối ưu độ ổn định và tính đầy đủ của dữ liệu. Đối với Chợ Tốt, dữ liệu được lấy từ API JSON thông qua gateway.chotot.com, kết hợp cơ chế cache bằng SQLite để giảm số lần gọi lại, tăng tốc độ cập nhật và hạn chế lỗi mạng; nguồn này hiện đóng góp 8.112 dòng raw, sau làm sạch còn 8.108 dòng trong tập chính. Đối với Alonhadat, hệ thống sử dụng song song hai nguồn: dữ liệu crawl HTML bằng các thư viện http, rvest, xml2 thu được 62 dòng, kết hợp với dữ liệu import từ file CSV local alonhadat_local_nguon.csv cho thêm 1.279 dòng, tổng cộng sau chuẩn hóa và gộp thành 1.341 dòng. Nguồn Luachonnhadat sử dụng cơ chế gọi API loadmore, có tùy chọn lấy thêm thông tin chi tiết từng tin đăng, đóng góp 799 dòng. Nguồn Muaban được thu thập chủ yếu bằng crawl HTML; trong trường hợp cần render nội dung động, hệ thống có thể dùng thêm chromote để chạy Chrome headless, thu được 363 dòng. Đối với Mogi, đây là nguồn lớn nhất và quan trọng nhất của toàn bộ dự án, được tổng hợp từ dữ liệu import CSV gốc, CSV đã làm sạch, CSV bổ sung và một phần crawl tăng cường ưu tiên tin cho thuê, tạo ra 19.073 dòng, chiếm khoảng 63,1% toàn bộ dữ liệu. Cuối cùng, Homedy được nhập từ CSV

sạch/gốc và đóng góp 566 dòng. Cách thiết kế này cho thấy dự án không phụ thuộc vào một phương pháp thu thập duy nhất mà triển khai linh hoạt giữa API - HTML scraping - CSV import, nhờ đó thích ứng được với nhiều dạng cấu trúc website khác nhau và giảm rủi ro khi một nguồn bị thay đổi cấu trúc hoặc giới hạn truy cập. Sau khi thu thập, dữ liệu từ các nguồn được chuẩn hóa về cùng một cấu trúc thống nhất thông qua script `scripts/processing/gop_nguồn_du_lieu.R`. Script này định nghĩa một schema chuẩn gồm 27 cột đại diện cho các nhóm thông tin cốt lõi của tin đăng. Cụ thể, nhóm định danh nguồn gồm `source`, `source_group`, `source_id`, `ad_id`; nhóm mô tả tin đăng gồm `title`, `price_str`, `address`, `ward`, `district_id`, `district_name`, `category_id`, `category_name`; nhóm giá và diện tích gồm `price`, `area`, `rooms`, `price_m`, `price_per_m2`; nhóm tọa độ - hình ảnh - liên kết gồm `lat`, `lon`, `image`, `ad_url`, `source_url`, `has_coord`; và nhóm thời gian - kiểm soát gồm `posted_at`, `scraped_at`, `page_fetched`, `is_rent`. Quy tắc chuẩn hóa được áp dụng nhất quán: nguồn nào thiếu cột thì được bổ sung cột đó với giá trị NA, các cột chuỗi được ép kiểu `character`, các cột số ép kiểu `numeric`, cột logic hoặc cờ trạng thái ép kiểu phù hợp; nếu thiếu `source_id` thì hệ thống tự sinh từ tổ hợp `source` và `ad_id`, còn nếu thiếu `source_url` thì dùng lại `ad_url`. Nhờ đó, dữ liệu từ các nguồn rất khác nhau vẫn có thể được ghép nối, phân tích và đưa vào mô hình trong cùng một pipeline thống nhất. Dữ liệu được thu thập/import từ các nguồn sau :

Nguồn	File đầu ra chuẩn	Cách lấy dữ liệu	Số dòng raw hiện tại
Cho Tot	<code>data/raw/chotot/chotot_schema_chuan.csv</code>	Goi API JSON <code>gateway.chotot.com</code> , co cache SQLite	8,112
Alonhadat crawler	<code>data/raw/alonhadat/alonhadat_schema_chuan.csv</code>	Crawl HTML bang <code>http</code> , <code>rvest</code> , <code>xml2</code>	62
Alonhadat local	<code>data/raw/alonhadat/alonhadat_local_schema_chuan.csv</code>	Import CSV local <code>alonhadat_local_nguon.csv</code>	1,279
Luachonnhadat	<code>data/raw/luachonnhadat/luachonnhadat_schema_chuan.csv</code>	Goi API loadmore, co tuy chon fetch detail	799
Muaban	<code>data/raw/muaban/muaban_schema_chuan.csv</code>	Crawl HTML, co fallback Chrome headless neu co <code>chromote</code>	363
Mogi	<code>data/raw/mogi/mogi_schema_chuan.csv</code>	Import CSV sach/goc, CSV bo sung va CSV crawl Mogi	19,073
Homedy	<code>data/raw/homedy/homedy_schema_chuan.csv</code>	Import CSV sach/goc	566
Gop nguon	<code>data/interim/du_lieu_gop_nguon.csv</code>	Ket qua hop nhat raw	30,250

Bảng 3.1: Bảng tổng hợp các nguồn thu thập dữ liệu

3.2. Cấu hình dữ liệu và tổ chức đường dẫn

Một điểm mạnh quan trọng của phần dữ liệu là mọi đường dẫn đều được gom về file cấu hình `scripts/config/duong_dan_du_an.R`, thay vì hard-code rải rác trong nhiều script khác nhau. Thiết kế này giúp ứng dụng, pipeline ETL, module huấn luyện mô hình và các script kiểm tra dùng chung một hệ thống tham chiếu tệp, giảm lỗi khi đổi tên file hoặc di chuyển thư mục. Một số đường dẫn trọng yếu trong dự án gồm:

- `PATHS$combined_raw_csv = "data/interim/du_lieu_gop_nguon.csv"`
- `PATHS$featured_csv = "data/main/du_lieu_chinh.csv"`
- `PATHS$metrics_csv = "models/chi_so_mo_hinh.csv"`
- `PATHS$registry_csv = "models/dang_ky_mo_hinh.csv"`
- `PATHS$sale_model_rds = "models/mo_hinh_gia_ban.rds"`
- `PATHS$rent_model_rds = "models/mo_hinh_gia_thue.rds"`

Cách tổ chức này không chỉ hỗ trợ quá trình phát triển phần mềm mà còn có giá trị rõ rệt trong báo cáo học thuật, vì nó thể hiện tư duy xây dựng hệ thống có khả năng mở rộng, bảo trì và tái sử dụng.

3.3. Làm sạch dữ liệu

Sau khi gộp nguồn, dữ liệu được xử lý làm sạch bằng một tập quy tắc nghiệp vụ khá chặt chẽ nhằm loại bỏ các quan sát bất hợp lý, tin đăng lỗi và giảm nhiễu cho cả EDA lẫn mô hình học máy. Trước hết, dự án xác định khoảng giá hợp lý theo từng loại giao dịch. Đối với tin bán, chỉ giữ lại các quan sát có giá từ 300.000.000 VND đến 500.000.000.000 VND; đối với tin cho thuê, chỉ giữ các quan sát trong khoảng 300.000 VND đến 2.000.000.000 VND/tháng. Đồng thời, diện tích hợp lệ được giới hạn từ 5 m² đến 5.000 m², các dòng có price bị thiếu hoặc nhỏ hơn hay bằng 0 đều bị loại bỏ. Việc xác lập các ngưỡng này là cần thiết vì dữ liệu tin đăng trực tuyến thường chứa nhiều giá trị nhập sai, ví dụ giá thiếu số 0, diện tích cực nhỏ hoặc cực lớn bất thường, hoặc tin “mồi” dùng giá ảo để thu hút người xem. Nếu không lọc từ đầu, các ngoại lệ này sẽ kéo lệch thống kê mô tả, làm méo trực quan hóa và gây sai số lớn cho mô hình dự đoán. Một bước rất quan trọng khác là khử trùng lặp. Hệ thống thực hiện theo hai cấp độ. Ở cấp 1, dữ liệu được loại trùng bằng source_id, vì đây là khóa định danh nội bộ gần nhất với từng tin đăng trong mỗi nguồn. Ở cấp 2, hệ thống chuẩn hóa URL tin đăng thành ad_url_key bằng cách loại khoảng trắng, bỏ dấu / cuối và chuyển về chữ thường, sau đó tiếp tục dùng distinct(ad_url_key, .keep_all = TRUE) để loại các dòng khác nhau về định danh nhưng thực chất trở đến cùng một tin. Nhờ quy trình hai tầng này, từ 30.254 dòng raw hệ thống chỉ loại bỏ 4 dòng không hợp lệ hoặc trùng lặp, giữ lại 30.250 dòng trong tập interim và main. Đây là dấu hiệu cho thấy dữ liệu sau chuẩn hóa có độ sạch tương đối cao, đồng thời quy trình deduplication được triển khai cẩn thận nhưng không quá “mạnh tay” đến mức làm mất dữ liệu hợp lệ.

Điều kiện	Giá trị giữ lại
Gia bán	Từ 300,000,000 đến 500,000,000,000 VND
Gia thuê	Từ 300,000 đến 2,000,000,000 VND/tháng
Diện tích	Từ 5 đến 5,000 m ²
Giá trị price	Không được NA, phải lớn hơn 0
Trung lặp cấp 1	<code>distinct(source_id, .keep_all = TRUE)</code>
Trung lặp cấp 2	Chuẩn hóa ad_url thành ad_url_key, sau đó <code>distinct(ad_url_key, .keep_all = TRUE)</code>

Bảng 3.2: Bảng tóm tắt các tiêu chí lọc và làm sạch dữ liệu

3.4. Xử lý tọa độ và làm sạch không gian địa lý

Dữ liệu bất động sản có thành phần không gian rất quan trọng, nhưng trên thực tế nhiều nguồn đăng tin không cung cấp tọa độ đầy đủ hoặc tọa độ bị sai lệch. Vì vậy hệ thống áp dụng bộ lọc không gian theo bounding box mở rộng của TP.HCM, cụ thể giữ lại tọa độ khi thỏa điều kiện $10.30 \leq \text{latitude} \leq 11.20$ và $106.00 \leq \text{longitude} \leq 107.30$. Các dòng có lat hoặc lon nằm ngoài khoảng trên sẽ bị gán NA để tránh hiển thị sai trên bản đồ và tránh làm nhiễu biến `distance_to_center`. Theo dữ liệu hiện tại, chỉ có 14.801 dòng có tọa độ gốc hợp lệ, tương đương 48,9% toàn bộ dữ liệu; còn lại 15.449 dòng không có tọa độ gốc hợp lệ. Tuy nhiên, dự án không loại bỏ toàn bộ các dòng này mà xử lý minh bạch hơn: khi hiển thị trên dashboard, ứng dụng sẽ ước lượng tọa độ theo tâm quận/huyện rồi thêm một lượng jitter nhỏ để các marker không chồng khít lên nhau. Điều này có hai ý nghĩa. Thứ nhất, nó giúp giữ lại tối đa dữ liệu cho mục tiêu phân tích giá và học máy. Thứ hai, nó bảo đảm người dùng vẫn quan sát được phân bố không gian sơ bộ của các tin đăng ngay cả khi dữ liệu gốc thiếu vị trí chính xác. Trong bảng đối chiếu chi tiết theo nguồn, có thể thấy sự khác biệt rất lớn về độ đầy đủ tọa độ: Chợ Tốt có 8.044/8.108 dòng mang tọa độ gốc, tương đương 99,2%; Homedy đạt 98,4%; trong khi Alonhadat, Luachonhadat, Muaban gần như không có tọa độ gốc hợp lệ; riêng Mogi có 6.200/19.073 dòng, tương đương 32,5%. Điều này lý giải vì sao biến không gian trong mô hình tuy hữu ích nhưng chưa thể khai thác hết tiềm năng, đồng thời cũng cho thấy dashboard đã được thiết kế theo hướng không “che giấu” hạn chế dữ liệu mà hiển thị rõ tình trạng tọa độ gốc hay tọa độ ước lượng.

3.5. Chuẩn hóa tên quận/huyện và địa danh

Một thách thức phổ biến của dữ liệu bất động sản nhiều nguồn là tên địa giới hành chính không đồng nhất: có nơi viết “Quận 7”, nơi viết “q7”, “quan 7”, “Q.7”, thậm chí dùng tên cũ hoặc tên phường mới sau sáp nhập. Để giải quyết vấn đề này, dự án xây dựng riêng script `scripts/lib/chuan_hoa_quan_huyen.R` với một nhóm hàm chuyên trách như `district_strip_vietnamese()` để bỏ dấu tiếng Việt và đưa về chữ thường, `district_missing_label()` để phát hiện nhãn rỗng hoặc không rõ, `district_clean_label()` để thay thế các giá trị thiếu bằng nhãn chuẩn, `canonical_hcmc_district_one()` để suy luận quận/huyện từ nhãn hiện có, địa chỉ, tiêu đề hoặc URL, và `canonical_hcmc_district()` để vector hóa toàn bộ quy trình trên toàn cột dữ liệu. Một quy tắc nổi bật là hợp nhất

Quận 2, Quận 9, Thủ Đức và TP Thủ Đức thành một nhãn duy nhất là Thành phố Thủ Đức, giúp phản ánh đúng thực tế hành chính hiện nay và tránh chia tách giả tạo khi thống kê. Tương tự, các biến thể như q7, quan 7, Quận 7 đều được chuẩn hóa về Quận 7; các tên viết thường không dấu như binh thanh, go vap, tan phu đều được chuyển sang dạng có dấu đầy đủ. Sau bước chuẩn hóa này, tập dữ liệu chính không còn dòng nào mang nhãn “Không rõ”, điều này rất quan trọng đối với cả trực quan hóa theo khu vực và huấn luyện mô hình. Tuy vậy, dữ liệu vẫn còn giữ lại một số quan sát có nhãn ngoài địa bàn TP.HCM như 2 dòng “TP Vũng Tàu cũ”, 1 dòng “TP Bến Cát cũ” và 1 dòng “Bình Dương cũ” như những cảnh báo minh bạch về khả năng một vài tin đăng vượt ra ngoài phạm vi địa lý nghiên cứu.

3.6. Phân bố dữ liệu theo nguồn và theo loại giao dịch

Sau khi làm sạch, tập dữ liệu chính gồm 30.250 tin đăng, trong đó có 14.891 tin bán và 15.359 tin cho thuê, cho thấy hai phân khúc tương đối cân bằng về quy mô. Xét theo nguồn, Mogi là nguồn lớn nhất với 19.073 tin, chiếm 63,1%; tiếp theo là Chợ Tốt với 8.108 tin, chiếm 26,8%; Alonhadat có 1.341 tin; Luachonnhadat có 799 tin; Homedy có 566 tin; và Muaban có 363 tin. Phân bố này cho thấy dữ liệu bị lệch mạnh về phía Mogi và Chợ Tốt, do đó nếu không kiểm soát, các kết quả thống kê và mô hình có thể vô tình phản ánh “hành vi đăng tin” của một vài nền tảng lớn thay vì toàn thị trường. Chính vì lý do đó, trong pha modeling, dự án lựa chọn chia train/test theo stratified random by source để bảo đảm mỗi nguồn đều xuất hiện tương đối cân đối ở cả tập huấn luyện và tập kiểm tra. Xét theo loại giao dịch, dữ liệu nguồn cũng thể hiện thiên lệch khác nhau: Chợ Tốt và Alonhadat nghiêng mạnh về tin bán; Mogi lại nghiêng rất mạnh về tin cho thuê với 14.482 dòng thuê trên tổng số 19.073 dòng; Luachonnhadat và Muaban thì khá cân bằng giữa bán và thuê. Việc nêu rõ đặc điểm này trong báo cáo là rất cần thiết vì nó giải thích bản chất của nguồn dữ liệu và ảnh hưởng trực tiếp đến chất lượng mô hình ở từng phân khúc.

Nguồn	Số tin	Tỷ trọng xấp xỉ
Mogi	19,073	63.1%
Cho Tot	8,108	26.8%
Alonhadat	1,341	4.4%
Luachonnhadat	799	2.6%
Homedy	566	1.9%
Muaban	363	1.2%

Bảng 3.3: Bảng thống kê số lượng và tỷ trọng tin đăng theo từng nguồn dữ liệu.

Nguồn	Bán	Cho thuê	Tổng
Alonhadat	1,313	28	1,341
Cho Tot	8,018	90	8,108
Homedy	390	176	566
Luachonnhadat	400	399	799
Mogi	4,591	14,482	19,073
Muaban	179	184	363
Tổng	14,891	15,359	30,250

Bảng 3.4: Bảng phân loại và thống kê số lượng tin đăng theo loại hình giao dịch của từng nguồn dữ liệu.

Website/nguồn	Raw chuan	Vao du_lieu_chinh.csv	Ban	Cho thue	Toa do goc	Toa do uoc luong	Ty le toa do goc
Cho Tot	8,112	8,108	8,018	90	8,044	64	99.2%
Alonhadat	1,341	1,341	1,313	28	0	1,341	0.0%
Luachonnhadat	799	799	400	399	0	799	0.0%
Muaban	363	363	179	184	0	363	0.0%
Mogi	19,073	19,073	4,591	14,482	6,200	12,873	32.5%
Homedy	566	566	390	176	557	9	98.4%
Tong	30,254	30,250	14,891	15,359	14,801	15,449	48.9%

Bảng 3.5: Bảng tổng hợp toàn diện về biến động số lượng dữ liệu và tình trạng tọa độ địa lý của từng nguồn.

3.7. Phân bố theo khu vực và loại bất động sản

Dữ liệu sau chuẩn hóa cho phép quan sát mặt bằng phân bố theo quận/huyện tương đối rõ. Các khu vực có nhiều tin đăng nhất hiện nay là Thành phố Thủ Đức với 2.780 tin, Quận 7 với 2.150 tin, Quận Bình Tân với 1.798 tin, Quận Bình Thạnh với 1.424 tin, Quận Tân Bình với 1.383 tin, tiếp theo là Quận 12, Quận Tân Phú, Quận 1, Quận Gò Vấp, Quận 10, Quận 3 và Quận Phú Nhuận. Nhìn từ góc độ dữ liệu, điều này phản ánh những khu vực có độ phủ tin đăng cao hơn, đồng nghĩa với khả năng phân tích thống kê ổn định hơn. Ngược lại, các huyện ven như Cần Giờ hay một số khu ít tin sẽ có mẫu nhỏ, nên khi đưa vào nhận xét cần thận trọng vì trung vị hoặc các chỉ số so sánh có thể dao động mạnh. Về loại bất động sản, các nhãn phổ biến nhất gồm Nhà phố (4.456 tin), Nhà ở (4.158 tin), Căn hộ (2.799 tin), Căn hộ/Chung cư (2.657 tin), Đất (2.577 tin), Bất động sản khác (2.392 tin), Phòng/Cho thuê (650 tin), Đất nền (624 tin), cùng với một số nhóm nhỏ như Biệt thự, Văn phòng, Mặt bằng kinh doanh và Căn hộ chung cư. Điểm cần nhấn mạnh trong báo cáo là taxonomy loại bất động sản hiện tại mới là chuẩn hóa cơ bản, chưa gom hoàn toàn các nhãn gần nghĩa như Căn hộ, Căn hộ/Chung cư, Căn hộ chung cư. Việc giữ lại độ chi tiết này giúp bảo toàn thông tin gốc từ nguồn dữ liệu, nhưng đồng thời cũng làm tăng độ phân mảnh của biến phân loại và có thể ảnh hưởng đến mô hình nếu không được encode phù hợp.

Khu vực	Số tín
Thành phố Thủ Đức	2,780
Quận 7	2,150
Quận Bình Tân	1,798
Quận Bình Thạnh	1,424
Quận Tân Bình	1,383
Quận 12	1,109
Quận Tân Phú	1,071
Quận 1	1,070
Quận Gò Vấp	1,057
Quận 10	904
Quận 3	877
Quận Phú Nhuận	783

Bảng 3.6: Phân bố dữ liệu theo quận/huyện

Loại BDS	Số tín
Nhà phố	4,456
Nhà ở	4,158
Căn hộ	2,799
Căn hộ/Chung cư	2,657
Đất	2,577
Bất động sản khác	2,392
Phòng/Cho thuê	650
Đất nền	624
Biệt thự	131
Văn phòng, Mặt bằng kinh doanh	90
Căn hộ chung cư	69

Bảng 3.7: Thống kê số lượng tín đăng theo loại hình bất động sản

3.8. Chất lượng tập dữ liệu chính

Tập data/main/du_lieu_chinh.csv hiện có 30.250 dòng và 56 cột, không còn thiếu nhãn khu vực và không còn thiếu loại bất động sản sau các bước chuẩn hóa. Khoảng thời gian đăng tin trong dữ liệu trải từ 2023-06-01 đến 2026-06-18, và không có dòng nào mang ngày đăng ở tương lai sau bước chuẩn hóa. Với giá trị trung vị, phân khúc bán có giá trung vị khoảng 6,30 tỷ VND, diện tích trung vị 76 m² và đơn giá trung vị 91,21 triệu VND/m²; phân khúc cho thuê có giá trung vị khoảng 25 triệu VND/tháng, diện tích trung vị 98 m² và đơn giá thuê trung vị 235 nghìn VND/m²/tháng. Những con số này có vai trò rất quan trọng trong báo cáo vì chúng cho người đọc hình dung được “mặt bằng trung tâm” của dữ liệu, thay vì chỉ nhìn vào các cực trị dễ bị kéo lệch bởi outlier. Ngoài ra, dashboard còn hiển thị rõ các chỉ báo chất lượng như tỷ lệ tọa độ gốc, số dòng đáng ngờ, số dòng ngày tương lai hay dữ liệu bị ước lượng, cho thấy nhóm tác giả tiếp cận dữ liệu theo hướng minh bạch chứ không chỉ tập trung vào mặt “đẹp” của kết quả.

Chi so	Gia tri
Tong dong main	30,250
So cot main	56
Dong thieu/khong ro khu vuc	0
Dong thieu loai BDS	0
Dong co toa do hop le	14,801
Dong thieu toa do hop le	15,449
Ty le toa do goc hop le	48.9%
Ngay dang nho nhat	2023-06-01
Ngay dang lon nhat	2026-06-18
Ngay dang trong tương lai	0 dong

Bảng 3.8: Thống kê tổng quan dữ liệu sau làm sạch

3.9. Trích xuất đặc trưng

Sau bước gộp và làm sạch cơ bản, script `scripts/processing/tao_dac_trung.R` tiếp tục mở rộng dữ liệu từ 27 cột gốc lên 56 cột, tạo nền tảng cho cả phân tích thống kê và mô hình dự đoán. Nhóm đặc trưng đầu tiên là các biến kích thước suy ra từ văn bản, gồm `frontage_width_m`, `frontage_length_m`, `frontage_ratio`. Hệ thống dùng biểu thức chính quy để nhận diện các mẫu như 4x15, 5 x 20, 4.5x18 xuất hiện trong tiêu đề hoặc mô tả, từ đó bóc tách chiều ngang, chiều dài và tỷ lệ hình học của bất động sản. Đây là thông tin rất có giá trị với nhà phố hoặc đất nền, vì cùng một diện tích nhưng lô đất mặt tiền rộng thường có giá trị thương mại khác đáng kể so với lô đất hẹp, sâu. Nhóm tiếp theo là các biến suy luận số tầng và số phòng, bao gồm `inferred_floors` và `inferred_rooms`. Hệ thống nhận diện các cụm như 3 tầng, 2 lầu, h + 4, 2PN, 3 phòng ngủ để chuyển về dạng số. Điều này đặc biệt hữu ích vì nhiều nguồn đăng tin không có cột số tầng hay số phòng rõ ràng, nhưng thông tin này lại thường xuất hiện trong tiêu đề như một điểm bán hàng quan trọng.

Nhóm đặc trưng	Cột
Kích thước trích tu text	<code>frontage_width_m</code> , <code>frontage_length_m</code> , <code>frontage_ratio</code>
Số tầng/phòng suy luận	<code>inferred_floors</code> , <code>inferred_rooms</code>
Biến nhị phân từ tiêu đề	<code>title_has_frontage</code> , <code>title_has_alley</code> , <code>title_has_car_access</code> , <code>title_has_corner</code> , <code>title_has_elevator</code> , <code>title_has_furnished</code> , <code>title_has_legal</code> , <code>title_has_income_info</code>
Độ dài text	<code>title_token_count</code>
Có dữ liệu gốc	<code>has_area</code> , <code>has_rooms</code> , <code>has_coord</code>
Giao dịch	<code>transaction_type</code>
Thống kê phường	<code>ward_median_price</code> , <code>ward_listing_count</code> , <code>ward_price_encoded</code>
Biến log	<code>log_price</code> , <code>log_area</code> , <code>log_price_per_m2</code>
Không gian/thời gian	<code>distance_to_center</code> , <code>listing_age_days</code> , <code>posted_hour</code> , <code>posted_wday</code> , <code>is_weekend_post</code>
Phân khúc giá	<code>price_segment</code>

Bảng 3.9: Tổng hợp các nhóm đặc trưng

3.10. Trích xuất tín hiệu ngữ nghĩa từ tiêu đề

Một đóng góp nổi bật của bước tạo đặc trưng là khai thác nội dung văn bản ngắn trong tiêu đề, địa chỉ và loại bất động sản để tạo các biến nhị phân có ý nghĩa thị trường. Script trước hết ghép `title`, `address`, `category_name` thành `text_raw`, sau đó bỏ dấu tiếng

Viết để tạo `text_key`, giúp regex hoạt động ổn định trên nhiều cách viết khác nhau. Từ đó, hệ thống sinh ra hàng loạt biến như `title_has_frontage`, `title_has_alley`, `title_has_car_access`, `title_has_corner`, `title_has_elevator`, `title_has_furnished`, `title_has_legal`, `title_has_income_info`. Cụ thể, `title_has_frontage` = 1 nếu tiêu đề có các từ như “mặt tiền”, “mặt phố”, “mặt đường”; `title_has_car_access` = 1 nếu có “hẻm xe hơi”, “xe hơi”, “ô tô”, “oto”; `title_has_corner` = 1 nếu có “góc”, “2 mặt”, “hai mặt”; `title_has_elevator` = 1 nếu có “thang máy”; `title_has_furnished` = 1 nếu có “nội thất”, “full nội thất”, “furnished”; `title_has_legal` = 1 nếu có “sổ hồng”, “pháp lý”, “giấy tờ”; còn `title_has_income_info` = 1 nếu nhắc đến hợp đồng thuê, dòng tiền hoặc thông tin sinh lợi. Dù là các biến nhị phân đơn giản, chúng giúp mô hình nắm bắt thêm các tín hiệu chất lượng và tính thương mại của tài sản, vốn thường không hiện diện ở các trường dữ liệu có cấu trúc. Bên cạnh đó, hệ thống còn tạo biến `title_token_count` để đo độ dài tiêu đề, coi như một chỉ báo gián tiếp về mức độ mô tả hoặc chiến lược đăng tin của người bán/người cho thuê.

3.11. Biến giá trên mét vuông và các biến log-transform

Một đặc trưng trung tâm của bài toán bất động sản là giá trên mét vuông. Hệ thống tính $\text{price_per_m}^2 = \text{price} / \text{area}$ cho mọi quan sát có đủ dữ liệu giá và diện tích. Biến này đặc biệt hữu ích vì tổng giá thường bị chi phối mạnh bởi quy mô tài sản, trong khi giá trên mét vuông phản ánh rõ hơn mặt bằng định giá theo khu vực và loại hình. Với tin cho thuê, price_per_m^2 được hiểu là VND/m²/tháng. Tuy nhiên, do phân phối giá bất động sản thường lệch phải rất mạnh, dự án tiếp tục tạo các biến log gồm $\log_price = \log(1 + \text{price})$, $\log_area = \log(1 + \text{area})$ và $\log_price_per_m^2 = \log(1 + \text{price_per_m}^2)$. Việc dùng $\log(1 + \cdot)$ thay vì $\log$ thường giúp xử lý cả những giá trị nhỏ và giảm tác động của outlier ở phía đuôi phải. Khi dự đoán, giá trị log được quy đổi lại về đơn vị VND bằng công thức $\text{predicted_price} = \exp(\text{predicted_log_price}) - 1$. Đây là một xử lý kinh điển nhưng rất phù hợp với dữ liệu giá nhà đất, vì nó giúp cả mô hình tuyến tính lẫn mô hình phi tuyến học ổn định hơn.

3.12. Đặc trưng không gian và thời gian

Dự án còn bổ sung các đặc trưng theo chiều không gian và thời gian để tăng khả năng giải thích của mô hình. Biến `distance_to_center` được tính theo công thức Haversine, đo khoảng cách từ tọa độ tin đăng đến điểm tham chiếu trung tâm TP.HCM đặt tại khu vực Quận 1 với tọa độ xấp xỉ `lat_center = 10.7758`, `lon_center = 106.7009`. Về mặt kinh tế bất động sản, đây là biến có ý nghĩa cao vì giá/m² thường có tương quan âm với khoảng cách tới trung tâm, dù mức độ còn phụ thuộc hạ tầng, loại tài sản và sự phát triển của các cực đô thị mới. Song song đó, hệ thống tạo các biến thời gian như `listing_age_days`, `posted_hour`, `posted_wday`, `is_weekend_post`. Những biến này không trực tiếp quyết định giá trị thật của tài sản nhưng phản ánh hành vi đăng tin, tuổi đời tin đăng và nhịp điệu cập nhật dữ liệu của từng nền tảng, nhờ vậy có thể hỗ trợ mô hình nhận diện một phần cấu trúc ẩn của tập dữ liệu.

3.13. Target Encoding cho biến phân loại

Một phần rất quan trọng của feature engineering là xử lý các biến phân loại có số mức lớn như phường, quận, loại bất động sản và nguồn dữ liệu. Thay vì one-hot encoding toàn bộ, dự án triển khai target encoding có smoothing. Trong file dữ liệu chính đã tồn tại biến `ward_price_encoded` dựa trên trung vị giá theo phường, nhưng trong quá trình huấn luyện mô hình, script `huan_luyen_mo_hinh.R` sẽ fit lại target encoding chỉ trên tập train để tránh rò rỉ dữ liệu. Công thức làm mượt được dùng là $\text{encoded_value} = \log1p((n_g * \text{median_g} + \text{smoothing} * \text{global_median}) / (n_g + \text{smoothing}))$, trong đó `n_g` là số mẫu trong nhóm, `median_g` là trung vị giá của nhóm đó trong train, `global_median` là trung vị toàn cục và `smoothing = 10` là hệ số kéo các nhóm ít mẫu về gần giá trị trung bình chung. Hệ thống xây dựng tổng cộng 6 bảng encoding gồm:

- `ward_price_encoded`
- `district_price_encoded`
- `category_price_encoded`
- `source_price_encoded`
- `district_category_price_encoded`
- `source_category_price_encoded`

Cách làm này cho phép mô hình tận dụng được thông tin “mặt bằng giá” của từng khu vực, từng loại BĐS và từng nguồn mà không tạo ra ma trận đặc trưng quá thừa hoặc quá lớn. Đây cũng là điểm có giá trị học thuật rõ rệt vì nó cho thấy nhóm tác giả nhận thức được vấn đề leakage và đã xử lý đúng nguyên tắc.

3.14. Ý nghĩa tổng thể của quy trình ETL

Từ góc độ báo cáo, phần dữ liệu và tiền xử lý không chỉ đơn thuần là mô tả các bước thao tác kỹ thuật mà còn thể hiện tính hệ thống của toàn bộ đề tài. Dữ liệu được thu thập từ nhiều nền tảng khác nhau, chuẩn hóa về một schema chung, làm sạch theo ngưỡng nghiệp vụ thực tế, khử trùng lặp theo hai tầng, chuẩn hóa quận/huyện để tránh sai lệch thống kê, kiểm soát tọa độ nhằm phục vụ phân tích không gian, rồi tiếp tục được làm giàu bằng các đặc trưng về văn bản, hình học, thời gian, khoảng cách và mặt bằng giá khu vực. Nhờ pipeline này, tập dữ liệu đầu ra không còn chỉ là một bảng tin đăng rời rạc mà đã trở thành một bộ dữ liệu phân tích có cấu trúc, đủ sức hỗ trợ cho cả EDA, thống kê suy luận, dashboard tương tác và mô hình học máy. Đồng thời, chính những đặc điểm như tỷ lệ thiếu tọa độ cao, taxonomy loại BĐS chưa hoàn toàn hợp nhất, sự lệch nguồn giữa Mogi và các website còn lại, hay bản chất listing price chứ không phải transaction price cũng cần được nêu rõ trong báo cáo như các giới hạn nền tảng của dữ liệu.

CHƯƠNG 4. TRỰC QUAN HÓA DỮ LIỆU


4.1. Phân tích Khám phá tĩnh

Quá trình Phân tích Dữ liệu Khám phá (EDA) tĩnh được triển khai tự động hóa thông qua mã nguồn scripts/analysis/phan_tich_eda.R. Bằng việc sử dụng thư viện **ggplot2**, hệ thống trực quan hóa và trích xuất ra các biểu đồ định dạng ảnh cùng tập tin thống kê tổng hợp tom_tat_eda_hcm.csv. Mục tiêu của bước này là làm rõ đặc tính phân phối, tìm kiếm các mẫu hình (patterns) tiềm ẩn và phát hiện các giá trị ngoại lệ của thị trường bất động sản tại TP.HCM.

4.1.1. Biểu đồ Phân phối Logarit Giá:

Đầu tiên, biểu đồ phân phối logarit giá thể hiện cấu trúc phân phối của biến giá mục tiêu sau khi đã được chuẩn hóa bằng phép biến đổi $\log(1 + \text{price})$. Việc áp dụng

hàm logarit là một bước xử lý kỹ thuật cần thiết nhằm khắc phục hiện tượng lệch phải nặng nề vốn rất đặc trưng của dữ liệu giá bất động sản, từ đó kéo phân phối về dạng gần chuẩn hơn để tối ưu hóa hiệu năng cho các mô hình học máy. Đồ thị bộc lộ một cấu trúc phân phối hai đỉnh (bimodal distribution) vô cùng rõ rệt. Đặc điểm này ngầm vạch trần một thực tế rằng thị trường bất động sản Thành phố Hồ Chí Minh không đồng nhất mà đang bị phân mảnh thành hai mảng biệt lập: một đỉnh đại diện cho phân khúc nhà ở bình dân hoặc thị trường cho thuê, trong khi đỉnh còn lại phản ánh dòng lưu chuyển vốn của phân khúc mua bán thương mại cao cấp.




Hình 4.1: Phân phối logarit giá

4.1.2. Biểu đồ Phân bố giá theo Quận/Huyện:

Kiểm tra mức độ biến động giá giữa các khu vực thông qua biểu đồ hộp (Boxplot), kết quả bộc lộ rõ tính bất đối xứng trong phân bố tài sản. Khoảng tứ phân vị (IQR) – được biểu diễn qua độ cao của phần “hộp” – ở hầu hết các quận/huyện đều tương đối hẹp, chứng tỏ phần lớn các giao dịch trên thị trường đều diễn ra quanh một mặt bằng giá trung bình khá ổn định. Tuy nhiên, sự xuất hiện dày đặc của các râu (whiskers) kéo dài và các điểm chấm đen ngoại lệ (outliers) vươn lên những mốc giá trị cực đại tại Quận 1, Quận 3 và khu vực Thành phố Thủ Đức đã chỉ ra một hiện tượng thú vị: thị trường tồn tại một nhóm nhỏ các bất động sản “siêu cao cấp”. Dù chiếm tỷ


trọng rất thấp về mặt số lượng, song chính nhóm tài sản đất đỏ này lại là nhân tố chi phối mạnh mẽ biên độ dao động tổng thể và cấu trúc định giá của toàn thị trường.



Hình 4.2: Phân bố giá theo quận/huyện

4.1.3. Biểu đồ Tương quan giữa Diện tích và Giá:


Khảo sát mối liên hệ nội tại thông qua biểu đồ phân tán giữa diện tích và giá bán được phân rõ theo từng loại hình, dữ liệu một mặt xác nhận quy luật đồng biến hiển nhiên là quy mô càng lớn thì giá trị càng cao, mặt khác phản ánh tính chất phi tuyến phức tạp của thị trường. Cụ thể, các nhóm “Nhà mặt phố” và “Biệt thự” bộc lộ gia tốc tăng giá dốc đứng theo diện tích; điều này xảy ra do khi diện tích vượt qua một ngưỡng nhất định, bất động sản đó sẽ gánh thêm một “phần bù thương mại” cực lớn nhờ khả năng khai thác kinh doanh. Ngược lại, nhóm “Căn hộ chung cư” duy trì một đường xu hướng thoải và mang tính tuyến tính cao hơn. Sự phân nhánh về gia tốc giá này là minh chứng rõ nét giải thích vì sao các mô hình hồi quy tuyến tính truyền thống thường thất bại trên tập dữ liệu này, đồng thời đặt ra yêu cầu bắt buộc phải ứng dụng các thuật toán phi tuyến mạnh mẽ như Random Forest hay XGBoost trong giai đoạn huấn luyện.



Hình 4.3: Tương quan giữa Diện tích và Giá theo loại BDS

4.1.4. Biểu đồ Top khu vực có nhiều tin đăng nhất :


Xét về khía cạnh quy mô nguồn cung, biểu đồ thanh ngang thống kê lượng tin đăng theo đơn vị hành chính đã phác họa rõ nét hướng dịch chuyển trọng tâm đô thị của Thành phố Hồ Chí Minh. Về mặt quy mô tổng thể, Thành phố Thủ Đức vươn lên chiếm giữ vị thế thống trị tuyệt đối với tổng lượng tin rao vượt mốc 4.500 đơn vị, bỏ xa khu vực bám đuổi phía sau là Quận 7 (khoảng 3.150 tin) và Quận Bình Thạnh (khoảng 2.500 tin). Sự áp đảo của bộ ba “Thủ Đức – Quận 7 – Bình Thạnh” phơi bày trực phát triển năng động nhất của bất động sản Thành phố Hồ Chí Minh: dòng vốn và các đại dự án đang dồn toàn lực về phía Đông và phía Nam. Đây là những tọa độ sở hữu quỹ đất lớn, được “cởi trói” về hạ tầng kết nối (với các vành đai, cầu cảng và tuyến Metro) và tập trung các siêu đô thị mới. Ngược lại, các quận trung tâm lõi truyền thống như Quận 1, Quận 3 hay Quận 10 chỉ xếp ở mốc giữa và cuối bảng do quỹ đất phát triển dự án mới đã hoàn toàn cạn kiệt.



Hình 4.4: Top 10 quận/huyện có nhiều tin đăng nhất

4.1.5. Biểu đồ Top 10 khu vực có đơn giá/m² đắt đỏ nhất:


Để định vị lại các “thủ phủ” giá trị mà không bị làm nhiễu bởi các tin đăng rác hay các siêu biệt thự dị biệt, biểu đồ top 10 khu vực đắt đỏ nhất đã thông minh sử dụng thước đo là giá trung vị trên mỗi mét vuông (Median price/m²). Quan sát tổng thể, đồ thị phác họa một cấu trúc định giá hình bậc thang với tầng giá giá cao nhất thuộc về Quận 1 (đạt xấp xỉ 330 triệu đồng/m²) và Quận 3 (xấp xỉ 265 triệu đồng/m²). Điểm đắt giá nhất của đồ thị nằm ở “vách đá giá trị” (value cliff) xuất hiện ngay sau vị trí của Quận 3: dải đơn giá đột ngột rơi tự do mất gần 100 triệu đồng/m² khi chuyển sang vị trí thứ ba là Quận Phú Nhuận. Cú hẫng phi tuyến này chính là đường biên giới vô hình vạch trần ranh giới thực sự của khu vực CBD (Central Business District) – nơi đất đai đã thoát ly khỏi công năng “để ở” để biến thành một dạng tài sản tích trữ tài chính tối thượng, có độ co giãn cực thấp trước các chu kỳ suy thoái.



Hình 4.5: Top 10 quận/huyện có giá/m² cao nhất

4.1.6. Biểu đồ Xu hướng lượng tin đăng theo thời gian:


Đồ thị chuỗi thời gian đếm số lượng tin đăng xuất hiện mới theo từng ngày vạch trần một thuộc tính kỹ thuật mang tính “chiến dịch” của tập dữ liệu. Do sự chênh lệch về mặt khối lượng giữa các giai đoạn là quá lớn, đồ thị buộc phải sử dụng thang đo lôgarit cơ số 10 (Log10) trên trục tung để có thể hiển thị đồng thời các giá trị. Quan sát chuỗi lịch sử từ đầu năm 2024 đến hết năm 2025, lượng tin ghi nhận ở cả hai phân khúc Bán và Cho thuê dao động bám rất sát mặt đáy (chỉ leo lắt ở mức từ 1 đến dưới 20 tin/tháng). Tuy nhiên, bước sang đầu năm 2026, đồ thị ghi nhận một cú “dừng đứng” phi tuyến cực đại khi khối lượng vọt lên chạm mốc **hơn 10.000 tin đăng** cho mỗi phân khúc chỉ trong một khoảng thời gian vô cùng chớp nhoáng.



Hình 4.6: lượng tin đăng theo thời gian

4.1.7. Bản đồ Phân bố Địa lý theo Giá trị:


Bước sang không gian hai chiều của tọa độ địa lý, bản đồ phân bố vị trí bất động sản theo vĩ độ và kinh độ phơi bày hai hành vi không gian đối lập hoàn toàn giữa thị trường mua bán và cho thuê. Trong khi các điểm dữ liệu của phân khúc nhà bán trải rộng và lan tỏa mạnh mẽ theo trục Tây Bắc - Đông Nam, vươn sâu vào các vùng ven và huyện ngoại thành, thì phân khúc cho thuê lại thể hiện đặc tính hướng tâm sâu sắc. Cụ thể, đám mây tọa độ của các bất động sản cho thuê co cụm thành một khối đặc có độ hội tụ cực cao ngay tại lõi nội thành. Sự phân ly không gian này minh chứng cho quy luật tất yếu của kinh tế đô thị: nhu cầu mua đứt thường linh hoạt dạt ra vùng ven để tìm kiếm mức giá dễ tiếp cận và quỹ đất rộng, trong khi nhu cầu thuê lại gắn chặt với vòng quay thương mại, dịch vụ và nơi làm việc tại trung tâm, buộc nguồn cung phải bám sát khu vực lõi để tối ưu hóa tỷ lệ lấp đầy.



Hình 4.7: Phân bố địa lý

4.1.8. Biểu đồ Phân bố Giá theo Loại hình Bất động sản:


Đi sâu vào cấu trúc vi mô của từng dải sản phẩm, biểu đồ hộp so sánh đơn giá trên mỗi mét vuông phân tách theo loại hình bất động sản một lần nữa khẳng định sự phân hóa giai tầng gay gắt của thị trường. Nhóm “Biệt thự” và “Nhà phố / nhà ở” sở hữu dải biến động tứ phân vị (phần thân hộp) rộng nhất cùng hàng loạt điểm ngoại lệ (outliers) vươn lên những mức giá cực đoan. Hiện tượng này xác nhận đây là nhóm tài sản mang tính cá biệt hóa cao, nơi giá trị không bị trói buộc bởi khuôn mẫu xây dựng mà chịu sự chi phối tuyệt đối từ giá trị đất nền và vị trí độc bản của từng căn. Ngược lại, nhóm “Căn hộ / chung cư” lại thu mình vào một dải hộp ngắn và vuông vức, phản ánh tính chuẩn hóa cao của sản phẩm; mặt bằng giá tại đây được thiết lập minh bạch, đồng đều theo khung giá chủ đầu tư và ít bị biến động bởi cảm tính cá nhân hay yếu tố ngẫu nhiên của thị trường.




Hình 4.8: phân bố giá theo loại BDS

4.1.9. Biểu đồ Mức độ Quan trọng của Các Biến:

Chuyển sang giai đoạn giải thích cơ chế dự đoán của mô hình học máy, biểu đồ phân tích mức độ quan trọng của các đặc trưng từ thuật toán Random Forest đã phơi bày sự khác biệt căn bản trong tâm lý định giá giữa người mua và người thuê. Đối với bài toán dự đoán giá bán, các biến đại diện cho vị trí (đặc biệt là biến mã hóa mục tiêu `district_category_price_encoded`) và biến quy mô (`log_area`) cạnh tranh khốc liệt vị trí dẫn đầu về mức độ đóng góp. Điều này chứng tỏ khi quyết định mua đứt một khối tài sản, nhà đầu tư đang trả tiền cho “giá trị khu vực” ngang bằng, thậm chí nhỉnh hơn cả phần diện tích sử dụng. Trái lại, trong mô hình dự đoán giá thuê, hai biến quy mô diện tích (`area` và `log_area`) lại vươn lên thống trị hoàn toàn, đẩy các yếu tố về vị trí hành chính xuống hàng thứ cấp. Quy luật này phản ánh sát sao thực tế: người đi thuê vốn bị giới hạn bởi ngân sách sinh hoạt hàng tháng sẽ ưu tiên tối thượng cho bài toán “họ nhận được bao nhiêu mét vuông không gian sống” trước khi cân nhắc đến danh xưng hào nhoáng của khu vực đó.




Hình 4.9: Mức độ quan trọng của các biến trong phân khúc bán




Hình 4.10: mức độ quan trọng của các biến trong phân khúc thuê

4.1.10. Biểu đồ So sánh Kết quả Dự đoán và Thực tế:

Cuối cùng, để nghiệm chứng hiệu năng thực tế của hệ thống, biểu đồ phân tán đối chiếu giữa giá trị dự đoán và giá trị thực tế đóng vai trò như một màn lọc đánh giá độ tin cậy. Ở cả hai mô hình dự đoán giá bán và giá thuê, quần thể các điểm dữ liệu bám rất sát đường chéo chuẩn tại dải giá trị từ thấp đến trung bình, minh chứng cho năng lực tổng quát hóa xuất sắc của thuật toán trên các phân khúc bất động sản đại chúng. Tuy nhiên, khi dải giá thực tế tiến sâu về phía các giá trị cực đại ở phần đuôi phân phối (những bất động sản hàng trăm tỷ đồng), đám mây điểm bắt đầu tura ra và có xu hướng rũ xuống phía dưới đường chuẩn. Hiện tượng “under-prediction” (dự đoán thấp hơn thực tế) này phơi bày một điểm nghẽn đặc thù của các mô hình dựa trên cây quyết định: thuật toán thường có xu hướng kéo các dự đoán về phía giá trị trung bình của những điểm lân cận, dẫn đến sự “hụt hơi” tất yếu khi phải định giá những siêu bất động sản mang tính độc bản, nơi giá trị được quyết định bởi những cảm xúc xa xỉ vượt ra ngoài các thông số kỹ thuật thông thường.




Hình 4.11: So sánh kết quả dự đoán và thực tế trong phân khúc bán



Hình 4.12: So sánh kết quả dự đoán và thực tế trong phân khúc thuê


4.2. Trực quan hóa không gian :

Trực quan hóa không gian (Spatial Visualization) không chỉ đơn thuần là một kỹ thuật hiển thị đồ họa, mà là bước chuyển hóa then chốt nhằm đưa khối dữ liệu bất động sản khổng lồ “nhập vai” vào bối cảnh địa lý thực tế. Trong đồ án này, phân tích không gian được triển khai trực tiếp tại tab **Bản đồ dữ liệu** trên giao diện Shiny Dashboard thông qua việc tích hợp thư viện Leaflet. Bằng cách xử lý triệt để tọa độ kinh độ và vĩ độ, hệ thống đã phá vỡ rào cản của những con số khô khan trong bảng biểu thống kê, ánh xạ chúng lên bề mặt không gian hai chiều (2D). Thao tác này giải quyết triệt để bài toán “mù không gian”, giúp người phân tích vạch trần các quy luật phân bổ nguồn cung bám theo các trục hạ tầng huyết mạch hoặc các lõi đô thị tự nhiên mà các thuật toán học máy thuần túy không thể mô tả trọn vẹn.




Hình 4.13: Trực quan hóa không gian 1

Điểm đắt giá nhất của hệ thống bản đồ này nằm ở cơ chế tương tác thời gian thực và năng lực giải quyết hiện tượng quá tải dữ liệu (overplotting). Thay vì hiển thị chồng chéo hàng vạn điểm đánh dấu gây nhiễu thị giác, giao diện đã ứng dụng xuất sắc thuật toán gom cụm không gian (Spatial Clustering). Quan sát ở góc nhìn vĩ mô, các điểm dữ liệu tự động co cụm thành những khối tròn mang dải số lớn (như cụm 2.248, 1.262 hay 591 tin đăng), khoanh vùng ngay lập tức các trọng điểm giao dịch của thị trường đang đổ dồn về khu vực nào. Đi kèm với đó là hệ thống bộ lọc đa chiều bên thanh công cụ (sidebar), cho phép người dùng tùy biến linh hoạt theo loại hình giao dịch (bán/thuê), ranh giới hành chính, đến các mốc giới hạn về giá và diện tích. Mỗi thay đổi trên bộ lọc lập tức kích hoạt cơ chế kết xuất động (reactive rendering), biến Dashboard thành một “hệ thống truy vấn không gian” (Spatial Query System) đích thực để cô lập và rà soát từng ngách thị trường cụ thể.



Hình 4.14: Trực quan hóa không gian 2

Dải màu của các điểm đánh dấu được thiết kế để phân cấp trực quan sức nặng tài chính: sắc xanh đại diện cho phân khúc bình dân, sắc vàng hoặc cam cho mức giá tầm trung, và sắc đỏ rực đóng vai trò như một chỉ báo khoanh vùng các tọa độ đất đỏ. Đặc biệt, chức năng popup thể hiện sự trọn vẹn trong luồng trải nghiệm người dùng. Điển hình như khi nhấp chuột vào một marker bất kỳ, hệ thống lập tức bung mở một hồ sơ định danh chi tiết (như ví dụ đất đẹp ngang 6m gần Sông Sài Gòn khu Trần Nãi có tổng giá 27 tỷ đồng, đơn giá xấp xỉ 195,7 triệu/m²). Sự giao thoa giữa hiển thị mật độ vĩ mô và bóc tách thông số vi mô này giúp nhà đầu tư không chỉ nhận diện nhanh các “điểm nóng” (hotspots) tổng thể, mà còn có khả năng thẩm định chéo giá trị thực tế của từng khối tài sản ngay trên nền tảng bản đồ số.




Hình 4.15: Hồ sơ chi tiết của marker

4.3. Phân tích giá


Dựa trên lăng kính tổng quan trích xuất từ 30.250 tin đăng với mức giá trung vị toàn thị trường ghi nhận ở mốc 6,3 tỷ đồng (đối với bán) và 25 triệu đồng/tháng (đối với thuê), phần phân tích dưới đây sẽ bóc tách cấu trúc tài chính của thị trường bất động sản TP.HCM thông qua sáu hệ thống đồ thị chuyên sâu:

Khảo sát mối quan hệ giữa quy mô và giá trị tài sản thông qua biểu đồ “Diện tích vs Giá” tập dữ liệu cho thấy một sự hội tụ mật độ cực lớn ở các phân khúc đại chúng. Cụ thể, trên thị trường mua bán, phần lớn các điểm dữ liệu ôm rất sát trục hoành tại dải diện tích dưới 1.000 m² và mức giá dưới 50 tỷ đồng; trong khi thị trường cho thuê lặp lại quy luật tương tự tại quy mô dưới 500 m² và dải giá dưới 100 triệu đồng/tháng. Tuy nhiên, giá trị phân tích thực sự lộ diện ở dải ngoại lai (outliers) khi đồ thị vươn tới các mốc diện tích khổng lồ chạm ngưỡng 5.000 m², đẩy giá bán lên mức 150 tỷ đồng và giá thuê vọt lên mốc 400 - 500 triệu đồng/tháng. Trực quan này chứng minh một tính phi tuyến quan trọng: mối tương quan thuận giữa diện tích và giá chỉ đúng ở quy mô nhỏ và vừa; khi diện tích vượt qua một “ngưỡng tới hạn”, tổng giá trị tài sản không còn tăng

thuần túy theo mét vuông mà bị chi phối mạnh mẽ bởi loại hình công trình và công năng khai thác thương mại.



Hình 4.16: Biểu đồ Diện tích vs Giá theo phân khúc bán




Hình 4.17: Biểu đồ Diện tích vs Giá theo phân khúc thuê


Về mặt phân hóa địa lý, biểu đồ “Top khu vực cũ theo giá/m²” chỉ ra sự thống trị tuyệt đối của Quận 1 khi dẫn đầu cả hai thị trường với đơn giá trung vị bán đạt xấp xỉ 380 triệu đồng/m² và đơn giá thuê đạt mức 400 nghìn đồng/m². Vị trí thứ hai thuộc về Quận 3 với mốc định giá khoảng 270 triệu đồng/m² ở mảng bán và xấp xỉ 320 nghìn đồng/m² ở mảng thuê. Đáng chú ý, tại phân khúc cho thuê, Quận 11 vươn lên chiếm giữ vị trí thứ ba với đơn giá xấp xỉ 280 nghìn đồng/m², vượt qua các địa bàn trung tâm truyền thống khác như Phú Nhuận hay Quận 10. Lăng kính “Heatmap khu vực x loại BĐS” tiếp tục làm rõ ranh giới này: mảng bán xuất hiện vùng giá trị cao vượt mốc 400 triệu đồng/m² tại Quận 1 tập trung vào các nhóm Bất động sản khác, Nhà phố và Nhà ở, trong khi mảng thuê bùng nổ một “lõi nhiệt” vàng sáng đột biến chạm thang đo 3.000 nghìn đồng/m² tại Quận 7 thuộc loại hình Văn phòng, Mặt bằng kinh doanh.

Soi chiếu vào cấu trúc sản phẩm thông qua biểu đồ “Khoảng giá theo loại BĐS”, loại hình Biệt thự sở hữu biên độ giá bán rộng nhất và mức trung vị cao nhất, vươn tới mốc tối đa trên 60 tỷ đồng. Ở thị trường cho thuê, nhóm “Văn phòng, Mặt bằng kinh doanh” chiếm giữ mức trung vị cao nhất (khoảng 60 triệu đồng) và có dải giá trải dài tới mốc 150 triệu đồng. Để xử lý tính thiên lệch tự nhiên của con số tài chính thô, biểu đồ “Phân phối giá” lột tả dáng điệu phân phối hình chuông (normal distribution) sau khi thực hiện chuẩn hóa, với mốc giá bán hội tụ cao nhất tại đỉnh 23 (vượt 3.000 tin đăng)

và mức giá thuê hội tụ lớn nhất quanh đỉnh 18 (vượt 2.000 tin đăng).




Hình 4.18: Các biểu đồ theo phân khúc bán



Hình 4.19: Các biểu đồ theo phân khúc thuê

Phân tích động lực học theo trục thời gian và ma trận tương quan đã vạch trần những rủi ro nội tại của việc giải nghĩa số liệu thô. Tại mảng bán, hiện tượng lượng tin đăng sụt giảm mạnh từ 10.000 xuống 2.000 tin trong giai đoạn giữa năm 2025 đến đầu 2026 nhưng giá trung vị vẫn bất tốc đi lên chính là minh chứng kinh điển cho hiệu ứng cơ cấu giỏ hàng (Compositional Effect). Khi thị trường gặp cú sốc thanh khoản, các sản phẩm giá rẻ hoặc bị bán tháo sẽ biến mất trước, để lại trên rõ hàng trực tuyến những bất động sản cao cấp có chủ sở hữu khả năng gồng gánh tài chính tốt, làm cho giá trung vị tăng lên một cách giả tạo dù mặt bằng chung không hề đắt lên. Đồng thời, ma trận tương quan phát đi cảnh báo về hiện tượng đa cộng tuyến khi diện tích logarit và số phòng có độ đồng biến cực kỳ cao. Nếu đưa đồng thời hai biến này vào một phương trình hồi quy tuyến tính mà không áp dụng biện pháp co rút hay tạo biến tương tác, hệ thống sẽ bị suy biến ma trận thiết kế và làm sai lệch toàn bộ trọng số của các yếu tố ảnh hưởng.



Hình 4.20: Các biểu đồ theo phân khúc bán



Hình 4.21: Các biểu đồ theo phân khúc thuê

Cuối cùng, biểu đồ “ECDF giá/m²” lột tả trực quan mức độ tích lũy và trôi nổi của nguồn cung. Đối với các địa bàn vùng ven như Bình Tân hay Thành phố Thủ Đức, đường cong ECDF dốc đứng và bão hòa cực kỳ nhanh chóng ngay trong dải đơn giá từ 50 đến 120 triệu đồng/m². Độ dốc khốc liệt này chỉ ra rằng sức mua và mức độ chấp nhận giá của thị trường địa phương đã bị vắt kiệt ở một ngưỡng ngân sách chật hẹp; bất kỳ một nỗ lực chào bán nào vượt qua vách đá này sẽ lập tức rơi vào trạng thái đóng băng thanh khoản. Ngược lại, dáng điệu thoải mái và tịnh tiến chậm rãi của đường cong Quận 1 kéo từ mốc 100 triệu đến hơn 400 triệu đồng chứng minh vùng lõi trung tâm không hề tồn tại một mặt bằng định giá đại chúng. Tại đây, cấu trúc giá trị hoàn toàn phân tán, phản ánh tính chất độc bản của bất động sản lõi đô thị nơi mỗi giao dịch là một nỗ lực đàm phán độc lập vượt ra ngoài các quy luật mét vuông thông thường.

CHƯƠNG 5. TÍNH TOÁN XÁC SUẤT VÀ SUY LUẬN THỐNG KÊ

Nội dung phân tích xác suất và suy luận thống kê trong đồ án đóng vai trò là cầu nối quan trọng giữa bước làm sạch dữ liệu thô và bước xây dựng mô hình học máy phức tạp. Toàn bộ các công cụ phân tích này được lập trình bằng ngôn ngữ R và tích hợp trực tiếp vào tab “Suy luận thống kê” trên ứng dụng Shiny Dashboard, cho phép người dùng tính toán và theo dõi trực quan các chỉ số phân tích chuyên sâu trên tập dữ liệu bất động sản theo thời gian thực.

Thay vì chỉ dừng lại ở các con số trung bình đơn giản, dự án áp dụng các kỹ thuật thống kê mô tả mạnh mẽ để bóc tách cấu trúc dữ liệu, sử dụng lý thuyết xác suất để lượng hóa các rủi ro và xu hướng thị trường, đồng thời triển khai các phương pháp suy luận thống kê phi tham số (non-parametric) để kiểm chứng các giả thuyết kinh tế một cách chặt chẽ và khách quan.

5.1. Thống kê mô tả và xử lý ngoại lệ

Mô đun thống kê mô tả thực hiện các phép tính cơ bản để đánh giá hình dáng, vị trí trung tâm và độ phân tán của dữ liệu. Trong thống kê truyền thống, trung bình cộng mẫu ($\bar{x}$) và độ lệch chuẩn (s) thường được sử dụng. Tuy nhiên, đặc thù của dữ liệu giá bất động sản tại TP.HCM là có độ lệch phải cực kỳ mạnh. Sự tồn tại của các tài sản siêu cao cấp, chẳng hạn như biệt thự ven sông hay nhà mặt phố trung tâm Quận 1 có giá trị lên tới hàng trăm tỷ đồng, khiến cho giá trị trung bình bị kéo lệch về phía các giá trị lớn, làm mất đi tính đại diện cho phần đông thị trường.

Do đó, hệ thống ưu tiên sử dụng chỉ số trung vị (Median) làm thước đo vị trí trung tâm. Trung vị, là giá trị nằm chính giữa tập dữ liệu khi đã được sắp xếp, mang lại

tính bền vững cao, không bị nhiễu bởi các giá trị ngoại lai, qua đó phản ánh chính xác hơn mặt bằng giá thực tế mà đại đa số người dân có thể tiếp cận.

Bên cạnh đó, để đo lường độ phân tán và tự động hóa việc phát hiện các tin đăng có giá trị bất hợp lý, hệ thống không sử dụng phương sai hay quy tắc 3σ (ba độ lệch chuẩn) mà áp dụng phương pháp khoảng tứ phân vị (IQR - Interquartile Range).


Cơ sở toán học: Khoảng tứ phân vị là độ đo sự phân tán của 50% lượng dữ liệu nằm ở vùng trung tâm, giúp loại bỏ nhiễu từ hai phía đuôi của phân phối. Công thức tính IQR được định nghĩa là:

$$IQR = Q_3 - Q_1.$$

Trong đó, Q_1 là tứ phân vị thứ nhất (percentile 25) và Q_3 là tứ phân vị thứ ba (percentile 75). Dựa trên nguyên lý của Tukey, một điểm dữ liệu, trong đồ án là đại diện cho một tin đăng bất động sản sẽ bị hệ thống gắn cờ là ngoại lệ (Outlier) nếu giá trị của nó vượt qua hàng rào kiểm soát trên Upper Bound:

$$Upper\ Bound = Q_3 + 1.5 \times IQR.$$

Thực tiễn áp dụng trên dữ liệu: Quá trình trực quan hóa thông qua biểu đồ hộp minh họa rất rõ nguyên lý này. Các đường râu của biểu đồ kéo dài tới giá trị quan sát lớn nhất nhưng không vượt quá Upper Bound. Các chấm tròn nằm tản mạn kéo dài ở phía bên phải của các đường râu chính là các bất động sản vượt quá hàng rào ngưỡng trên. Sự xuất hiện dày đặc của các điểm ngoại lệ này không hẳn là lỗi nhập liệu, mà nó phản ánh một cách trung thực mức độ phân mảnh, sự chênh lệch giàu nghèo và sự xuất hiện của các sản phẩm bất động sản mang tính dị biệt trên thị trường.



Hình 5.1: Phát hiện ngoại lệ giá BĐS bằng biểu đồ hộp

5.2. Tính toán xác suất

Dựa trên nguyên lý của Luật số lớn, khi kích thước mẫu lên tới hơn 30.000 tin đăng, tần suất xuất hiện của các sự kiện trong mẫu sẽ xấp xỉ rất sát với xác suất thực tế của tổng thể thị trường. Hệ thống tận dụng điều này để đo lường các xác suất thực tiễn.

5.2.1. Xác suất thực nghiệm

Xác suất thực nghiệm $P(A)$ đo lường khả năng xảy ra của một thuộc tính A dựa trên việc đếm tần suất xuất hiện của nó trong không gian mẫu. Công thức toán học cơ bản:

$$P(A) = \frac{n(A)}{N}.$$

Trong đó, $n(A)$ là số lượng tin đăng thỏa mãn điều kiện A , và N là tổng số lượng tin đăng trong tập dữ liệu.

Hệ thống ứng dụng công thức này để tự động tính toán hàng loạt các chỉ số quan trọng nhằm định hình bức tranh thị trường:

- Xác suất một nguồn cung bất động sản rơi vào một khu vực hành chính cụ thể: $P(\text{khu vực} = \text{District } A)$.
- Xác suất phân bổ theo loại hình sản phẩm: $P(\text{loại BĐS} = \text{Category})$.
- Khả năng một tài sản bị định giá ở mức cao (nằm trong top 25% đắt đỏ nhất thị trường): $P(\text{giá/m}^2 \geq Q_3)$.

Kết quả phân tích từ dữ liệu: Khi quan sát trên bảng phân tích xác suất của Dashboard, hệ thống ghi nhận những con số phản ánh đúng xu hướng đô thị hóa. Ví dụ, khả năng một tin đăng xuất hiện tại Thành phố Thủ Đức là 12.3%, cho thấy sự dịch chuyển nguồn cung mạnh mẽ về khu vực phía Đông. Xác suất bắt gặp một sản phẩm thuộc loại hình “Nhà ở” chiếm 27.9% tổng không gian mẫu. Đặc biệt, dưới góc độ chất lượng dữ liệu, thống kê báo cáo có tới 86.6% tin đăng sở hữu tọa độ địa lý gốc chính xác từ nền tảng, minh chứng cho độ tin cậy không gian học của tập dữ liệu đang được phân tích.

Bảng xác suất thực nghiệm

Các xác suất nổi bật trong dữ liệu đã lọc

Xác suất thực nghiệm	Giá trị
$P(\text{khu vực} = \text{Thành phố Thủ Đức})$	12.3%
$P(\text{loại BĐS} = \text{Nhà ở})$	27.9%
$P(\text{giá/m}^2 \geq Q3)$	25.1%
$P(\text{Nhà ở} \mid \text{Thành phố Thủ Đức})$	15.1%
$P(\text{tọa độ gốc từ nguồn})$	86.6%

Bảng 5.1: Bảng xác suất thực nghiệm

5.2.2. Xác suất có điều kiện

Việc đánh giá xác suất đơn lẻ là chưa đủ để thấy được sự gắn kết phức tạp của thị trường. Xác suất có điều kiện $P(A|B)$ thể hiện khả năng xảy ra biến cố A (ví dụ: loại hình là Căn hộ) khi biết trước biến cố B (ví dụ: tài sản nằm ở Quận 7) đã xảy ra.

Cơ sở toán học: Dựa trên định lý Bayes và không gian mẫu thu hẹp, công thức được biểu diễn:


$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

Để giúp người dùng đọc vị được các ma trận xác suất phức tạp này, hệ thống trực quan hóa kết quả thông qua biểu đồ bản đồ nhiệt. Trục tung biểu diễn biến cố A (Loại BĐS) và trục hoành biểu diễn điều kiện B (Khu vực hành chính).

Thực tế dữ liệu: Quan sát bản đồ nhiệt $P(\text{category}|\text{district})$, sự khác biệt trong quy hoạch đô thị hiện lên cực kỳ sắc nét. Nhìn vào biểu đồ, ta có thể thấy rõ quy luật phân bố: Khi biết trước khu vực là Quận 7, xác suất cao nhất sẽ rơi vào loại hình “Căn hộ” (màu xanh nhạt trên biểu đồ) do đặc thù khu vực này phát triển mạnh các đại đô thị mới. Ngược lại, tại các khu vực trung tâm hiện hữu như Quận 3 hoặc vùng ven dân cư đông đúc như Quận Bình Tân, xác suất áp đảo lại thuộc về loại hình “Nhà phố”. Phân tích xác suất có điều kiện cung cấp bằng chứng toán học vững chắc phản ánh chính xác đặc thù quỹ đất và lịch sử phát triển của từng quận.

Xác suất có điều kiện

$P(\text{loại BĐS} \mid \text{khu vực})$ theo số tin



Hình 5.2: Bản đồ nhiệt xác suất có điều kiện

5.3. Tính toán suy luận thống kê

Nếu phân thống kê mô tả giúp nhìn thấy dữ liệu hiện tại, thì suy luận thống kê cung cấp công cụ để kiểm chứng các giả thuyết, đánh giá sai số và suy rộng kết quả từ mẫu ra toàn bộ thị trường thực tế.

5.3.1. Hàm phân phối tích lũy thực nghiệm (ECDF)

Thay vì dùng biểu đồ Histogram dễ bị che khuất thông tin bởi việc chia bin (thùng), dự án sử dụng Hàm phân phối tích lũy thực nghiệm (Empirical Cumulative Distribution Function - ECDF) để so sánh toàn diện mặt bằng giá giữa các khu vực.

- **Cơ sở toán học:** Hàm ECDF $\hat{F}(x)$ tính tỷ lệ phần trăm các điểm dữ liệu trong mẫu có mức giá nhỏ hơn hoặc bằng một ngưỡng x cụ thể. Nó là một hàm bậc thang tăng dần từ 0 đến 1:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x)$$

- Trong đó I là hàm chỉ thị, bằng 1 nếu quan sát $X_i \leq x$ và bằng 0 nếu ngược lại.
- **Thực tế dữ liệu:** Do đặc tính nhạy cảm với các điểm ngoại lệ cực trị, hệ thống đã áp dụng kỹ thuật gọt bỏ 5% dữ liệu có giá trị cao nhất tại phần đuôi để các đường cong phân phối hiển thị rõ nét hình dáng thực sự. Khi phân tích trên đồ thị so sánh, đường ECDF của Quận Bình Tân vọt lên mức xác suất 1.0 (100%) từ rất sớm ở trục hoành (giá/m²). Trong khi đó, đường ECDF của Quận 1 lại trải dài và lệch hẳn về phía bên phải đồ thị. Trong toán học thống kê, hiện tượng này gọi là sự thống trị ngẫu nhiên bậc nhất (First-order Stochastic Dominance). Điều này cung cấp bằng chứng thống kê trực quan và tuyệt đối khẳng định mặt bằng giá/m² tại Quận 1 đắt đỏ hơn Quận Bình Tân ở mọi bách phân vị, từ phân khúc giá rẻ nhất cho đến phân khúc đắt nhất.




Hình 5.3: So sánh phân phối tích lũy giá/m² giữa Quận 1 và Quận Bình Tân

5.3.2. Mô phỏng Định lý Giới hạn Trung tâm (CLT)

Nhiều thuật toán thống kê truyền thống yêu cầu dữ liệu phải tuân theo phân phối chuẩn hình chuông. Tuy nhiên, giá bất động sản lại vi phạm nghiêm trọng giả định này. Để tháo gỡ rào cản, hệ thống tích hợp công cụ mô phỏng Định lý Giới hạn Trung tâm.

- **Cơ sở toán học:** Định lý CLT khẳng định một nguyên lý toán học: Bất kể dữ liệu gốc có phân phối hình dạng dị biệt hay lệch phải mạnh đến đâu, nếu ta thực hiện lấy mẫu ngẫu nhiên độc lập với kích thước mẫu đủ lớn ($n \geq 30$) và tính trung bình mẫu, lặp lại quá trình này rất nhiều lần, thì phân phối của các trung bình mẫu đó sẽ luôn hội tụ về xấp xỉ phân phối chuẩn.
- **Thực tế dữ liệu:** Giao diện ứng dụng cung cấp thanh trượt tương tác cho phép người dùng tự điều chỉnh cỡ mẫu và số lần lặp. Khi quan sát trực tiếp quá trình mô phỏng lặp lại hàng trăm lần, người dùng sẽ thấy biểu đồ hình chuông dần hiện ra. Việc chứng minh được CLT trên chính tập dữ liệu thực tế giúp đảm bảo tính hợp lệ toán học cho toàn bộ các phép kiểm định thống kê phía sau, gạt bỏ lo ngại về việc dữ liệu BĐS gốc không có phân phối chuẩn.




Hình 5.4: Mô phỏng định lý giới hạn trung tâm

5.3.3. Ước lượng khoảng tin cậy bằng Bootstrap

Trong khi trung bình cộng ($\bar{x}$) có các công thức giải tích sẵn có để tính sai số chuẩn, thì chỉ số quan trọng nhất của ngành bất động sản là trung vị lại không hề có công thức toán học tính trực tiếp khoảng tin cậy. Để giải quyết bài toán này, dự án áp dụng thuật toán mô phỏng máy tính hiện đại đó là Bootstrap.

Cơ sở toán học và hoạt động thuật toán: Bootstrap hoạt động dựa trên kỹ thuật lấy mẫu lại có hoàn lại. Từ tập dữ liệu gốc của một quận, thuật toán sẽ bốc ngẫu nhiên ra các tin đăng (có thể bốc trùng lại tin cũ) cho đến khi bằng đúng kích thước mẫu gốc, sau đó tính ra giá trị trung vị. Quá trình này được thuật toán lập trình cho lặp lại tự động 600 lần, sinh ra 600 giá trị trung vị giả lập. Bằng cách cắt bỏ 2.5% giá trị thấp nhất và 2.5% giá trị cao nhất từ chuỗi kết quả này, hệ thống thu được Khoảng tin cậy 95% cho trung vị.

Thực tế dữ liệu: Xét ví dụ ứng dụng phân tích phân khúc giá bán tại khu vực Thành phố Thủ Đức. Tập mẫu hiện tại ghi nhận giá trị Trung vị là 77.4 triệu/m². Sau khi kích hoạt thuật toán Bootstrap chạy 600 vòng lặp, hệ thống vẽ ra phân phối của trung vị cùng hai đường giới hạn nét đứt màu vàng. Kết quả cho phép nhà phân tích tự tin tuyên bố với độ tin cậy 95% rằng: Bất chấp những biến động nhiều của thị trường, mặt bằng giá trung vị thực tế của toàn bộ khu vực Thành phố Thủ Đức chắc chắn sẽ rơi vào khoảng từ 74.2 triệu/m² đến 80.2 triệu/m². Khoảng dao động biên độ hẹp chỉ chênh lệch khoảng 6 triệu/m² là bằng chứng toán học đánh thép chứng minh lượng mẫu dữ liệu thu thập được từ các nền tảng có độ ổn định và tính đại diện cực kỳ cao cho thị trường thực tế.



Hình 5.5: Bootstrap lấy mẫu

5.3.4. Kiểm định giả thuyết

Khi quan sát thấy trung bình giá của Quận A cao hơn Quận B, câu hỏi đặt ra là: Sự chênh lệch này là do bản chất thị trường thực sự khác biệt, hay chỉ là do yếu tố ngẫu nhiên như sai số lấy mẫu khi thu thập tin đăng? Kiểm định giả thuyết được sinh ra để trả lời câu hỏi đó thông qua giá trị xác suất P-value.

Cơ sở toán học: Hệ thống đặt giả thuyết vô hiệu H_0 mang ý nghĩa “Không có sự khác biệt”:

$$H_0: \mu_A = \mu_B$$

(Nghĩa là kỳ vọng mặt bằng giá của hai nhóm thực chất bằng nhau, mọi sự chênh lệch trên bảng tính chỉ là ngẫu nhiên). Để linh hoạt xử lý, hệ thống lập trình song song hai bộ thuật toán kiểm định:

- **Welch's t-test (Kiểm định tham số):** Đây là phiên bản nâng cấp của Student's t-test truyền thống. Thay vì ép buộc giả định hai nhóm phải có phương sai bằng nhau, đây là điều không bao giờ xảy ra giữa một quận trung tâm và một huyện vùng ven, Welch's t-test tự động điều chỉnh bậc tự do để so sánh giá trị trung bình một cách công bằng và chính xác.
- **Wilcoxon Rank-Sum test (Kiểm định phi tham số):** Còn được gọi là kiểm định Mann-Whitney U. Nhận thức được rủi ro dữ liệu BĐS luôn bị lệch phải và chứa đầy nhiễu ngoại lệ, kiểm định Wilcoxon không tính toán trực tiếp trên giá trị (VND). Thay vào đó, thuật toán xếp hạng toàn bộ các tin đăng từ rẻ nhất đến đắt nhất, sau đó so sánh tổng hạng giữa hai khu vực. Đặc tính toán học này giúp Wilcoxon trở thành công cụ bền vững, không bị đánh lừa bởi các căn biệt thự có giá trị đột biến.

Thực tế dữ liệu: Thử nghiệm chạy kiểm định mức độ chênh lệch mặt bằng giá giữa hai khu vực đông dân là Thành phố Thủ Đức và Quận Bình Tân. Kết quả từ động cơ suy luận thống kê trả về giá trị $P - value < 0.05$ (thường nhỏ hơn rất nhiều so với ngưỡng ý nghĩa $\alpha = 5\%$). Dựa trên quy tắc quyết định thống kê, p-value cực nhỏ cho phép hệ thống bác bỏ hoàn toàn Giả thuyết vô hiệu H_0 . Kết luận phân tích khẳng định sự chênh lệch giá quan sát được giữa hai khu vực này mang ý nghĩa thống kê thực sự, xuất phát từ yếu tố cung cầu và quy hoạch định giá của thị trường, chứ tuyệt đối không phải là hệ quả do sai số ngẫu nhiên của việc lấy mẫu dữ liệu.

Kiểm định giả thuyết

H0: giá/m² trung bình log-scale của hai khu vực bằng nhau

Mục	Giá trị
H0	Mean log(giá/m ²) hai khu vực bằng nhau
Nhóm A	Thành phố Thủ Đức · n=1.838
Nhóm B	Quận Bình Tân · n=1.173
Chênh lệch median A-B	-12,2 triệu VND/m ²
t-test p-value	0,025
Wilcoxon p-value	< 0,001
Kết luận $\alpha=0,05$	Bác bỏ H0

Hình 5.6: Kết quả kiểm định giả thuyết

CHƯƠNG 6. MÔ HÌNH HÓA DỮ LIỆU

Chương này trình bày toàn bộ phương pháp luận và kiến trúc kỹ thuật của lớp mô hình hóa dữ liệu được triển khai trong dự án. Quá trình mô hình hóa bao gồm việc định nghĩa bài toán dự đoán, thiết lập chiến lược phân chia dữ liệu, xây dựng cơ chế chống rò rỉ thông tin trong quá trình mã hóa đặc trưng, cấu trúc hóa dữ liệu đầu vào và huấn luyện các thuật toán học máy. Các thuật toán được sử dụng bao gồm mô hình học có giám sát phục vụ nhiệm vụ định giá bất động sản, thuật toán học không giám sát phục vụ bài toán phân cụm thị trường vĩ mô và mô đun xử lý ngôn ngữ tự nhiên phục vụ chức năng trợ lý ảo.

6.1. Thiết lập bài toán và chuẩn bị dữ liệu huấn luyện

6.1.1. Bài toán mô hình hóa

Tập dữ liệu bất động sản thu thập được trong đồ án bao gồm hai nhóm giao dịch mang bản chất tài chính và thước đo hoàn toàn độc lập. Phân khúc dự đoán giá bán được

tính toán trên tổng giá trị giao dịch tài sản bằng đơn vị tiền Việt Nam Đồng, trong khi phân khúc dự đoán giá cho thuê được tính toán dựa trên chi phí sử dụng tài sản định kỳ theo đơn vị Việt Nam Đồng trên một tháng. Sự khác biệt quá lớn về hệ quy chiếu, biên độ dao động và động lực định giá thị trường buộc dự án phải thiết lập hệ thống thành hai bài toán mô hình hóa hồi quy tách biệt hoàn toàn để tránh hiện tượng nhiễu loạn thông tin.


Thực tế phân tích dữ liệu cho thấy phân phối giá trị bất động sản luôn bị lệch phải rất mạnh do sự xuất hiện tất yếu của nhóm tài sản siêu cao cấp như biệt thự hoặc nhà phố trung tâm. Việc để các thuật toán máy học tối ưu hóa trực tiếp trên biến giá trị gốc sẽ khiến hệ thống bị chi phối nặng nề bởi các giá trị ngoại lệ này, dẫn đến sai số phình to ở phân khúc phổ thông. Để giải quyết rào cản kỹ thuật này, hệ thống tiến hành một phép biến đổi toán học lên biến mục tiêu thông qua việc lấy logarit tự nhiên của giá trị gốc cộng thêm một, theo phương trình $y = \log(1 + price)$.

Phép biến đổi logarit đóng vai trò cốt lõi trong việc chuẩn hóa dữ liệu đầu vào. Kỹ thuật này không chỉ giúp nén biên độ dao động của các tài sản giá trị cực lớn để đưa phân phối dữ liệu về dạng tiệm cận đối xứng, mà còn chuyển đổi mối quan hệ nhân phức tạp giữa diện tích và đơn giá thành mối quan hệ cộng đơn giản. Nhờ đó, các thuật toán dựa trên nền tảng cây quyết định và mô hình tuyến tính có thể nhận diện quy luật ổn định hơn trên toàn bộ dải phân khúc thị trường. Khi hoàn tất quá trình tính toán dự đoán, kết quả đầu ra trên thang đo logarit sẽ được hệ thống dịch ngược về đơn vị tiền tệ gốc thông qua hàm số mũ trừ đi một theo công thức $price = \exp(\hat{y}) - 1$, đảm bảo giá trị trả về cho người dùng luôn mang ý nghĩa thực tiễn.

6.1.2. Luồng huấn luyện tổng quát

Quy trình tạo ra các mô hình học máy được tự động hóa hoàn toàn thông qua một chuỗi các kịch bản mã nguồn được lập trình bằng ngôn ngữ R. Chu trình này bắt đầu từ việc hệ thống nạp tập dữ liệu đã qua làm sạch, sau đó tiến hành phân tách thành tập huấn luyện và tập kiểm thử. Ngay sau khi dữ liệu được phân chia, quy trình trích xuất đặc trưng và tính toán các bảng mã hóa mục tiêu sẽ được kích hoạt nội bộ trên tập huấn luyện. Tập dữ liệu sau khi chuẩn hóa định lượng sẽ được đưa vào huấn luyện đồng

thời trên nhiều kiến trúc thuật toán khác nhau. Hệ thống sẽ tự động đo lường, đối chiếu các chỉ số sai số trên tập kiểm thử để xếp hạng và chọn ra phiên bản mô hình có độ chính xác cao nhất. Bước cuối cùng của luồng xử lý là xuất các cấu hình mô hình tối ưu dưới định dạng tệp tin rds để tích hợp trực tiếp lên bộ nhớ của giao diện ứng dụng phân tích.



Hình 6.1: Sơ đồ luồng huấn luyện tổng quát

6.1.3. Phân chia dữ liệu huấn luyện và kiểm thử phân tầng

Để đo lường hiệu năng của các thuật toán một cách độc lập và khách quan, dự án áp dụng chiến lược phân tách tập dữ liệu theo tỉ lệ 80 phần trăm không gian mẫu dành cho quá trình huấn luyện và 20 phần trăm không gian mẫu bảo lưu cho quá trình kiểm thử. Điểm tối ưu kỹ thuật cốt lõi trong bước này là việc hệ thống không áp dụng thuật toán lấy mẫu ngẫu nhiên thông thường mà thiết lập cơ chế lấy mẫu phân tầng dựa trên biến số nguồn gốc nền tảng thu thập dữ liệu.

Nguyên nhân ra đời của cơ chế này xuất phát từ thực tế cấu trúc dữ liệu của 6 nguồn thu thập có sự chênh lệch tỷ trọng rất lớn. Nền tảng Mogi chiếm tỷ trọng chi phối toàn hệ thống và chứa lượng lớn tin đăng phân khúc cho thuê, trong khi nền tảng Chợ Tốt lại tập trung gần như toàn bộ vào phân khúc rao bán. Các nền tảng còn lại như Homedy, Mua Bán hay Lựa Chọn Nhà Đất có dung lượng mẫu khá khiêm tốn. Việc phân chia ngẫu nhiên sẽ dẫn đến rủi ro tập kiểm thử bị khuyết thiếu hoàn toàn dữ liệu từ các nền tảng nhỏ, hoặc làm biến dạng tỷ lệ phân phối nguồn so với thực tế tổng thể, gây ra sai lệch trong khâu đánh giá mô hình.

Kỹ thuật chia phân tầng khắc phục triệt để rủi ro này thông qua một thuật toán đảm bảo số lượng bản ghi được trích xuất vào tập huấn luyện từ một nền tảng cụ thể luôn tuân thủ nghiêm ngặt công thức $n_{train,g} \approx \lceil 0.8 \times n_g \rceil$ là tổng số dòng thu thập được từ nền tảng đó. Đáng chú ý, sau khi hoàn tất toàn bộ chu trình đánh giá và xác định được kiến trúc thuật toán cùng bộ siêu tham số tốt nhất trên tập kiểm thử, mã nguồn sẽ tự động thực thi một tiến trình huấn luyện lại từ đầu trên toàn bộ 100 phần trăm dữ liệu sạch. Phiên bản mô hình toàn diện này mới là sản phẩm cuối cùng được lưu trữ để cung cấp khả năng định giá trên ứng dụng trực tuyến, giúp hệ thống hấp thụ trọn vẹn tri thức từ toàn bộ không gian mẫu.

Phân khúc giao dịch	Tổng số dòng	Tập huấn luyện (Train)	Tập kiểm thử (Test)	Tỷ lệ phân chia	Thuật toán phân tách
Bán	14.891	11.911	2.978	80,0%	stratified_random_by_source
Cho thuê	15.359	12.285	3.074	80,0%	stratified_random_by_source

Bảng 6.1: Chi tiết phân chia quy mô tập dữ liệu huấn luyện và kiểm thử theo từng phân khúc giao dịch


6.1.4. Cơ chế chống rò rỉ dữ liệu bằng kỹ thuật mã hóa mục tiêu

Các thuật toán máy học tiêu chuẩn như hồi quy tuyến tính hay rừng ngẫu nhiên không sở hữu khả năng tính toán trực tiếp trên các biến đầu vào mang định dạng ký tự văn bản thuần túy như tên phường xã hay tên loại hình bất động sản. Để khắc phục, dự án áp dụng kỹ thuật mã hóa mục tiêu nhằm thay thế các chuỗi ký tự này bằng mặt bằng giá trị trung vị tương ứng của chính nhóm phân loại đó. Tuy nhiên, nếu tiến trình tính toán bảng mã hóa này được thực thi trên toàn bộ tập dữ liệu trước thời điểm chia tách tập kiểm thử, mô hình sẽ vi phạm nguyên tắc rò rỉ dữ liệu nghiêm trọng do thuật toán đã trực tiếp học được thông tin đáp án của tập kiểm tra ngay từ khâu tiền xử lý.

Để ngăn chặn tuyệt đối rủi ro rò rỉ dữ liệu, quy trình tính toán được hệ thống cô lập thành các bước vận hành khép kín. Thuật toán bắt buộc phải hoàn thành việc chia tách tập huấn luyện và kiểm thử trước. Ngay sau đó, quá trình quét dữ liệu và tính toán mặt bằng giá trị trung vị chỉ được phép giới hạn bên trong không gian của tập huấn luyện. Bảng tra cứu toán học sinh ra từ tập huấn luyện này sau đó mới được ánh xạ một chiều sang tập kiểm thử. Đối phó với tình huống trong tập kiểm thử xuất hiện một đơn vị hành chính hoàn toàn mới chưa từng tồn tại lúc huấn luyện, thuật toán sẽ tự động kích hoạt cơ chế dự phòng bằng cách sử dụng giá trị trung vị toàn cục của thành phố để nội suy, bảo đảm mô hình luôn đánh giá khách quan.

Song song với việc cô lập dữ liệu, hệ thống tích hợp thêm một hệ số làm mượt vào phương trình mã hóa nhằm triệt tiêu hiện tượng quá khớp tại những nhóm phân loại có quá ít số lượng tin đăng quan sát được. Công thức mã hóa được lập trình là

$encoded_g = \log \left(1 + \frac{n_g \times median_g + \lambda \times median_{global}}{n_g + \lambda} \right)$ Trong phương trình này, đại diện cho số lượng bản ghi của nhóm, $median_g$ là trung vị giá của nhóm đó, $median_{global}$ là trung vị giá toàn cục và hệ số làm mượt λ được cấu hình cố định bằng 10. Cơ chế này vận hành theo nguyên lý tự động điều tiết mặt bằng giá mã hóa của các nhóm khuyết thiếu dữ liệu tiến dần về mức mặt bằng chung của toàn thành phố, giúp tín hiệu đầu vào cho mô hình học máy trở nên ổn định và đáng tin cậy hơn.



Hình 6.2: Sơ đồ Target Encoding

Biến mã hóa (Encoding)	Nhóm đặc trưng gốc	Ý nghĩa định giá
ward_price_encoded	ward	Mặt bằng giá theo cấp độ phường/xã
district_price_encoded	district_name	Mặt bằng giá theo khu vực cũ/quận/huyện
category_price_encoded	category_name	Mặt bằng giá phân bổ theo loại hình bất động sản
source_price_encoded	source	Khác biệt mặt bằng giá tùy thuộc theo nguồn đăng tin
district_category_price_encoded	district_name + category_name	Tương tác chéo giữa khu vực địa lý và loại hình bất động sản

source_category_price_encoded	source + category_name	Tương tác chéo giữa nguồn thu thập dữ liệu và loại hình bất động sản
-------------------------------	---------------------------	--

Bảng 6.2: Danh mục các biến mã hóa mục tiêu được thiết lập trong quá trình huấn luyện mô hình.

6.1.5. Cấu trúc tập đặc trưng đầu vào

Không gian dữ liệu đầu vào dành cho mô hình được cấu trúc hóa thành các cụm đặc trưng đa chiều, đại diện cho nhiều khía cạnh định giá tài sản trên thực tế. Cụm đặc trưng về quy mô bao gồm các biến diện tích gốc, diện tích trên thang logarit, số lượng phòng ngủ từ nguồn cấp và số lượng phòng ngủ được thuật toán suy luận tự động, đóng vai trò là hạt nhân cơ sở cấu thành nên giá trị tài sản. Cụm đặc trưng hình học ghi nhận các chỉ số về mặt tiền, chiều sâu và tỷ lệ khung, cung cấp dữ liệu về độ vuông vức cũng như tiềm năng khai thác không gian thương mại của bất động sản. Cụm tín hiệu văn bản bao gồm loạt biến nhị phân được trích xuất thông qua biểu thức chính quy trực tiếp từ tiêu đề tin đăng, giúp mô hình bắt được các lợi thế vô hình mang tính quyết định như vị trí nhà mặt phố, ngõ xe hơi tiếp cận, tình trạng bàn giao nội thất hay sự tồn tại của sổ hồng pháp lý.

Cụm đặc trưng không gian thực hiện đo lường định lượng mức độ ảnh hưởng vị trí thông qua khoảng cách tuyến tính đường chim bay từ tọa độ tài sản đến khu vực trung tâm hành chính Quận 1 bằng công thức hình học cầu Haversine. Cụm đặc trưng thời gian ghi nhận giờ phát sóng tin, ngày đăng trong tuần và tuổi thọ tồn tại của bản tin trên hệ thống nhằm đánh giá độ trẻ thanh khoản. Cuối cùng, 6 biến mã hóa mục tiêu đã được tính toán kết hợp cùng các nhãn phân loại nguyên bản gốc được nạp vào mô hình, giúp các thuật toán nhận diện sâu sắc sự chênh lệch mặt bằng giá vi mô và mức độ tương tác chéo phức tạp giữa từng vị trí địa lý với từng loại hình bất động sản riêng biệt.

Nhóm đặc trưng	Các biến số tiêu biểu	Vai trò và ý nghĩa trong cơ chế định giá
----------------	-----------------------	--

Quy mô tài sản	area, log_area, rooms, inferred_rooms, inferred_floors	Yếu tố quy mô diện tích và số lượng phòng chức năng thường là nhân tố nền tảng cơ bản nhất chi phối trực tiếp giá trị tổng của một tài sản
Hình học nhà đất	frontage_width_m, frontage_length_m, frontage_ratio	Cấu trúc nhà có chiều ngang rộng và chiều sâu tỷ lệ hợp lý thường mang lại lợi thế khai thác thương mại và định giá tốt hơn trên thị trường
Tín hiệu từ tiêu đề	title_has_frontage, title_has_alley, title_has_car_access, title_has_corner, title_has_elevator, title_has_furnished, title_has_legal, title_has_income_info	Thuật toán trích xuất các tín hiệu có sức ảnh hưởng mạnh từ văn bản như lợi thế mặt tiền, tuyến hẻm tiếp cận xe hơi, tình trạng giấy tờ pháp lý hay mức độ trang bị nội thất
Thông tin văn bản	title_token_count	Độ dài của tiêu đề phản ánh mức độ cung cấp thông tin mô tả chi tiết của người bán và có khả năng liên quan mật thiết đến độ tin cậy của tin đăng
Yếu tố không gian	distance_to_center	Khoảng cách tuyến tính đo lường đến trung tâm Quận 1 tác động mạnh mẽ đến việc hình thành mặt bằng giá theo quy luật kinh tế học không gian
Yếu tố thời gian	posted_hour, posted_wday, listing_age_days	Thời điểm phát hành tin và độ tuổi lưu trữ của tin đăng có thể phản ánh mức độ thanh khoản hoặc chất lượng thực sự của bất động sản đó

Mã hóa mục tiêu (Target Encoding)	Bao gồm 6 biến mã hóa giá trị	Tóm tắt và chuẩn hóa mặt bằng giá theo từng khu vực địa lý hành chính, loại hình bất động sản và sự chênh lệch giữa các nền tảng thu thập
Biến phân loại gốc	source, district_name, category_name, posted_wday	Được hệ thống giữ lại nhằm duy trì hiệu ứng phân loại độc lập sau khi đã tiến hành các bước mã hóa mục tiêu ở trên

Bảng 6.3: Phân loại và tổng hợp chi tiết tập các đặc trưng đầu vào được sử dụng để huấn luyện mô hình máy học

6.2 Thuật toán học có giám sát (Supervised Learning): Dự đoán giá

Lớp mô hình hóa có giám sát đóng vai trò cấu trúc hạt nhân trong kiến trúc phân tích của đề án, hướng tới mục tiêu thiết lập một hàm số toán học có khả năng ánh xạ chính xác không gian đặc trưng đa chiều X sang biến mục tiêu liên tục y . Trong khuôn khổ dự án, biến mục tiêu y không phải là giá trị tiền tệ nguyên bản mà là giá trị đã qua phép biến đổi logarit tự nhiên cộng một nhằm chuẩn hóa phân phối dữ liệu. Việc so sánh và đánh giá một hệ thống phân cấp mô hình từ các thuật toán tuyến tính cổ điển cho đến các kiến trúc cây quyết định phức tạp và các mô hình lai hóa là điều kiện tiên quyết để nhận diện mức độ phi tuyến tính tính chất phức tạp của thị trường bất động sản Thành phố Hồ Chí Minh. Hệ thống tiến hành huấn luyện, tinh chỉnh siêu tham số và đánh giá song song 5 cấu trúc mô hình đại diện cho các trường phái lý thuyết học máy khác nhau cho cả hai phân khúc chiến lược: Bán bất động sản và Cho thuê bất động sản.

Danh mục tổng hợp cấu trúc lớp mô hình được thiết lập làm hệ quy chiếu thực nghiệm bao gồm:

Nhóm mô hình	Tên mô hình thuật toán	Mục đích công nghệ và cơ sở lý thuyết nền tảng
Baseline tuyến tính	Linear Regression (OLS)	Làm mốc tham chiếu cơ sở để kiểm tra giả định tuyến tính của không gian dữ liệu. Khả năng diễn giải hệ số rất cao nhưng cấu trúc toán học đơn giản nên dễ rơi vào trạng thái underfitting trước dữ liệu biến động mạnh.

Nhóm mô hình	Tên mô hình thuật toán	Mục đích công nghệ và cơ sở lý thuyết nền tảng
Họ thuật toán Bagging	Random Forest Regression	Giảm thiểu phương sai (Variance) tổng thể thông qua cơ chế trung bình hóa dự đoán của một rừng gồm nhiều cây quyết định độc lập. Khả năng học sâu các tương tác chéo phi tuyến tính vô cùng xuất sắc.
Họ thuật toán Boosting	XGBoost Regression	Giảm thiểu độ lệch (Bias) bằng cách xây dựng các chuỗi cây quyết định tuần tự, tập trung tối đa vào việc sửa chữa sai số phần dư của các cây phía trước. Cấu trúc được tối ưu hóa đặc biệt cho dữ liệu dạng bảng.
Ensemble cơ bản	RF + XGBoost Ensemble	Kết hợp hai triết lý đối nghịch Bagging và Boosting theo tỷ lệ trọng số cố định (0.5/0.5) nhằm dung hòa thế mạnh nội tại của từng mô hình, thiết lập trạng thái cân bằng Bias-Variance tối ưu.
Ensemble tối ưu	Tuned RF/XGBoost Ensemble	Tiến hành tìm kiếm lưới (Grid Search) không gian trọng số kết hợp liên tục nhằm xác định tỷ lệ phối trộn tối ưu nhất, trực tiếp cực tiểu hóa hàm mất mát MAPE trên tập dữ liệu kiểm thử thực nghiệm.

Bảng 6.4: Danh mục tổng hợp cấu trúc lớp mô hình thuật toán học có giám sát tham gia thực nghiệm.

6.2.1 Hồi quy tuyến tính Baseline OLS (Ordinary Least Squares)

Mô hình hồi quy tuyến tính cổ điển sử dụng phương pháp bình phương tối thiểu (Ordinary Least Squares - OLS) được thiết lập đóng vai trò là thước đo đáy (Baseline) cho toàn bộ dự án. Thuật toán này hoạt động dựa trên giả định nghiêm ngặt rằng tồn tại một mối quan hệ tuyến tính bậc nhất, mang tính cộng gộp giữa biến mục tiêu dạng logarit và các đặc trưng định lượng đầu vào. Phương trình toán học tổng quát biểu diễn cho một quan sát thứ i trong không gian mẫu được cấu trúc như sau:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \epsilon_i$$

Trong phương trình nền tảng này, các thành phần tham số đại diện cho các đại lượng nghiệp vụ chuyên sâu:

- $y_i = \log(1 + price_i)$ đại diện cho giá trị mục tiêu đã được nén biên độ dao động thông qua phép biến đổi toán học logarit tự nhiên nhằm đưa phân phối lệch phải về tiệm cận phân phối chuẩn.
- x_{ij} đại diện cho giá trị định lượng của đặc trưng thứ j (chẳng hạn như diện tích, số phòng, hay khoảng cách đến trung tâm Quận 1) được trích xuất từ quan sát thứ i .
- β_j ($j = 0, 1, \dots, p$) là tập hợp các hệ số hồi quy tuyến tính mà mô hình cần phải học tập và tối ưu hóa thông qua quá trình huấn luyện dữ liệu.
- ϵ_i đại diện cho thành phần sai số ngẫu nhiên hoặc nhiễu hệ thống, tuân theo giả định phân phối chuẩn có kỳ vọng bằng 0 và phương sai đồng nhất $\mathcal{N}(0, \sigma^2)$.

Cơ sở toán học: Phương pháp OLS tìm kiếm vector hệ số tối ưu β bằng cách cực tiểu hóa tổng bình phương các phần dư (Residual Sum of Squares - RSS), tức là khoảng cách hình học giữa giá trị thực tế và đường thẳng dự đoán:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i^T \beta)^2$$

Dưới đại số tuyến tính ma trận, nếu ma trận hiệp phương sai của các đặc trưng đầu vào $X^T X$ đạt trạng thái toàn hạng cột và có khả năng nghịch đảo, nghĩa là không tồn tại hiện tượng đa cộng tuyến hoàn hảo giữa các biến độc lập, nghiệm giải tích đóng độc nhất của bài toán tối ưu được xác định bằng phương trình:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Vai trò hệ thống và hạn chế thực tiễn: Trong kiến trúc công nghệ của đồ án, OLS đóng vai trò như một bộ lọc chẩn đoán sơ bộ. Nếu các kiến trúc học máy phi tuyến tính phức tạp như Random Forest hay XGBoost không thể vượt qua được các chỉ số sai số của OLS, điều đó chứng tỏ cấu trúc định giá của thị trường mang bản chất thuần tuyến tính đơn giản.

Tuy nhiên, thực tế phân tích thị trường bất động sản Thành phố Hồ Chí Minh chỉ ra rằng các giả định cốt lõi của OLS thường xuyên bị vi phạm nghiêm trọng. Bản chất của kinh tế học không gian khẳng định tính phi tuyến tính: tác động của việc tăng thêm $1m^2$ diện tích tại một huyện ngoại thành như Củ Chi mang một giá trị hoàn toàn khác biệt so với việc tăng thêm $1m^2$ tại khu vực lõi trung tâm như Quận 1. OLS cũng thể hiện sự nhạy cảm cực đoan đối với các điểm dị thường (Outliers) và hoàn toàn bất lực trong việc tự động mô hình hóa các hiệu ứng tương tác chéo giữa các biến phân loại nếu không được người lập trình định nghĩa thủ công một cách máy móc.

6.2.2 Random Forest Regression

Để khắc phục triệt để rào cản underfitting và tính nhạy cảm với nhiễu của mô hình tuyến tính, đồ án tri triển thuật toán Random Forest. Đây là đại diện ưu tú nhất của


họ thuật toán học máy kết hợp dạng túi (Bagging - Bootstrap Aggregating). Cấu trúc này giải quyết bài toán biến động phương sai cao và hiện tượng quá khớp (Overfitting) của một cây quyết định đơn lẻ bằng cách xây dựng một quần thể gồm nhiều cây quyết định phân tách nhánh độc lập, hoạt động dựa trên hai cơ chế ngẫu nhiên hóa cốt lõi.

Cơ chế hoạt động:

1. **Lấy mẫu Bootstrap:** Từ tập dữ liệu huấn luyện nguyên bản có quy mô n dòng quan sát, thuật toán tiến hành rút trích ngẫu nhiên có hoàn lại đúng n mẫu để tạo ra một tập dữ liệu con. Quy trình này được lặp lại tự động B lần để tạo ra B tập dữ liệu huấn luyện độc lập cho B cây quyết định khác nhau. Theo lý thuyết xác suất, mỗi tập mẫu Bootstrap sẽ chứa xấp xỉ 63.2% các quan sát độc nhất từ tập gốc, phần còn lại được gọi là dữ liệu Out-Of-Bag (OOB) dùng để đánh giá nội bộ mô hình.
2. **Không gian con ngẫu nhiên:** Đây là cải tiến đột phá giúp phá vỡ tính tương quan giữa các cây quyết định. Tại mỗi nút phân chia nhánh của một cây hồi quy, thay vì duyệt qua toàn bộ không gian p đặc trưng sẵn có, thuật toán chỉ lấy mẫu ngẫu nhiên một tập con gồm m đặc trưng ($m < p$). Đối với bài toán hồi quy liên tục, hệ số tiêu chuẩn được cấu hình theo khuyến nghị toán học là $m \approx \frac{p}{3}$. Sự kết hợp này đảm bảo các cây quyết định trong rừng có cấu trúc hoàn toàn dị biệt, giúp mô hình hấp thụ được các góc nhìn đa dạng từ không gian đặc trưng.
3. **Tổng hợp kết quả:** Dự đoán cuối cùng của hệ thống Rừng ngẫu nhiên là kết quả trung bình cộng toán học từ dự đoán của toàn bộ quần thể các cây thành phần. Với quy mô $B = 500$ cây quyết định được thiết lập cố định trong mã nguồn hồi quy của dự án, dự đoán cho một điểm dữ liệu đặc trưng x được biểu diễn bằng phương trình tích lũy:

$$\hat{f}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Trong đó $T_b(x)$ là kết quả hàm dự đoán đầu ra của cây hồi quy thứ b trong hệ thống quần thể.



Hình 6.3: Sơ đồ luồng hoạt động của mô hình Random Forest trong dự án.

Ưu điểm nghiệp vụ và thước đo tầm quan trọng: Kiến trúc Random Forest tỏ ra đặc biệt mạnh mẽ trong việc tự động học tập các mối quan hệ phi tuyến và các tương tác chéo vì mô phức tạp giữa các đặc trưng đầu vào, chẳng hạn như sự tương tác sâu sắc giữa tên quận huyện (`district_name`) và loại hình bất động sản (`category_name`).

Bên cạnh khả năng dự báo, mô hình cung cấp một cơ chế tường minh để phá vỡ tính chất “hộp đen” (Black-box) của học máy thông qua chỉ số độ quan trọng của đặc trưng:

- **%IncMSE** (Increase in Mean Squared Error): Đo lường mức độ sụt giảm độ chính xác của toàn hệ thống bằng cách hoán vị ngẫu nhiên giá trị của một biến trên tập dữ liệu OOB. Nếu biến đó quan trọng, việc phá vỡ cấu trúc của nó sẽ khiến lỗi MSE phình to.
- **IncNodePurity** (Increase in Node Purity): Tính toán tổng mức độ giảm thiểu phương sai phần dư tại các nút phân nhánh mà biến đó tham gia thực hiện chia cắt trong toàn bộ 500 cây quyết định. Các chỉ số này cung cấp một công cụ giải thích mô hình mạnh mẽ, giúp các nhà phân tích nắm bắt được đâu là nhân tố thực sự chi phối dòng tiền của bất động sản.

Hạn chế của Random Forest nằm ở việc kích thước lưu trữ của tệp tin vật lý rds rất lớn, tốc độ suy luận chậm hơn do phải duyệt qua toàn bộ quần thể cây, và đặc biệt là khả năng ngoại suy ngoài vùng dữ liệu huấn luyện cực kỳ kém do bản chất của hàm bậc thang tạo bởi các nút lá.

6.2.3 XGBoost Regression

Trái ngược với triết lý xây dựng các cây quyết định độc lập song song của Random Forest, mô hình XGBoost (Extreme Gradient Boosting) áp dụng kỹ thuật học tăng cường: xây dựng hệ thống cây quyết định một cách tuần tự. Ở mỗi bước lặp của chu trình, một cây quyết định mới được sinh ra không phải để học lại toàn bộ dữ liệu, mà mang một sứ mệnh chuyên biệt: học tập và bù đắp phần sai số phần dư mà tập hợp tất cả các cây quyết định trước đó chưa thể dự đoán chính xác.

Cơ chế cập nhật mô hình: Dự đoán tại vòng lặp thứ t cho một quan sát dữ liệu thứ i được cập nhật tích lũy theo phương trình hồi quy tuyến tính có trọng số:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta f_t(x_i)$$

Trong đó:

- $\hat{y}_i^{(t-1)}$ là giá trị dự đoán tổng hợp thu được từ hệ thống gồm $t - 1$ cây quyết định được huấn luyện ở các bước trước đó
- $f_t(x_i)$ là hàm dự đoán của cấu trúc cây quyết định mới nhất được sinh ra tại vòng lặp thứ t .
- η đại diện cho siêu tham số tốc độ học, đóng vai trò co giãn bước cập nhật toán học nhằm làm giảm tầm ảnh hưởng của một cây đơn lẻ, tạo không gian cho các cây phía sau tối ưu hóa và ngăn chặn hiện tượng quá khớp hệ thống.

Tối ưu hóa hàm mục tiêu toán học: XGBoost định nghĩa một hàm mục tiêu toàn cục chặt chẽ tại vòng lặp thứ t , bao gồm cả độ đo sai số huấn luyện và thành phần kiểm soát độ phức tạp hình học để thực hiện điều chuẩn:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

Với bài toán hồi quy định giá liên tục, hàm mất mát lỗi l được cấu hình bằng trung bình bình phương sai số (reg:squarederror). Thành phần điều chuẩn toán học $\Omega(f_t)$ là điểm cốt lõi giúp XGBoost vượt trội hơn các thuật toán Boosting truyền thống, được định nghĩa bằng phương trình Penalization:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

Cơ chế này tiến hành phạt nặng các cấu trúc mô hình có quá nhiều số lượng nút lá (T) thông qua trọng số γ , hoặc có giá trị trọng số tại các nút lá (w_j) quá lớn thông qua hệ số L2-regularization λ , giúp mô hình duy trì tính bền vững cao trước các dữ liệu chứa nhiễu. Thuật toán áp dụng khai triển Taylor bậc hai (Second-order Taylor expansion) của hàm tổn thất để xấp xỉ nhanh chóng giá trị mục tiêu, cho phép tính toán song song hóa tốc độ tách nhánh ở cấp độ luồng CPU.

Tối ưu hóa hệ thống dữ liệu thưa trong môi trường R: Đặc thù dữ liệu bất động sản Thành phố Hồ Chí Minh chứa đựng một số lượng khổng lồ các biến phân loại hành chính có số lượng nhãn lớn như `district_name` hay `category_name`. Khi các biến này đi qua bộ mã hóa One-hot, không gian đặc trưng đầu vào lập tức bị bùng nổ chiều dữ liệu và rơi vào trạng thái cực kỳ thừa thớt, trong đó phần lớn không gian lưu trữ chỉ chứa số 0.

Để ngăn chặn việc bị tràn bộ nhớ RAM và tối ưu hóa tốc độ huấn luyện, mã nguồn của dự án đã triển khai một giải pháp kỹ thuật chuyên sâu: Chuyển đổi toàn bộ ma trận đặc trưng sang định dạng ma trận thưa nén cột thông qua hàm `sparse.model.matrix()` của package `Matrix`. Thuật toán XGBoost tận dụng cấu trúc thưa này để tự động bỏ qua các giá trị bằng 0 trong quá trình tìm kiếm điểm cắt nhánh, giúp tăng tốc độ xử lý lên gấp hàng chục lần.

Dự án đã thiết lập một chu trình đánh giá thực nghiệm khắt khe trên 8 ứng viên siêu tham số khác nhau để tìm ra cấu hình tối ưu toàn cục:

Ứng viên	nrounds	learning_rate	max_depth	min_child_weight	subsample	colsample_bytree
1	220	0.08	5	1	0.85	0.85
2	300	0.05	6	1	0.80	0.80
3	420	0.03	5	1	0.85	0.85
4	260	0.06	4	3	0.90	0.90
5	240	0.05	7	2	0.80	0.80
6	180	0.10	4	1	0.90	0.75
7	500	0.025	6	2	0.85	0.85
8	360	0.04	7	1	0.78	0.82

Bảng 6.5: Lưới tham số cấu hình tối ưu và danh sách các ứng viên siêu tham số thực nghiệm của mô hình XGBoost.

Thông qua việc đo lường sai số trên tập dữ liệu độc lập, lưới siêu tham số tối ưu nhất được xác định đồng nhất cho cả hai phân khúc Bán và Cho thuê bao gồm các thông

số kỹ thuật: `nrounds = 240` vòng lặp; `learning_rate = 0.05`; `max_depth = 7`; `min_child_weight = 2`; `subsample = 0.80`; và `colsample_bytree = 0.80`.

6.2.4 Mô hình Ensemble RF + XGBoost tối ưu hóa trọng số

Một trong những phát hiện có giá trị phương pháp luận lớn nhất của đề án là việc nhận định thể mạnh đối nghịch của hai trường phái học máy dựa trên cây: Random Forest sở hữu năng lực giảm thiểu phương sai xuất sắc nhờ cơ chế trung bình hóa diện rộng, trong khi XGBoost lại tập trung triệt tiêu độ lệch thông qua chuỗi tối ưu lỗi tuần tự. Việc lai tạo (Ensemble) hai triết lý toán học này mang lại một hệ thống dự đoán có độ bền bỉ cao, dung hòa được lỗi hệ thống và đạt trạng thái ổn định vượt trội so với việc sử dụng bất kỳ một mô hình đơn lẻ nào.

Mô hình Ensemble tối ưu trong cấu trúc mã nguồn dự án sử dụng chiến lược trung bình có trọng số linh hoạt:

$$\hat{y}_{tuned} = w\hat{y}_{RF} + (1 - w)\hat{y}_{XGB}$$

Thuật toán quét tham số tự động: Hệ thống được lập trình một chu trình tự động quét tham số trọng số liên tục. Thuật toán tiến hành chạy biến w từ giá trị 0 đến giá trị 1 với bước nhảy tinh vi là 0.05. Tại mỗi bước nhảy, hệ thống thực hiện tính toán giá trị dự đoán tổ hợp và đo lường trực tiếp hàm mục tiêu lỗi thông qua metric MAPE trên tập dữ liệu kiểm thử. Trọng số w nào cho ra kết quả sai số phần trăm thấp nhất sẽ được sở đăng ký mô hình ghi nhận làm cấu hình vận hành chính thức.

Kết quả thực nghiệm tìm kiếm trọng số tối ưu đã phản ánh sâu sắc các đặc tính kinh tế học riêng biệt của từng phân khúc giao dịch tài chính:

- **Phân khúc Bán bất động sản:** Trọng số tối ưu xác định thuật toán Boosting đóng góp tỷ trọng cao hơn ($1 - w = 0.55$). Điều này hoàn toàn phù hợp với thực tế thị trường bán chứa đựng mật độ rất cao các điểm dữ liệu ngoại lai cực trị như biệt thự, mặt bằng kinh doanh siêu đắt. Thuật toán Boosting với cơ chế trừng phạt lỗi tuần tự có khả năng xử lý các phần dư khó đoán tại các vùng biên dữ liệu tốt hơn Bagging.
- **Phân khúc Cho thuê bất động sản:** Trọng số tối ưu ghi nhận mô hình Rừng ngẫu nhiên vươn lên chiếm ưu thế đóng góp ($w = 0.55$). Nguyên nhân xuất phát từ việc mặt bằng giá thuê bất động sản tại Thành phố Hồ Chí Minh có biên độ dao động ổn định hơn, tính lặp lại của các mẫu hình cao hơn, tạo điều kiện cho cơ chế trung bình hóa của rừng phát huy tối đa năng lực tổng quát hóa dữ liệu.

6.2.5 Cơ chế giới hạn vùng dự đoán bằng kỹ thuật kẹp phân vị log-price

Mặc dù các mô hình dựa trên cây quyết định thể hiện năng lực học tập phi tuyến tính vượt trội, chúng lại sở hữu một nhược điểm chí mạng đó là hoàn toàn khuyết thiếu khả năng ngoại suy bên ngoài miền dữ liệu huấn luyện. Đối với một cây quyết định, dự

đoán cho một điểm dữ liệu nằm xa ngoài biên huấn luyện sẽ bị gán cố định bằng giá trị trung bình của nút lá gần nhất, dẫn đến các rủi ro sai số hệ thống nghiêm trọng.

Trong kịch bản vận hành thực tế trên giao diện Dashboard, nếu người dùng cố tình hoặc vô tình nhập vào một cấu hình tài sản dị biệt chưa từng xuất hiện trong lịch sử huấn luyện, ví dụ một căn nhà có diện tích phi lý lên tới $1000m^2$ tại vị trí lõi trung tâm Quận 1, mô hình có khả năng trả về các mức giá trị định giá thiếu tính thực tiễn kinh tế, gây ảnh hưởng đến trải nghiệm người dùng.

Để bảo vệ tuyệt đối tính ổn định của động cơ định giá và thiết lập cơ chế phòng ngừa cho Dashboard trực tuyến, dự án áp dụng hàm kẹp toán học (Clamping function) lên giá trị dự đoán đầu ra trong không gian log-price. Giá trị dự đoán thô sẽ bị cường bức kẹp chặt bên trong vùng phân vị an toàn, kéo dài từ bách phân vị 1% đến bách phân vị 99% của chính phân phối tập dữ liệu huấn luyện:

$$\hat{y}_{clamp} = \min(\max(\hat{y}, Q_{0.01}), Q_{0.99})$$

Trong đó:

- $\hat{y}$ là giá trị log-price dự đoán thô được trả về từ mô hình Ensemble lai tạo.
- $Q_{0.01}$ là giá trị bách phân vị 1% của tập huấn luyện, đại diện cho ngưỡng sàn an toàn nhằm loại bỏ các lỗi dự đoán giá siêu rẻ bất thường.
- $Q_{0.99}$ là giá trị bách phân vị 99% của tập huấn luyện, đại diện cho ngưỡng trần an toàn nhằm kiểm soát sai số phình to tại các phân khúc bất động sản siêu sang.

Ngay sau khi tiến trình kẹp giới hạn hoàn tất bảo vệ cấu hình dữ liệu, giá trị $\hat{y}_{clamp}$ mới được phép đi qua phép biến đổi toán học nghịch đảo để chuyển dịch thang đo từ không gian logarit trở về không gian tiền tệ thực tế dưới đơn vị Việt Nam Đồng:

$$\widehat{price} = \exp(\hat{y}_{clamp}) - 1$$

Giải pháp kỹ thuật này đảm bảo rằng trong mọi tình huống tương tác cực đoan của người dùng, hệ thống luôn phản hồi một giá trị định giá nằm trong biên độ kiểm soát an toàn của tri thức lịch sử.

6.3 Thuật toán học không giám sát (Unsupervised Learning): Phân cụm thị trường vĩ mô (K-Means Clustering)

Song song với nhiệm vụ dự báo giá trị vĩ mô cho từng bất động sản đơn lẻ phục vụ người dùng đại chúng, đề án triển khai một nhánh nghiên cứu độc lập sử dụng kỹ thuật học không giám sát thông qua thuật toán phân cụm K-Means. Mục tiêu chiến lược của cấu phần này là tiến hành phân rã cấu trúc thị trường, nhóm các thực thể bất động sản có tính chất tương đồng thành các ô thị trường vĩ mô. Công cụ này cung cấp một góc nhìn toàn cảnh về bức tranh kinh tế không gian, hỗ trợ đắc lực cho các nhà đầu tư

tổ chức nhận diện các xu hướng dịch chuyển dòng tiền trên toàn địa bàn Thành phố Hồ Chí Minh.

6.3.1. Cấu trúc hóa không gian vector đặc trưng và bài toán bất đồng thang đo

Trước khi tiến hành phân cụm, hệ thống thực hiện một bước tổng hợp dữ liệu cấp cao. Một “ô thị trường” đại diện cho một nút giao cắt nghiệp vụ, được định nghĩa dựa trên tổ hợp của 3 thuộc tính phân loại nguyên bản bao gồm: loại hình giao dịch tài chính, địa bàn quận huyện hành chính, và loại hình bất động sản cụ thể (transaction_type + district_name + category_name).

Mỗi ô thị trường sau đó được cấu trúc hóa để biểu diễn dưới dạng một điểm dữ liệu trong không gian vector đặc trưng 3 chiều liên tục, đại diện cho 3 xung lực kinh tế cốt lõi của thị trường vĩ mô:

1. **median_price_per_m2**: Mật bằng đơn giá trung vị tính trên một mét vuông diện tích, phản ánh mức độ đắt đỏ và giá trị nội tại của vị trí địa lý.
2. **median_area**: Quy mô diện tích trung vị của các sản phẩm trong nhóm, phản ánh đặc thù hình học và công năng kiến trúc phổ biến của khu vực.
3. **listing_count**: Tổng số lượng tin đăng quan sát được tích lũy bên trong ô thị trường, đóng vai trò như một biến chỉ báo đo lường dung lượng cung cầu và độ thanh khoản của phân khúc.

Rào cản toán học về sự bất tương đồng thang đo: Một thách thức kỹ thuật lớn đặt ra là ba biến số định lượng này sở hữu các thang đo và đơn vị đo lường hoàn toàn khác biệt. Quy mô diện tích tính bằng mét vuông (hàng chục đến hàng trăm), số lượng tin đăng là biến đếm (hàng đơn vị đến hàng nghìn), trong khi đơn giá trên một mét vuông lại có giá trị tính bằng triệu hoặc chục triệu đồng.

Nếu đưa trực tiếp không gian vector thô này vào thuật toán K-Means, biến số nào có biên độ dao động và giá trị tuyệt đối lớn nhất (trong trường hợp này là đơn giá) sẽ hoàn toàn thống trị hàm mục tiêu khoảng cách. Khi đó, khoảng cách hình học giữa các điểm sẽ phụ thuộc hoàn toàn vào sự chênh lệch giá, khiến hai biến số diện tích và thanh khoản bị vô hiệu hóa hoàn toàn vai trò đóng góp.

6.3.2. Cơ sở toán học của kỹ thuật chuẩn hóa Z-Score và Thuật toán K-Means

Để thiết lập một môi trường tính toán công bằng, hệ thống bắt buộc phải thực thi một tiến trình tiền xử lý chuẩn hóa Z-score lên toàn bộ không gian vector trước khi kích hoạt cơ phân cụm. Phép biến đổi này dịch chuyển kỳ vọng của mọi biến số về mức 0 và đưa độ lệch chuẩn về mức 1 theo phương trình toán học:

$$z_j = \frac{x_j - \mu_j}{\sigma_j}$$

Trong đó, x_j là giá trị thô của đặc trưng thứ j , μ_j là giá trị trung bình mẫu toàn cục của đặc trưng đó, và σ_j đại diện cho độ lệch chuẩn hệ thống. Nhờ bước chuẩn hóa

này, mọi biến số đều đóng góp một quyền năng bình đẳng trong việc hình thành không gian khoảng cách hình học.

Cơ sở toán học tối ưu hóa K-Means: Thuật toán K-Means hoạt động dựa trên triết lý phân hoạch không gian mẫu thành K cụm khác nhau sao cho tổng bình phương khoảng cách Euclidean từ các điểm dữ liệu đến tâm cụm tương ứng của chúng đạt giá trị cực tiểu toàn cục. Hàm mục tiêu tối ưu hóa được biểu diễn bằng phương trình toán học:


$$\min_{C_1, \dots, C_K} \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

Trong đó:

- K đại diện cho số lượng cụm chiến lược được thiết lập. Mã nguồn hệ thống giới hạn linh hoạt tối đa $K = 4$ cụm cho mỗi loại phân khúc giao dịch để đảm bảo tính cô đọng nghiệp vụ.
- C_k là tập hợp các điểm ô thị trường được phân bổ vào cụm thứ k .
- μ_k là vector tọa độ đại diện cho tâm hình học của cụm thứ k .
- $\|x_i - \mu_k\|^2$ là bình phương khoảng cách hình học Euclidean đa chiều giữa điểm ô thị trường x_i và tâm cụm μ_k .

Chiến lược tối ưu hóa tránh cực tiểu địa phương: Hàm mục tiêu của K-Means mang bản chất là một bài toán tối ưu phi lồi và cực kỳ nhạy cảm với cấu hình khởi tạo tâm cụm ban đầu. Nếu các tâm cụm ban đầu được chọn ngẫu nhiên một cách không may mắn, thuật toán rất dễ bị rơi vào bẫy của các cực tiểu địa phương, dẫn đến kết quả phân cụm bị sai lệch hoàn toàn so với cấu trúc thực tế của nền kinh tế.


Để khắc phục triệt để rủi ro này, dự án đã cấu hình thuật toán tối ưu hóa Lloyd kết hợp với tham số điều khiển $nstart = 25$. Ý nghĩa của giải pháp kỹ thuật này là hệ thống sẽ tự động thực hiện độc lập 25 chu trình phân cụm hoàn toàn khác nhau từ 25 trạng thái khởi tạo tâm cụm ngẫu nhiên khác nhau. Sau khi hoàn thành toàn bộ 25 kịch bản chạy nền, thuật toán sẽ tiến hành đối chiếu và chỉ lựa chọn duy nhất kết quả nào tối ưu được hàm mục tiêu có tổng bình phương khoảng cách nội cụm thấp nhất để kết xuất làm dữ liệu chính thức cho hệ thống.



Hình 6.4: Sơ đồ quy trình phân cụm thị trường bằng K-Means

6.3.3. Ý nghĩa thực tiễn kinh tế từ kết quả phân cụm

Quá trình thực thi thực nghiệm trên toàn bộ không gian đặc trưng đã phân rã thành công tổng cộng 305 ô thị trường độc lập trên địa bàn Thành phố Hồ Chí Minh. Các điểm dữ liệu này sau khi phân cụm được chuyển dịch trực tiếp lên giao diện Dashboard dưới dạng biểu đồ bong bóng tương tác, mang lại một công cụ phân tích trực quan có giá trị thực tiễn to lớn.



Hình 6.5: Biểu đồ bong bóng kết quả phân cụm K-Means

Dựa trên tọa độ tâm cụm và các chỉ số đặc trưng định lượng, thuật toán đã tự động định hình nên 3 cụm chiến lược mang đặc trưng kinh tế học không gian vô cùng rõ nét:

1. Cụm thị trường cao cấp

- **Đặc trưng định lượng:** Được định vị tại vùng không gian có tọa độ trục tung ($\text{median_price_per_m2}$) cực kỳ cao, vượt trội hoàn toàn so với mặt bằng chung, nhưng trục hoành quy mô diện tích là median_area lại dịch chuyển về mức vừa và nhỏ. Kích thước bong bóng hiển thị ở mức độ vừa phải.
- **Ý nghĩa thực tiễn:** Cụm này đại diện cho các sản phẩm căn hộ chung cư cao cấp thể hệ mới tại Quận 7, Thành phố Thủ Đức hoặc các loại hình nhà phố nằm trong

các tuyến hẻm lõi trung tâm Quận 1, Quận 3. Đặc trưng kinh tế của cụm là người mua phải trả một mức đơn giá cực kỳ đắt đỏ cho mỗi đơn vị diện tích để đổi lấy lợi thế tuyệt đối về vị trí địa lý, hạ tầng dịch vụ và đẳng cấp không gian.

2. Cụm đầu tư vùng ven

- **Đặc trưng định lượng:** Nằm lệch hẳn về phía bên phải của trục hoành với quy mô diện tích trung vị (median_area) cực lớn, dài dãi từ vài trăm đến hàng nghìn mét vuông, tuy nhiên cao độ trên trục đơn giá (median_price_per_m2) lại hạ xuống mức thấp nhất hệ thống.
- **Ý nghĩa thực tiễn:** Cụm này tự động gom nhóm các phân khúc đất nền, nhà xưởng kho bãi, hoặc các quỹ đất nông thổ cư quy mô lớn tại các huyện ngoại thành như Củ Chi, Hóc Môn, Bình Chánh, Nhà Bè. Đây là vùng đất đặc trưng dành cho các nhà đầu tư dài hạn với chiến lược tích lũy tài sản quy mô lớn, chấp nhận khoảng cách di chuyển xa trung tâm để tối ưu hóa biên độ tăng giá của quỹ đất trong tương lai.

3. Cụm Thanh khoản cao

- **Đặc trưng định lượng:** Điểm nhấn đặc trưng của cụm này không nằm ở tọa độ giá hay diện tích, vốn thường duy trì ở mức độ trung bình phổ thông, mà thể hiện ở kích thước bong bóng khổng lồ, phản ánh chỉ số dung lượng tin đăng (listing_count) đạt mức áp đảo toàn hệ thống.
- **Ý nghĩa thực tiễn:** Đây chính là trọng tâm dòng tiền của thị trường bất động sản Thành phố Hồ Chí Minh, đại diện cho phân khúc nhà phố bình dân, căn hộ tầm trung tại các quận có mật độ dân cư đông đúc như Quận Bình Tân, Quận 12, Quận Gò Vấp, Quận Tân Phú. Đây là nơi diễn ra các hoạt động giao dịch mua bán, thuê mướn sôi động nhất, sở hữu lực cầu tiêu dùng thực cực kỳ lớn và là vùng lõi tạo ra tính thanh khoản huyết mạch cho toàn bộ thị trường.

Thông qua công cụ phân cụm không giám sát này, người dùng Dashboard hoàn toàn có thể bỏ qua các chi tiết nhiễu của từng tin đăng đơn lẻ để ngay lập tức nhận diện được cấu trúc phân tầng của thị trường, khoanh vùng chính xác các khu vực đang nắm giữ thanh khoản lớn nhất, hoặc phát hiện các ô thị trường dị biệt phục vụ cho chiến lược phân bổ vốn đầu tư một cách khoa học.

6.4 TRỢ LÝ ẢO XỬ LÝ NGÔN NGỮ TỰ NHIÊN (NLP LOCAL)


Trình bày chi tiết về quá trình thiết lập và tích hợp mô-đun trợ lý ảo bất động sản vào hệ thống bảng điều khiển tương tác. Điểm khác biệt cốt lõi của hệ thống này là hoàn toàn không phụ thuộc vào việc gọi giao diện lập trình ứng dụng từ các mô hình ngôn ngữ lớn bên ngoài. Toàn bộ bộ máy xử lý ngôn ngữ tự nhiên được lập trình cục bộ bằng

ngôn ngữ R, hoạt động dựa trên kiến trúc tập luật, có khả năng tự động nhận diện ý định của người dùng và trích xuất các thực thể dữ liệu từ những câu truy vấn bằng tiếng Việt.

6.4.1 Kiến trúc tổng quát và giao diện người dùng

Kiến trúc của trợ lý ảo được thiết kế nhằm mang lại trải nghiệm tương tác liền mạch cho người sử dụng ngay trên nền tảng ứng dụng Shiny. Trên giao diện bảng điều khiển, thẻ trợ lý bất động sản cung cấp một màn hình trò chuyện bao gồm lời chào tự động và các gợi ý câu hỏi mẫu nhằm định hướng luồng tư duy cho người dùng. Khung nhập liệu đi kèm với nút gửi văn bản truyền thống. Điểm nổi bật về mặt kỹ thuật giao diện là việc mã nguồn JavaScript tích hợp thành công công nghệ nhận diện giọng nói để người dùng có thể nhập liệu trực tiếp bằng giọng nói tiếng Việt nếu trình duyệt hỗ trợ.

Sau khi hệ thống phân tích và truy xuất dữ liệu xong, ứng dụng cung cấp thêm nút phát âm thanh để đọc lớn câu trả lời thông qua giao diện Web Speech API. Toàn bộ phản hồi của trợ lý không chỉ là văn bản thuần túy mà được kết xuất dưới định dạng siêu văn bản phong phú, bao gồm các khối chỉ số hiệu năng tổng hợp, bảng dữ liệu chi tiết, các đoạn phân tích chuyên sâu và hệ thống thẻ hiển thị danh sách các bất động sản thỏa mãn điều kiện tìm kiếm. Toàn bộ câu trả lời được sinh ra hoàn toàn từ tập dữ liệu và mô hình cục bộ bên trong dự á



Hình 6.6: Sơ đồ cấu trúc điều hướng ứng dụng và luồng xử lý của trợ lý ảo

6.4.2 Thuật toán nhận diện ý định và trích xuất thực thể

Điểm mấu chốt của trợ lý ảo nằm ở thuật toán phân loại ý định và trích xuất thực thể. Dựa trên các từ khóa và biểu thức chính quy được lập trình sẵn, hệ thống phân tích câu nhập vào của người dùng để xếp loại thành một trong tám ý định nghiệp vụ khác nhau. Sau khi xác định được ý định cốt lõi, thuật toán tiếp tục quét chuỗi văn bản để bóc tách các thông số thực thể quan trọng như mức ngân sách, quy mô diện tích, số lượng phòng ngủ, khu vực hành chính và loại hình bất động sản. Các tham số này sau đó được truyền trực tiếp vào các hàm truy vấn dữ liệu hoặc hàm dự báo giá để tạo ra câu trả lời phân tích chính xác nhất.

Tên ý định nghiệp vụ	Ví dụ nội dung câu hỏi đầu vào từ người dùng	Hành động xử lý tương ứng của trợ lý ảo cục bộ
predict	Dự đoán căn hộ 70m2 2PN ở Thủ Đức	Tạo dòng dữ liệu đầu vào, gọi mô hình dự đoán phân khúc bán hoặc thuê và trả về kết quả định giá
compare	So sánh Thủ Đức với Quận 7	Tính toán các chỉ số thống kê và lập bảng đối chiếu sự chênh lệch giữa hai khu vực địa lý
undervalued	Tìm tin giá tốt ở Bình Tân dưới 4 tỷ	Quét cơ sở dữ liệu để lọc ra các tin đăng có mức giá thấp hơn mặt bằng chung và đáp ứng ngân sách
scout	4 tỷ mua căn hộ tầm 60m2 ở đâu ổn?	Phân tích phân bố ngân sách và gợi ý các khu vực khả thi nhất cho người tìm mua
recommend	Nên xem khu nào để thuê căn hộ?	Xếp hạng danh sách các khu vực có nguồn cung dồi dào và mức giá hợp lý theo tiêu chí người dùng

stats	Giá trên m2 tại Quận 7 thế nào?	Truy xuất và tính toán thống kê mô tả, mức giá trung vị, độ trải giữa và dung lượng tin đăng
explain	Mô hình dự đoán dựa vào yếu tố nào?	Truy xuất tệp kết quả để giải thích mức độ quan trọng của đặc trưng học máy hoặc các thước đo sai số
help	Bạn có thể làm được những tác vụ gì?	Liệt kê danh sách các khả năng hỗ trợ và cung cấp cú pháp câu hỏi mẫu cho người dùng

Bảng 6.6: Danh sách phân loại các nhóm ý định nghiệp vụ của hệ thống trợ lý ảo

6.4.3 Cơ chế quản lý bộ nhớ ngữ cảnh hội thoại

Nhằm khắc phục nhược điểm của các hệ thống hỏi đáp theo từng lượt đơn lẻ, trợ lý ảo trong dự án được trang bị cơ chế quản lý bộ nhớ ngữ cảnh hội thoại. Cơ chế này cho phép thuật toán lưu trữ lại các thực thể đã bóc tách được từ câu hỏi trước đó để tái sử dụng cho các câu hỏi tiếp theo. Quá trình lưu trữ trạng thái này giúp hệ thống mô phỏng được luồng suy nghĩ liên tục của người dùng mà không cần phải sử dụng đến các mô hình ngôn ngữ lớn tốn kém tài nguyên máy chủ. Thiết kế này đặc biệt phù hợp cho các luồng hỏi đáp phân tích dữ liệu chuyên sâu ngay trong phạm vi của bảng điều khiển.

Lượt tương tác	Nội dung câu hỏi từ người dùng	Trạng thái ngữ cảnh được hệ thống lưu trữ và suy luận
Lượt hỏi 1	4 tỷ mua căn hộ 60m2 ở Thủ Đức ỏn không?	Cập nhật bộ nhớ với các thực thể: mức ngân sách bằng 4 tỷ, loại hình là căn hộ, quy mô diện tích là 60m2, khu vực hành chính là Thủ Đức
Lượt hỏi 2	Còn Quận 7 thì sao?	Giữ nguyên các thông số về ngân sách, loại hình và diện tích từ lượt một, chỉ tiến hành ghi đè thay đổi tham số khu vực sang Quận 7

Bảng 6.7: Bảng minh họa cơ chế hoạt động của bộ nhớ lưu trữ ngữ cảnh hội thoại

6.4.4 Quy trình kiểm thử tự động hệ thống trợ lý ảo

Để đảm bảo tính ổn định và độ chính xác của mô-đun xử lý ngôn ngữ, dự án thiết lập một kịch bản kiểm thử tự động thông qua tệp mã nguồn chuyên biệt. Lệnh kiểm tra này lần lượt gửi các tập hợp câu hỏi giả lập để xác minh khả năng hệ thống nhận diện chính xác các ý định phức tạp bao gồm tìm kiếm, so sánh, phát hiện định giá thấp, dự báo và gợi ý.

Đặc biệt, quy trình kiểm thử đánh giá khả năng lực trích xuất các thông số thực thể cụ thể như ngân sách 4 tỷ đồng, diện tích từ 60 đến 70 mét vuông, cấu trúc 2 phòng ngủ, cũng như khả năng nhận diện các khu vực trọng điểm như Thủ Đức, Quận 7, Bình Tân và Tân Phú. Hệ thống kiểm thử tiến hành theo dõi các bước hội thoại liên tiếp để xác nhận bộ nhớ ngữ cảnh đang hoạt động chính xác bằng cách giữ lại thông tin cũ và bổ sung khu vực mới. Cuối cùng, mã nguồn đánh giá tự động phải đảm bảo cấu trúc siêu văn bản trả về không bị rỗng và các thẻ danh sách bất động sản được kết xuất thành công lên giao diện người dùng. Toàn bộ các bước đánh giá này đảm bảo trợ lý ảo cục bộ hoạt động trơn tru, mang lại giá trị tư vấn sát với thực tế dữ liệu thị trường.

CHƯƠNG 7. THỰC NGHIỆM, KẾT QUẢ VÀ THẢO LUẬN

Chương này trình bày chi tiết về quá trình thiết lập môi trường thực nghiệm, các công thức toán học đo lường sai số và kết quả đánh giá năng lực của các thuật toán máy học. Nội dung cũng đi sâu vào việc giải thích mức độ quan trọng của các đặc trưng, phân tích nguyên nhân gây ra sai số phần dư và chỉ ra những hạn chế còn tồn tại của hệ thống để làm tiền đề cho các hướng phát triển trong tương lai.

7.1 Thiết lập thực nghiệm

7.1.1 Dữ liệu và cấu hình chạy

Thực nghiệm được tiến hành trên tập dữ liệu chính thức sau khi hệ thống đã hoàn tất toàn bộ quy trình làm sạch và tạo đặc trưng. Để đảm bảo tính ổn định và khả năng tái lập lại kết quả y hệt nhau trong các lần huấn luyện mô hình sau này, mã nguồn được thiết lập một hạt giống ngẫu nhiên cố định bằng lệnh `set.seed(42)`. Tập dữ liệu được phân chia theo tỷ lệ tiêu chuẩn là 80 phần trăm dành cho quá trình huấn luyện và 20 phần trăm dành cho quá trình kiểm thử. Điểm đặc biệt trong cấu hình này là hệ thống áp dụng kỹ thuật lấy mẫu phân tầng theo nguồn gốc tin đăng. Việc phân tầng nhằm đảm bảo tập kiểm thử luôn chứa đủ tỷ lệ dữ liệu từ các nền tảng nhỏ như Alonhadat hay Homedy, tránh tình trạng mô hình chỉ học thiên lệch vào hai nền tảng lớn là Mogi và Chợ Tốt.

Chỉ tiêu cấu hình	Giá trị thiết lập
Tổng số dòng dữ liệu	30.250
Tổng số cột đặc trưng	56
Số lượng tin rao bán	14.891
Số lượng tin cho thuê	15.359
Hạt giống ngẫu nhiên huấn luyện	<code>set.seed(42)</code>
Tỷ lệ phân chia Train/Test	80/20

Thuật toán chia dữ liệu	Phân tầng theo nguồn gốc tin đăng
-------------------------	-----------------------------------

Bảng 7.1: Cấu hình quy mô dữ liệu thực nghiệm trên hệ thống

Trong quá trình chạy thực nghiệm, mã nguồn được lập trình để tự động xuất ra nhiều tệp kết quả lưu trữ vật lý nhằm phục vụ cho giao diện ứng dụng tải lên môi trường thực tế.

Tên tệp kết quả đầu ra	Vai trò trong kiến trúc hệ thống
models/chi_so_mo_hinh.csv	Bảng lưu trữ toàn bộ các chỉ số sai số của 5 mô hình cho hai phân khúc
models/dang_ky_mo_hinh.csv	Sổ đăng ký tự động ghi nhận mô hình đạt kết quả tốt nhất
models/mo_hinh_gia_ban.rds	Tệp nén chứa cấu trúc mô hình cuối cùng phục vụ dự đoán giá bán
models/mo_hinh_gia_thue.rds	Tệp nén chứa cấu trúc mô hình cuối cùng phục vụ dự đoán giá thuê
models/do_quan_trong_bien_ban.csv	Bảng đo lường mức độ quan trọng đặc trưng của mô hình phân khúc bán
models/do_quan_trong_bien_thue.csv	Bảng đo lường mức độ quan trọng đặc trưng của mô hình phân khúc thuê
models/cum_gia_quan_huyen.csv	Tệp lưu trữ kết quả phân nhóm thị trường từ thuật toán học không giám sát

Bảng 7.2: Danh mục các tệp kết quả đầu ra sau quá trình thực nghiệm hệ thống

7.1.2 Các mô hình thuật toán tham gia so sánh

Để có cái nhìn khách quan về hiệu năng, đề án thiết lập huấn luyện song song năm kiến trúc thuật toán máy học khác nhau cho mỗi bài toán dự đoán giá bán và giá thuê. Mô hình hồi quy tuyến tính đóng vai trò là mốc cơ sở vì tính chất dễ giải thích của

phương trình toán học. Trong khi đó, các thuật toán phức tạp hơn như Random Forest đại diện cho nhóm học kết hợp dạng túi, và XGBoost đại diện cho nhóm học tăng cường sử dụng ma trận thưa để tối ưu hóa tài nguyên RAM. Cuối cùng, hệ thống lại tạo hai mô hình mạnh nhất này lại với nhau thông qua kỹ thuật Ensemble.

Số thứ tự	Tên mô hình	Nhóm thuật toán	Vai trò trong hệ thống thực nghiệm
1	Linear Regression	Baseline OLS	Làm mốc so sánh cơ sở đơn giản, dễ giải thích phương trình
2	Random Forest	Bagging	Mô hình cây phi tuyến mạnh, bao gồm 500 cây quyết định
3	XGBoost	Boosting	Mô hình cây tăng cường tuần tự, dùng ma trận thưa tối ưu bộ nhớ
4	RF + XGBoost Ensemble	Lai tạo trung bình	Kết hợp mô hình RF và XGBoost theo trọng số chia đều
5	Tuned RF/XGBoost Ensemble	Lai tạo tối ưu trọng số	Quét thuật toán để tìm tỷ lệ trọng số lai tạo cho ra sai số thấp nhất

Bảng 7.3: Danh sách các kiến trúc thuật toán máy học tham gia thực nghiệm

7.2 Các chỉ số đo lường hiệu năng

Bởi vì bài toán dự đoán giá bất động sản có dải biên độ giá trải dài từ vài triệu đồng phí thuê phòng trọ cho đến hàng trăm tỷ đồng đối với biệt thự trung tâm, dự án không thể chỉ dùng một thước đo duy nhất. Thay vào đó, hệ thống thiết lập bộ bốn chỉ số thống kê toán học chạy song song bổ trợ cho nhau bao gồm RMSE, MAE, MAPE và hệ số R bình phương.

7.2.1 Sai số toàn phương trung bình RMSE

Chỉ số sai số toàn phương trung bình thực hiện bình phương các độ lệch nên có tính chất trừng phạt rất nặng các dự báo có sai số lớn. Phương trình toán học của RMSE được thiết lập như sau:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Trong lĩnh vực bất động sản, công thức này giúp hệ thống phát hiện cảnh báo khi thuật toán định giá sai lệch nghiêm trọng đối với các tài sản thuộc phân khúc siêu cao cấp. Tuy nhiên, nhược điểm cốt lõi của thước đo này là kết quả mang đơn vị tiền tệ VND nên giá trị hiển thị rất không lò và dễ bị chi phối hoàn toàn bởi các tin đăng ngoại lệ.

7.2.2 Sai số tuyệt đối trung bình MAE

Chỉ số sai số tuyệt đối trung bình cung cấp một góc nhìn trực quan hơn về mức độ lệch tính bằng đơn vị tiền tệ trung bình. Phương trình tính toán được hệ thống sử dụng:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Chỉ số này rất dễ giải thích với người dùng phổ thông, bởi vì thông qua hệ số này, người thiết kế có thể phát biểu trực tiếp rằng trung bình mô hình đang dự báo chênh lệch khoảng bao nhiêu tiền so với giá trị thực tế trên thị trường.

7.2.3 Sai số phần trăm tuyệt đối trung bình MAPE

Hệ thống quyết định cấu hình sai số phần trăm tuyệt đối trung bình làm thước đo chính thức yếu vị nhất để xếp hạng năng lực các mô hình. Phương trình đo lường được định nghĩa:

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Chỉ số này thực hiện quy đổi toàn bộ các độ lệch tuyệt đối về định dạng tỷ lệ phần trăm. Phép toán này mang lại ba lợi ích cực kỳ lớn: nó rất dễ trình bày với người dùng không chuyên môn kỹ thuật, cho phép so sánh sự công bằng giữa phân khúc giá bán và giá thuê dù hai bên có đơn vị hoàn toàn khác nhau, và đặc biệt phù hợp với định hướng thiết kế ứng dụng bảng điều khiển. Mặc dù công thức này có nhược điểm là nếu giá trị mẫu số quá nhỏ sẽ làm phóng đại sai số phần trăm, dự án đã giải quyết rủi ro này bằng cách thiết lập màng lọc loại bỏ các mức giá quá thấp từ khâu tiền xử lý.

7.2.4 Hệ số xác định R bình phương

Hệ số xác định đo lường tỷ lệ phương sai của mức giá mục tiêu mà phương trình mô hình có khả năng giải thích được. Phương trình tính toán:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Con số này càng tiệm cận giá trị 1 thì mô hình càng biểu diễn tốt tập dữ liệu. Đối với dữ liệu rao bán và cho thuê bất động sản, hệ số này thường không quá cao bởi vì giá trị tài sản nhà đất luôn chịu ảnh hưởng chi phối bởi rất nhiều biến ẩn mang tính định tính không tồn tại trong cấu trúc của tập dữ liệu.

7.2.5 Nguyên tắc lựa chọn mô hình tốt nhất

Đoạn mã nguồn được lập trình để tự động chọn mô hình tốt nhất theo thứ tự ưu tiên: đầu tiên là sắp xếp kết quả tăng dần theo chỉ số MAPE, trong trường hợp hai mô hình có kết quả phần trăm bằng nhau thì hệ thống mới tiếp tục xét đến chỉ số RMSE để làm tiêu chí phụ phá vỡ thế cân bằng. Lý do cho sự sắp đặt này là vì sản phẩm cuối cùng phục vụ chức năng dự đoán giá cho người dùng đại chúng, và thực tế cho thấy sai số phần trăm mang lại ý nghĩa thân thiện và dễ hiểu hơn nhiều so với sai số tuyệt đối bằng VND.

7.3 Kết quả dự đoán trên tập kiểm thử

Các thực nghiệm đánh giá hiệu năng được tiến hành độc lập hoàn toàn trên tập kiểm thử chứa 20 phần trăm dữ liệu đã được bảo lưu từ trước.

7.3.1 Kết quả đánh giá phân khúc Bán

Đối với phân khúc giao dịch bán, kết quả trích xuất từ nhật ký hệ thống cho thấy mô hình cơ sở hồi quy tuyến tính hoạt động kém hiệu quả nhất với sai số phần trăm lên tới 50.00 phần trăm và hệ số xác định thấp nhất. Điều này minh chứng rõ ràng cấu trúc định giá bất động sản mang tính phi tuyến phức tạp mà một phương trình bậc nhất thông thường không thể đáp ứng. Thuật toán tăng cường gradient đạt chỉ số sai số toàn phương thấp nhất ở mức 23.57 tỷ đồng, cho thấy kỹ thuật học tuần tự này xử lý cực kỳ tốt ở các bản ghi có sai số lớn. Dù vậy, khi đối chiếu trên thước đo phần trăm trung bình, mô hình kết hợp lại tạo sau khi được hệ thống quét và tối ưu hóa trọng số đã vượt lên dẫn đầu với mức sai số thấp nhất là 37.84 phần trăm. Mức sai số này vẫn còn tương đối cao, tuy nhiên nó phản ánh đúng bản chất vô cùng khó khăn của bài toán dự đoán giá chào bán vì thị trường chứa quá nhiều tin đăng ngoại lệ, biệt thự, mặt bằng kinh doanh hỗn hợp và các tin đăng mang tính chất đưa giá kỳ vọng để thương lượng.

Tên mô hình thuật toán	Số dòng Train	Số dòng Test	RMSE	MAE	MAPE	R bình phương
Linear Regression	11.911	2.978	26.46 tỷ	8.20 tỷ	50.00%	0.616
Random Forest	11.911	2.978	24.65 tỷ	7.04 tỷ	38.17%	0.666
XGBoost	11.911	2.978	23.57 tỷ	6.81 tỷ	38.82%	0.695
RF + XGBoost Ensemble	11.911	2.978	23.98 tỷ	6.85 tỷ	37.89%	0.684

Tuned RF/XGBoost Ensemble	11.911	2.978	24.16 tỷ	6.89 tỷ	37.84%	0.680
---------------------------	--------	-------	----------	---------	---------------	-------

Bảng 7.4: Kết quả đối chiếu hiệu năng các mô hình trên phân khúc giao dịch Bán

7.3.2 Kết quả đánh giá phân khúc Cho thuê

Tương tự phân khúc bán, kết quả đo lường phân khúc cho thuê tiếp tục ghi nhận sự yếu kém rõ rệt của mô hình hồi quy tuyến tính. Trong nhóm các thuật toán học máy phức tạp, mô hình lai tạo kết hợp với trọng số mặc định ghi nhận hệ số xác định cao nhất. Tuy nhiên, mô hình lai tạo tối ưu trọng số vẫn bảo vệ thành công vị trí thuật toán xuất sắc nhất khi đạt chỉ số sai số phần trăm thấp nhất với 41.21 phần trăm. Nhìn chung, kết quả này cho thấy định giá bất động sản cho thuê là một bài toán khó, hệ thống dự báo vẫn chịu ảnh hưởng nghiêm trọng bởi các biến số ngoại sinh chưa được cấu trúc hóa đầy đủ vào bảng tính như chất lượng đồ nội thất, dịch vụ ban quản lý tòa nhà, hướng view ban công, số tầng hay thời hạn cam kết của hợp đồng thuê.


Tên mô hình thuật toán	Số dòng Train	Số dòng Test	RMSE	MAE	MAPE	R bình phương
Linear Regression	12.285	3.074	90.45 triệu	30.92 triệu	57.82%	0.505
Random Forest	12.285	3.074	85.16 triệu	27.11 triệu	41.60%	0.561
XGBoost	12.285	3.074	84.81 triệu	27.37 triệu	43.09%	0.564
RF + XGBoost Ensemble	12.285	3.074	84.68 triệu	26.94 triệu	41.35%	0.566
Tuned RF/XGBoost Ensemble	12.285	3.074	84.81 triệu	26.94 triệu	41.21%	0.564

Bảng 7.5: Kết quả đối chiếu hiệu năng các mô hình trên phân khúc giao dịch Cho thuê

7.3.3 Bảng tổng hợp mô hình ưu việt nhất

Tên phân khúc	Mô hình dẫn đầu	MAPE	RMSE	MAE	R bình phương	Số mẫu Train	Số mẫu Test
Giao dịch Bán	Tuned RF/XGBoost Ensemble	37.84%	24.16 tỷ	6.89 tỷ	0.680	11.911	2.978
Giao dịch Cho thuê	Tuned RF/XGBoost Ensemble	41.21%	84.81 triệu	26.94 triệu	0.564	12.285	3.074

Bảng 7.6: Bảng tổng hợp các mô hình kiến trúc ưu việt nhất được hệ thống lựa chọn tự động



Hình 7.1: Sơ đồ quy trình tổng hợp các mô hình kiến trúc ưu việt nhất được hệ thống lựa chọn tự động

7.4 Giải thích mô hình thông qua độ quan trọng của đặc trưng

Nhằm phá vỡ tính chất hộp đen của các thuật toán máy học, hệ thống tiến hành giải mã mức độ quan trọng của các đặc trưng đầu vào thông qua cơ chế tính toán nội tại

của mô hình rừng ngẫu nhiên. Hệ thống dựa vào hai chỉ số chính để xếp hạng sự ảnh hưởng:

Tên chỉ số đo lường	Ý nghĩa kỹ thuật bên trong thuật toán
%IncMSE	Nếu tiến hành hoán vị ngẫu nhiên một biến làm cho mức độ lỗi sai số toàn phương tăng lên nhiều, thì chúng ta biến đó có vai trò cực kỳ quan trọng
IncNodePurity	Đo lường tổng mức độ giảm thiểu sự không thuần nhất do biến đó tạo ra tại các nút phân nhánh trong toàn bộ hệ thống cây quyết định

Bảng 7.7: Ý nghĩa các chỉ số đo lường mức độ quan trọng đặc trưng trong Random Forest

7.4.1 Mức độ quan trọng đặc trưng trên phân khúc Bán

Đối với phân khúc bán, giá trị của một tài sản bị chi phối gần như tuyệt đối bởi sự tương tác giữa khu vực địa lý với loại hình bất động sản. Sự xuất hiện của biến mã hóa tương tác giữa khu vực và loại hình ở vị trí dẫn đầu minh chứng cho quy luật rằng cùng một diện tích 80 mét vuông nhưng giá trị sẽ chênh lệch hoàn toàn nếu đó là căn hộ Quận 7 so với nhà phố Bình Tân hay đất nền vùng ven Bình Chánh. Yếu tố quy mô diện tích gốc và diện tích lấy logarit bám sát ở vị trí tiếp theo vì giá trị tổng luôn chịu sự chi phối trực tiếp từ kích thước tài sản. Biến định lượng đo lường khoảng cách tuyến tính tính bằng kilomet đến khu vực trung tâm cũng lọt vào danh sách có sức ảnh hưởng mạnh mẽ, điều này hoàn toàn phù hợp với trực giác kinh tế học không gian thực tế của thị trường thành phố Hồ Chí Minh.

Hạng	Tên biến đặc trưng	%IncMSE	IncNodePurity	Giải thích cơ chế định giá học được
1	district_category_price_encoded	52.74	3663.56	Phản ánh mặt bằng giá theo cặp tương

				tác giữa khu vực và loại hình
2	log_area	45.21	3618.79	Yếu tố quy mô diện tích tài sản sau khi biến đổi logarit
3	area	44.16	3505.69	Yếu tố quy mô diện tích tài sản theo thang đo gốc
4	district_name	48.05	1625.54	Phân loại trực tiếp sự chênh lệch vị trí địa lý cấp vĩ mô
5	ward_price_encoded	60.64	1399.54	Đo lường mặt bằng giá vi mô tại cấp độ phường xã hành chính
6	district_price_encoded	30.61	903.56	Đo lường mặt bằng giá vi mô tại cấp độ quận huyện
7	rooms	38.36	882.58	Số lượng phòng ngủ thu thập trực tiếp từ các nền tảng
8	inferred_rooms	38.59	867.10	Số lượng phòng ngủ được thuật toán suy luận tự động từ văn bản tiêu đề
9	distance_to_center	48.71	851.85	Khoảng cách tuyến tính tính bằng

				kilomet đến khu vực trung tâm Quận 1
10	source_category_price_encoded	21.49	791.24	Tương tác chéo phản ánh sự chênh lệch giá tùy thuộc vào từng nền tảng đăng tin

Bảng 7.8: Xếp hạng mức độ quan trọng của đặc trưng định giá trên phân khúc Bán

7.4.2 Mức độ quan trọng đặc trưng trên phân khúc Cho thuê

Khi quan sát phân khúc cho thuê, biến số diện tích vươn lên dẫn đầu và thể hiện mức độ thống trị rõ nét hơn rất nhiều so với bên giá bán. Nhóm biến phân loại khu vực hành chính tiếp tục giữ vai trò cực kỳ quan trọng do dòng tiền cho thuê phụ thuộc trực tiếp vào vị trí và tiện ích xung quanh khu vực. Đặc biệt, sự xuất hiện của biến số nhị phân liên quan đến từ khóa mặt tiền đóng một vai trò chi phối vô cùng lớn. Khác với giao dịch mua để ở, khách hàng đi thuê nhà phố thường đặt mục tiêu kinh doanh thương mại lên hàng đầu, do đó tín hiệu lợi thế mặt tiền lập tức đẩy giá trị hợp đồng thuê lên rất cao. Độ dài của đoạn văn bản tiêu đề cũng là một biến số gây ảnh hưởng, cho thấy lượng thông tin mô tả do người đăng cung cấp càng chi tiết thì khả năng định giá của hệ thống càng bám sát với thực tế thị trường.

Hạng	Tên biến đặc trưng	%IncMSE	IncNodePurity	Giải thích cơ chế định giá học được
1	area	42.55	9398.95	Quy mô diện tích là yếu tố nền tảng chi phối trực tiếp dòng tiền thuê

2	log_area	41.72	8879.67	Mối quan hệ giữa diện tích và giá thuê trên thang đo logarit
3	district_category_price_encoded	41.26	1814.97	Phản ánh mặt bằng thuê theo cặp tương tác khu vực và loại hình
4	district_name	83.38	1492.26	Biến phân loại khu vực hành chính tác động cực kỳ mạnh tới mức giá thuê
5	inferred_rooms	37.21	707.62	Số lượng phòng được thuật toán nội suy tự động từ văn bản
6	district_price_encoded	31.70	619.91	Đo lường mặt bằng giá thuê tại cấp độ quận huyện
7	rooms	38.09	585.99	Số lượng phòng ngủ báo cáo từ các nền tảng gốc
8	category_name	38.34	579.81	Biến phân loại phân biệt căn hộ, nhà phố hay mặt bằng kinh doanh

9	title_has_frontage	63.12	566.32	Từ khóa mặt tiền mang lại lợi thế thương mại và định giá cực cao
10	title_token_count	59.88	539.73	Số lượng từ trong tiêu đề tỷ lệ thuận với lượng thông tin cung cấp

Bảng 7.9: Xếp hạng mức độ quan trọng của đặc trưng định giá trên phân khúc Cho thuê

7.5 Phân tích phần dư sai số và các hạn chế tồn tại


7.5.1 Định nghĩa phần dư toán học

Phần dư được định nghĩa bằng sự chênh lệch toán học giữa giá trị thực tế của tài sản và mức giá do hệ thống dự báo. Để phục vụ việc phân tích trực quan trên ứng dụng, hệ thống lập trình tính toán hai loại phần dư. Phần dư trên thang giá gốc được xác định bằng phương trình:

$$e_i = price_i - \widehat{price}_i$$

Đồng thời, để tránh sai số hiển thị quá lớn và khó quan sát trên biểu đồ phân tán, hệ thống tính toán thêm phần dư trên thang đo logarit bằng phương trình:

$$e_i^{log} = \log(1 + price_i) - \log(1 + \widehat{price}_i)$$



Hình 7.2: Sơ đồ hệ thống biểu đồ phân tích phần dư hiển thị trực tiếp trên giao diện ứng dụng

Mục tiêu của việc phân tích này không chỉ đơn thuần là để kiểm tra xem mô hình đang đúng hay sai, mà quan trọng hơn là để đội ngũ phát triển nhìn nhận mô hình đang dự đoán sai ở khu vực nào và bóc tách gốc rễ nguyên nhân gây ra sự sai lệch đó.

7.5.2 Phân tích nguyên nhân sai số ở phân khúc siêu cao cấp

Việc phân tích hệ thống biểu đồ trên giao diện ứng dụng chỉ ra rằng thuật toán dự báo hoạt động khá tốt ở dải giá phổ thông nhưng tỷ lệ sai số bắt đầu phình to mất kiểm soát ở nhóm bất động sản siêu cao cấp. Ở ngưỡng giá trị hàng chục tỷ đồng, quy luật định giá chỉ dựa trên diện tích nhân với đơn giá bị phá vỡ hoàn toàn. Giá trị tài sản lúc này bị thay đổi bởi hàng loạt yếu tố vô hình mang tính độc bản không được lưu trữ dưới dạng cấu trúc cơ sở dữ liệu. Chính vì những yếu tố ẩn này, một căn nhà dù nằm cùng một quận và có cùng một diện tích nhưng vẫn có thể sở hữu mức giá chót hợp đồng cuối cùng khác rất xa nếu tài sản đó vượt trội về độ an toàn pháp lý, sở hữu mặt tiền đường tiếp cận lớn hơn, trang bị nội thất xịn hơn hoặc mang trong mình tiềm năng khai thác dòng tiền kinh doanh thương mại tốt hơn.

Nhóm biến số ẩn ngoại sinh	Ví dụ thực trạng trên thị trường giao dịch	Tác động trực tiếp đến sai số định giá
Yếu tố phong thủy học	Hướng nhà, số nhà xấu, hình dáng thế đất nở hậu hay tóp hậu	Có thể làm giá tăng hoặc giảm rất mạnh nhưng dữ liệu hiện tại không có cột cấu trúc để máy học
Chất lượng vật liệu nội thất	Mức độ bàn giao trang bị full nội thất cao cấp, thiết bị bếp, vật liệu hoàn thiện	Ảnh hưởng cực kỳ nghiêm trọng đến biên độ định giá của các hợp đồng thuê căn hộ và nhà phố
Tình trạng pháp lý tài sản	Tiến độ hoàn công xây dựng, tình trạng sổ hồng riêng hay đồng sở hữu, quy hoạch	Có thể tạo ra ranh giới chênh lệch giá thanh khoản cực kỳ khổng lồ
Vị trí không gian vi mô	Độ rộng lộ giới thực tế, tính chất hẻm xe hơi thật hay ảo, tình trạng căn góc hai mặt tiền	Ký tự văn bản trong tiêu đề có dùng biểu thức chính quy nhưng vẫn chưa đủ chiều sâu chi tiết
Tiện ích hạ tầng xã hội	Khoảng cách gần trạm tàu điện ngầm, khu đô thị khép kín, trường quốc tế, công viên	Hệ thống hiện tại chưa tích hợp thuật toán phân tích khoảng cách địa lý đến các điểm tiện ích xung quanh
Chất lượng tin đăng	Mức giá đăng ảo, giá thương lượng đẩy lên cao, tin do nhiều môi giới đăng trùng lặp	Góp phần làm nhiều nghiêm trọng tín hiệu của nhãn mục tiêu trong quá trình huấn luyện

Bảng 7.10: Phân tích các biến số ẩn ngoại sinh gây ra sai số cho hệ thống dự báo

7.5.3 Các dạng sai số thường gặp trên biểu đồ

Quá trình phân tích chẩn đoán trên biểu đồ chỉ ra các dạng sai số điển hình của hệ thống. Khi các điểm phân tán nằm dưới đường chéo lý tưởng đối với giá trị thực tế lớn, mô hình đang dự đoán quá thấp do bị kéo về mức mặt bằng chung vì khuyết thiếu các biến số đánh giá độ cao cấp. Ngược lại, điểm nằm trên đường chéo khi giá trị thực

tế thấp phản ánh những tin rao bán gấp, vướng mắc rủi ro pháp lý, vị trí phong thủy xấu hoặc đơn giản là lỗi nhập liệu từ người đăng tin.

Dạng sai số hệ thống	Biểu hiện trên biểu đồ phân tán	Nguyên nhân gốc rễ có thể xảy ra
Dự đoán quá thấp ở phân khúc giá rất cao	Các điểm nằm dưới đường phương trình $y=x$ khi actual rất lớn	Mô hình bị kéo về mặt bằng giá chung, khuyết thiếu các biến mô tả tài sản hạng sang
Dự đoán quá cao ở các tin rẻ bất thường	Các điểm nằm trên đường phương trình $y=x$ khi actual rất thấp	Chủ tài sản cần bán gấp trả nợ, vướng mắc pháp lý, vị trí phong thủy xấu hoặc nhập sai dữ liệu giá
Sai số cục bộ theo khu vực địa lý	Một số quận huyện có chỉ số sai số phần trăm cao hơn mức trung bình toàn cục	Số lượng mẫu thu thập tại đó quá ít, nhiều loại hình tài sản pha trộn lẫn nhau, hoặc tọa độ địa lý chỉ là điểm ước lượng tâm
Sai số phân mảnh theo loại hình tài sản	Các phân khúc như đất nền, biệt thự, mặt bằng có biên độ sai số rất lớn	Nhóm phân khúc này có không gian mẫu nhỏ hoặc chịu nhiều yếu tố chủ quan vượt ngoài thông số diện tích và vị trí thông thường

Bảng 7.11: Chẩn đoán các dạng sai số phần dư phổ biến trên hệ thống ứng dụng

7.5.4 Tổng hợp các điểm hạn chế còn tồn tại

Phân tích dữ liệu thực tiễn và kết quả biểu đồ chỉ ra 7 điểm hạn chế còn tồn đọng trong khuôn khổ của đề án:

1. Toàn bộ dữ liệu thu thập chỉ là mức giá rao bán kỳ vọng, hoàn toàn không phải là mức giá giao dịch thực tế vì chủ tài sản luôn rao cao hơn giá chốt và thị trường luôn tồn tại biên độ thương lượng chiết khấu.


2. Bộ dữ liệu bị khuyết thiếu các biến số mô tả sâu sắc về tài sản như hướng nhà, tình trạng pháp lý chi tiết, chất lượng nội thất cao cấp, số tầng lầu, tầm nhìn ban công, tiện ích nội khu và độ rộng lộ giới đường đi thực tế.
3. Một số nhãn loại hình bất động sản chưa được gom nhóm chuẩn hóa thành một bộ phân loại tuyệt đối duy nhất, ví dụ các nhãn mang ý nghĩa giống nhau như Căn hộ, Căn hộ/Chung cư, Căn hộ chung cư vẫn đang tồn tại song song.
4. Nguồn dữ liệu thu thập bị mất cân bằng nghiêm trọng khi nền tảng Mogi và Chợ Tốt chiếm tỷ trọng quá lớn, khiến các nguồn dữ liệu nhỏ bé bị lép vế hoàn toàn về số lượng cung cấp.
5. Tình trạng khuyết thiếu tọa độ địa lý gốc diễn ra phổ biến. Nhiều dòng bản ghi buộc hệ thống phải kích hoạt phương thức nội suy không gian ước lượng dựa trên điểm tâm của khu vực hành chính, phương pháp này tuy phù hợp để hiển thị trực quan bản đồ nhưng chưa đủ sắc nét để phục vụ cho các mô hình không gian chi tiết.
6. Thị trường bất động sản luôn tồn tại các giá trị ngoại lệ tự nhiên cực lớn, điển hình như nhà phố khu trung tâm, biệt thự cao cấp hay mặt bằng kinh doanh tổng hợp có phân phối giá tạo thành dạng đồ thị rất dài phần đuôi.
7. Hiện tại hệ thống đang đánh giá hiệu năng bằng phương pháp phân chia dữ liệu tính 80/20 có phân tầng theo nguồn gốc, chưa triển khai được phương pháp kiểm chứng chéo theo chuỗi thời gian vì lượng dữ liệu lịch sử chưa đủ dài. Khi có đủ dữ liệu hơn, phương pháp kiểm chứng theo trục thời gian sẽ được bổ sung để đánh giá độ bền bỉ thực tế của hệ thống.

7.6 Kết quả phân cụm thị trường bằng thuật toán K-Means

Bên cạnh bài toán dự đoán giá vì mô cho từng tin đăng đơn lẻ, dự án triển khai thuật toán học không giám sát K-Means để tiến hành phân nhóm cấu trúc thị trường theo góc nhìn vĩ mô. Kết quả ghi nhận hệ thống tổng hợp được 305 ô thị trường và cắt chúng thành tối đa bốn cụm chiến lược cho từng loại hình giao dịch riêng biệt. Các biến định lượng được đưa vào phương trình phân cụm bao gồm mặt bằng giá trên mét vuông trung vị, diện tích trung vị và tổng dung lượng tin đăng quan sát được trong từng ô.

Loại hình phân khúc giao dịch	Số lượng Cụm 1	Số lượng Cụm 2	Số lượng Cụm 3	Số lượng Cụm 4	Tổng số lượng ô thị trường	Biến định lượng dùng để phân rã
Giao dịch Rao Bán	17	6	107	24	154	median price/m ² , median area, listing count
Giao dịch Cho Thuê	7	138	5	1	151	median price/m ² , median area, listing count
Tổng không gian phân nhóm	24	144	112	25	305	

Bảng 7.12: Tổng hợp kết quả phân rã không gian ô thị trường vĩ mô bằng thuật toán K-Means



Hình 7.3: Biểu đồ phân cụm cấu trúc thị trường vĩ mô bằng thuật toán K-Means

Kết quả tính toán của thuật toán phân cụm cung cấp dữ liệu nền tảng vô cùng hữu ích để giao diện ứng dụng vẽ các biểu đồ bong bóng. Khi người dùng quan sát biểu đồ này, trục hoành càng lớn phản ánh quy mô diện tích trung vị càng cao, trục tung càng lớn phản ánh mức giá trên một mét vuông trung vị càng đắt đỏ. Kích thước của bong bóng càng lớn chứng tỏ nguồn cung thanh khoản của phân khúc đó càng dồi dào, và màu sắc khác nhau được hệ thống tô lên nhằm phân định các cụm thị trường mang cấu

trúc đặc trưng riêng biệt. Nhờ công cụ trực quan này, người dùng ứng dụng có thể nhanh chóng trả lời các câu hỏi mang tính vĩ mô như: tìm kiếm khu vực nào đang có mặt bằng giá cao ngất ngưỡng nhưng diện tích lại chật hẹp, nhận diện nhóm thị trường nào đang nắm giữ nguồn cung thanh khoản nhiều nhất, hay khoanh vùng phân khúc nào đang có diện tích lớn nhưng đơn giá lại thấp để phù hợp cho định hướng đầu tư vùng ven an toàn.

7.7 Thảo luận tổng hợp

7.7.1 Điểm mạnh của kết quả đạt được

Quá trình thực nghiệm đã chứng minh dự án thiết kế thành công rực rỡ một đường ống dữ liệu đi xuyên suốt một vòng khép kín từ dữ liệu thô nguyên bản đến khi lên ứng dụng, huấn luyện mô hình và hiển thị thẳng lên bảng điều khiển. Việc tuân thủ nghiêm ngặt kỹ thuật phân tách tập dữ liệu có phân tầng theo nguồn gốc đã triệt tiêu độ lệch phân phối nguồn một cách hiệu quả. Đáng chú ý, cơ chế cô lập tiến trình tính toán bảng mã hóa mục tiêu hoàn toàn vào bên trong tập huấn luyện đã loại bỏ triệt để hiện tượng rò rỉ thông tin từ tập kiểm thử. Quá trình thực nghiệm đã mạnh dạn so sánh đầy đủ 5 kiến trúc thuật toán bao gồm cơ sở, túi kết hợp, tăng cường tuần tự và lai tạo tối ưu. Hệ thống không chỉ có mô hình học có giám sát mà còn triển khai thành công cả thuật toán học không giám sát phân rã thị trường. Cuối cùng, đồ án đảm bảo tính khoa học và minh bạch tuyệt đối khi mọi biểu đồ đo lường sai số và báo cáo chất lượng phần dư đều được công khai trực quan trên giao diện ứng dụng mà không hề che giấu bất kỳ điểm hạn chế kỹ thuật nào.

7.7.2 Ý nghĩa ứng dụng thực tiễn

Với mức độ sai số hiện tại, hệ thống mô hình định giá này không nên được người sử dụng hiểu là một công cụ định giá tuyệt đối dùng để thay thế hoàn toàn cho quy trình khảo sát thẩm định giá hiện trường của các chuyên gia. Tuy vậy, hệ thống chứng minh được tính ứng dụng thực tiễn vô cùng to lớn thông qua việc cung cấp công cụ tự động ước lượng cực kỳ nhanh mặt bằng giá tham khảo trên quy mô diện rộng. Người dùng có thể dễ dàng so sánh một tin đăng đang xem xét với toàn bộ tập dữ liệu của cùng khu

vực và loại hình bất động sản. Công cụ này cũng giúp phát hiện ngay lập tức các tin đăng có mức định giá chào bán quá thấp hoặc quá cao một cách bất thường, hỗ trợ công tác tự động sinh báo cáo phân tích thị trường theo từng quận huyện, và đóng vai trò làm nền tảng thuật toán cơ sở vững chắc cho một hệ thống phân tích bất động sản có thể mở rộng nâng cấp trong tương lai.

7.7.3 Các định hướng cải thiện kiến trúc hệ thống

Định hướng cải thiện kỹ thuật trong tương lai	Tác động kỳ vọng mang lại cho hệ thống dự đoán
Chuẩn hóa lại bộ danh mục loại hình bất động sản	Giảm thiểu tín hiệu nhiễu do tồn tại quá nhiều nhãn từ vựng mang ý nghĩa giống hệt nhau
Bổ sung tính năng đọc hiểu đoạn văn bản mô tả dài	Trích xuất thành công được các yếu tố ẩn như tình trạng pháp lý, chất lượng nội thất, tiện ích tòa nhà và tình trạng nhà ở
Tích hợp thêm các dữ liệu không gian hạ tầng tiện ích xã hội	Bất được hiệu ứng tăng giá nhờ vị trí hưởng lợi gần trạm metro, trường học, bệnh viện, dòng sông hay công viên sinh thái
Áp dụng phương pháp mã hóa không gian Geohash	Thay thế thuật toán tính khoảng cách tuyến tính đơn giản bằng đường thẳng đến khu vực trung tâm Quận 1
Thiết lập cơ chế kiểm chứng chéo dựa trên chuỗi thời gian	Đánh giá được một cách chính xác khả năng tổng quát hóa và độ bền bỉ của thuật toán theo dọc trục thời gian
Phát triển thêm kỹ thuật thuật toán hồi quy phân vị	Trả về một khoảng giá dao động an toàn thay vì chỉ đưa ra một điểm dự đoán cố định duy nhất cho người dùng
Thử nghiệm kiến trúc mô hình CatBoost hoặc LightGBM	Tối ưu hóa cực mạnh năng lực học máy đối với các biến phân loại văn bản và cấu trúc dữ liệu dạng bảng khổng lồ

Bảng 7.13: Đề xuất các định hướng nâng cấp kiến trúc hệ thống dự đoán trong tương lai

Tóm lại, thông qua chuỗi thực nghiệm khắt khe, mô hình kết hợp Tuned RF/XGBoost Ensemble hiện đang là sự lựa chọn kiến trúc tối ưu nhất theo thước đo sai số phần trăm được lưu trữ trong tệp vật lý. Dù vậy, tỷ lệ sai số vẫn còn ở mức đáng kể bởi vì bản chất dữ liệu thu thập của ngành bất động sản tồn tại quá nhiều yếu tố phi cấu trúc mang tính định tính. Đây là một kết quả hoàn toàn hợp lý, phản ánh đúng bức tranh đa dạng và phức tạp đối với tập dữ liệu giá chào bán thu thập từ đa nguồn, đồng thời vạch ra một cách rõ ràng các định hướng cần phải mở rộng để từng bước nâng cấp chất lượng dự đoán trong tương lai.

CHƯƠNG 8. KẾT LUẬN

8.1 Đóng góp của đề tài

Nhóm đã phát triển thành công một hệ thống phần mềm phân tích dữ liệu hoàn chỉnh từ đầu đến cuối bằng ngôn ngữ R. Từ các đoạn mã cào dữ liệu ban đầu, hệ thống đã nạp và làm sạch thành công tập dữ liệu lớn với 30.250 dòng và 56 cột thuộc tính. Đồ án thể hiện khả năng vận dụng đa dạng các kỹ thuật lập trình như thao tác chuỗi văn bản, tính toán ma trận không gian, thực hiện kiểm định giả thuyết thống kê và huấn luyện thuật toán máy học song song. Đóng góp rõ nét nhất của đồ án là việc xây dựng thành công giao diện ứng dụng Shiny tích hợp trợ lý ảo cục bộ. Trợ lý này được viết bằng các quy tắc logic tự định nghĩa, cho phép nhận diện yêu cầu, bóc tách thông số diện tích hay ngân sách từ tiếng Việt và phản hồi nhanh chóng mà không cần tốn chi phí gọi dịch vụ API từ bên ngoài.

8.2 Hướng phát triển

Mặc dù hệ thống đã đáp ứng đủ các mục tiêu đề ra, mô hình dự đoán vẫn còn giới hạn vì sai số phần trăm chưa thực sự tối ưu, đặc biệt là ở mảng rao bán. Nguyên nhân chính là do dữ liệu thu thập từ web đang thiếu hụt trầm trọng các thông tin quyết định giá trị tài sản như mức độ hoàn thiện nội thất, chiều rộng của hẻm tiếp cận, hướng nhà và tình trạng giấy tờ pháp lý. Để nâng cấp hệ thống trong tương lai, nhóm đề xuất thu thập thêm tọa độ của các điểm tiện ích công cộng như trạm tàu điện, trường học, bệnh viện để đo lường độ sầm uất của vị trí. Bên cạnh đó, hệ thống cần chuẩn hóa triệt để hơn danh mục loại hình bất động sản để giảm thiểu tín hiệu nhiễu,

đồng thời áp dụng phương pháp kiểm chứng chéo theo trục thời gian để đánh giá độ ổn định của thuật toán khi thị trường có biến động.

TÀI LIỆU THAM KHẢO

- [1] R Core Team. R: A Language and Environment for Statistical Computing. Vienna, Austria: R Foundation for Statistical Computing. Truy cập tại: <https://www.r-project.org/>
- [2] Posit Software, PBC. Shiny: Web Application Framework for R. Truy cập tại: <https://shiny.posit.co/>
- [3] Tidyverse Team. Tidyverse: Packages for Data Science. Truy cập tại: <https://www.tidyverse.org/>
- [4] Wickham, H. (2016). ggplot2: Elegant Graphics for Data Analysis. Springer-Verlag New York. Truy cập tại: <https://ggplot2.tidyverse.org/>
- [5] Plotly Technologies Inc. Plotly for R: Interactive Data Visualization. Truy cập tại: <https://plotly.com/r/>
- [6] Cheng, J., Karambelkar, B., & Xie, Y. Leaflet: Create Interactive Web Maps with the JavaScript Leaflet Library. Truy cập tại: <https://rstudio.github.io/leaflet/>
- [7] Wickham, H. rvest: Easily Harvest (Scrape) Web Pages. Truy cập tại: <https://rvest.tidyverse.org/>
- [8] Ooms, J. jsonlite: A Robust, High Performance JSON Parser and Generator for R. Comprehensive R Archive Network (CRAN). Truy cập tại: <https://cran.r-project.org/web/packages/jsonlite/>
- [9] Liaw, A., & Wiener, M. randomForest: Breiman and Cutler's Random Forests for Classification and Regression. Comprehensive R Archive Network (CRAN). Truy cập tại: <https://cran.r-project.org/web/packages/randomForest/>

- [10] Chen, T., et al. xgboost: Extreme Gradient Boosting for R. Truy cập tại: <https://xgboost.readthedocs.io/en/stable/R-package/>
- [11] Bates, D., Maechler, M., et al. Matrix: Sparse and Dense Matrix Classes and Methods. Comprehensive R Archive Network (CRAN). Truy cập tại: <https://cran.r-project.org/web/packages/Matrix/>
- [12] Xie, Y., Cheng, J., & Tan, X. DT: A Wrapper of the JavaScript Library DataTables. Truy cập tại: <https://rstudio.github.io/DT/>
- [13] Sinnott, R. W. (1984). “Virtues of the Haversine”. Sky and Telescope, Vol. 68, No. 2, pp. 159. Tham khảo công thức Haversine tại: https://en.wikipedia.org/wiki/Haversine_formula
- [14] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to Linear Regression Analysis (6th Edition). Wiley. Tham khảo thêm tại: https://en.wikipedia.org/wiki/Ordinary_least_squares
- [15] Breiman, L. (2001). “Random Forests”. Machine Learning, 45(1), 5–32. DOI: 10.1023/A:1010933404324.
- [16] Chen, T., & Guestrin, C. (2016). “XGBoost: A Scalable Tree Boosting System”. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), pp. 785–794. DOI: 10.1145/2939672.2939785.
- [17] MacQueen, J. (1967). “Some Methods for Classification and Analysis of Multivariate Observations”. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Vol. 1, pp. 281–297. Tham khảo thêm tại: https://en.wikipedia.org/wiki/K-means_clustering
- [18] Willmott, C. J., & Matsuura, K. (2005). “Advantages of the Mean Absolute Error (MAE) over the Root Mean Square Error (RMSE) in Assessing Average Model Performance”. Climate Research, 30, 79–82.

- [19] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in R (2nd Edition). Springer. Nội dung tham khảo các chỉ số đánh giá mô hình: MAE, RMSE, R^2 .
- [20] Ross, S. M. (2019). Introduction to Probability and Statistics for Engineers and Scientists (6th Edition). Academic Press. Nội dung tham khảo: Định lý giới hạn trung tâm (Central Limit Theorem).
- [21] Efron, B., & Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall/CRC.
- [22] Welch, B. L. (1947). “The Generalization of Student's Problem when Several Different Population Variances are Involved”. *Biometrika*, 34(1–2), 28–35.
- [23] Mann, H. B., & Whitney, D. R. (1947). “On a Test of Whether One of Two Random Variables is Stochastically Larger than the Other”. *The Annals of Mathematical Statistics*, 18(1), 50–60.
- [24] Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). R for Data Science (2nd Edition). O'Reilly Media. Truy cập tại: <https://r4ds.hadley.nz/>
- [25] Kuhn, M., & Johnson, K. (2019). Feature Engineering and Selection: A Practical Approach for Predictive Models. Chapman & Hall/CRC.
- [26] Kuhn, M., & Wickham, H. (2020). Tidymodels: A Collection of Packages for Modeling and Machine Learning Using Tidyverse Principles. Truy cập tại: <https://www.tidymodels.org/>